

量化宏观经济学

满翔宇

2025-06-26 22:30

目录

I	量化宏观基础	1
1	序列视角下的动态优化	2
1.1	动态优化引例：消费-储蓄模型	2
1.1.1	消费储蓄模型设定	3
1.1.2	两期情形下的序列解	4
1.1.3	一般化形式的动态优化问题	5
1.1.4	有限期情形下的序列解	6
1.1.5	无限期情形、非庞氏条件与横截性条件	7
1.1.6	无限期情形下的消费-储蓄模型	11
1.2	新古典增长理论基础	12
1.2.1	索洛模型	13
1.2.2	稳态与动态	14
1.2.3	技术进步与平衡增长路径	16
1.2.4	特征事实：数据与模型	17
1.2.5	收敛性分析	19
1.2.6	应用索洛模型：增长核算	21
1.3	确定性最优增长：RCK 模型	22
1.3.1	有限期情形	24
1.3.2	无限期情形	26
1.3.3	RCK 模型中的平衡增长路径	28
2	递归方法与动态规划	30
2.1	递归与动态规划的基本概念	30
2.1.1	由序列问题转向递归形式	30
2.1.2	状态变量、贝尔曼方程与决策规则	32
2.1.3	欧拉泛函	33
2.1.4	递归问题解法的启示：贝尔曼方程 vs 欧拉泛函	34

2.2	递归形式下的最优增长模型	35
2.2.1	贝尔曼方程与一阶条件	35
2.2.2	包络定理与欧拉泛函	36
2.2.3	引利：连续逼近法求解	37
2.3	数学准备	39
2.3.1	度量空间中的收敛性	39
2.3.2	压缩映射定理	42
2.3.3	应用 CMT	45
2.4	值函数的存在性与性质	47
2.4.1	最优性原理：序列解与递归解的关系	47
2.4.2	最优策略间的关系	52
2.4.3	最大化定理和不动点的存在与唯一性	53
2.4.4	值函数与策略函数的性质	56
2.5	最优增长模型的稳态	58
2.6	数值解法初步：值函数迭代	59
2.6.1	值函数迭代基本算法	60
2.6.2	改进值函数迭代：插值	66
2.6.3	值函数迭代的改进：	68
2.6.4	投影法的初步实现：配置算法	68
2.6.5	Euler Based Methods	68
3	数值方法	69
3.1	引例：随机最优增长	69
3.1.1	基本概念与模型设定	69
3.1.2	序列问题和状态依存计划	71
3.1.3	递归形式下的随机最优增长	72
3.1.4	数值求解难点	73
3.2	求根方法	75
3.3	数值优化	75
3.4	马尔可夫过程与条件期望	75
3.4.1	转移路径与概率分布的运动方程	77
3.4.2	平稳分布	78
3.4.3	马尔可夫假设下的随机最优增长	80
3.5	马尔可夫近似与离散化估计	82
3.5.1	TauChen (1986) 方法	83

3.5.2	Rouwenhorst 方法	84
3.5.3	Tauchen-Hussey (1991) 方法	85
3.5.4	求解离散化的随机最优增长	86
3.6	数值积分	86
3.7	Function Approximation	86
3.8	Projection Methods	87
3.9	EGM	87
4	完备市场理论与宏观经济学中的均衡	88
4.1	完备市场理论基础	88
4.1.1	经济环境设定	88
4.1.2	两种交易结构	89
4.1.3	帕累托问题	92
4.2	Arrow-Debreu 市场中的均衡	94
4.2.1	Arrow-Debreu 竞争均衡价格	98
4.2.2	Arrow-Debreu 竞争均衡的算法	99
4.2.3	阿罗-德布鲁均衡配置	99
4.2.4	福利经济学定理	100
4.2.5	应用：资产定价初步	100
4.3	序贯市场下的均衡	102
4.3.1	自然债务限制与序贯市场均衡	104
4.3.2	均衡等价性	107
4.4	递归竞争均衡	112
4.4.1	马尔可夫性下均衡的特征	113
4.4.2	定义递归均衡	115
4.5	完备市场理论的应用	117
4.5.1	代表性家庭的存在性	117
4.5.2	资本资产定价 (CAPM)	119
4.6	均衡概念的运用：分散经济下的最优增长模型	119
4.6.1	AD	119
4.6.2	SQ	119
4.6.3	Recursive Competitive Equilibrium	119
4.6.4	Summarize	120

5	DSGE	121
5.1	线性化求解	121
5.1.1	对数线性化	121
5.1.2	线性化 RCK 模型的稳定性	122
5.1.3	线性差分方程解的性质	125
5.1.4	转移路径求解	129
5.1.5	Blanchard-Khan 条件：求解线性理性预期模型	130
5.1.6	广义 Shur 方法	138
5.2	RBC	138
5.3	新凯恩斯-DSGE	138
6	宏观计量理论与方法	139
6.1	Empirical Macro Methods	139
6.2	DSGE 模型的估计与贝叶斯方法	139
6.3	结构估计	139
II	量化宏观核心理论	140
7	不完全市场理论	141
7.1	局部均衡下的不完全市场	141
7.2	一般均衡下的不完全市场	141
8	总体不确定下的异质性模型	142
8.1	Krusell-Smith 算法	142
8.2	实现 KS 算法	142
8.3	Reiter 算法	142
9	企业动态	143
9.1	企业动态基础	143
9.2	微观异质性与宏观动态	143
III	现代量化宏观主要模型：HANK	144
10	异质性家庭理论	145
10.1	TANK 模型	145

10.2 HANK 模型	145
11 异质性企业理论	146
11.1 异质性企业模型求解	146
11.2 金融异质性	146
IV 量化宏观专题	147
12 宏观债务、周期与政策	148
12.1 企业债务	148
12.2 家庭债务	148
12.3 政府债务	148
13 银行、金融危机与宏观政策	149
13.1 银行挤兑	149
13.2 银行资本	149
13.3 宏观政策与金融危机	149
14 异质性模型前沿理论	150
14.1 Structural Method	150
14.2 深度强化学习与分布计算	150

Part I 量化宏观基础

1 序列视角下的动态优化

现代宏观经济学基于对经济主体行为的优化来研究经济运行的动态过程。因此，动态优化是学习量化宏观的基础。宏观经济理论发展至今，对动态优化问题形成了两种处理方法：**一是序列视角**：通过求解差分（微分）方程为经济主体选择一个最优的序列（有限或是无穷），这是处理动态问题的基本视角；**二是递归视角**：定义从当期到下期的映射，利用动态规划方法将优化问题转化为泛函方程的求解。

本章通过宏观经济学中两种重要模型对序列视角下的动态优化进行初步介绍：消费-储蓄模型和新古典增长模型。借助消费-储蓄问题，我们将初步掌握动态优化问题的基本概念与序列解的基本方法。接着，我们将详细学习新古典增长理论：先对经典的索洛模型进行回顾，深化对动态宏观基本概念和理论的认识；然后，借助现代宏观经济学的基石模型（Workhouse Model）——新古典增长模型（或称最优增长模型），深化对序列视角下动态优化理论的理解，为下一章递归方法和动态规划的学习奠定基础。

1.1 动态优化引例：消费-储蓄模型

一个典型的宏观模型包含如下结构：（1）个体（家庭）通过优化问题决定其消费；（2）企业决定其生产；（3）政府政策的决定。本章将对第一个方面——个体决策进行介绍，进而掌握求解动态优化问题的初步理论方法，为后续量化模型的学习奠定基础。事实上，动态优化是宏观模型能够刻画经济动态的核心所在。个体在今天和未来间进行权衡：通过牺牲一些今天的利益来获取将来的收益。例如，在我们将要看到的引例——消费-储蓄模型中，个体可以选择在今天储蓄（降低当前消费）来换取增加未来消费的可能。这背后的一个关键假设是个体是关注未来的（Forward Looking），这一概念最早由 Friedman（1957）提出。这意味着，个体不仅基于当前收入进行选择，同时还考虑他们未来的**期望收入**。换句话说，消费和储蓄是依赖于期望的。后续的研究进一步引入了**理性预期**（Rational Expectation）的思想，即个体在利用所有可得的信息对未来做出最优预测的基础上，进行当前决策。我们后续看到的大部分模型都将这一假设作为默认。对于理性预期的偏离一般涉及行为经济学的内容，不是我们的重点。下面介绍基本的消费-储蓄模型，用于引出动态优化问题及其序列化求解方法。

1.1.1 消费储蓄模型设定

模型中存在一个代表性个体 (Representative Agent), 生存 T 期, 偏好为 $U(\{c_t\}_{t=0}^T)$, 选择最优的第 t 期的消费流 $\{c_t\}_{t=0}^T$ 来最大化其偏好。假设偏好是可加可分的 (Additive Separability):

$$U(\{c_t\}_{t=0}^T) = \sum_{t=0}^T \beta^t u(c_t)$$

可加可分意味着 t 期消费的边际效用不会依赖其余时刻的消费。折现因子 $0 < \beta < 1$, 这与消费者通常更重视近期而不是更远的未来相合。当期效用 (瞬时效用) $u(\cdot)$ 不依赖时间, 并作如下假设:

假设 1.1 $u(c)$ 严格递增;

假设 1.2 $u(c)$ 严格凹;

假设 1.3 Inada 条件: $\lim_{c \rightarrow 0} u'(c) = \infty$

方便起见, 假设**禀赋经济**: 个体每期得到一单位时间劳动并将其无弹性地用于生产, 以获得工资 w_t 。¹ 个体能够在金融市场进行借贷, 记其资产为 a_t , 负的资产即表示负债。假设储蓄的利率为 r_t , 从而**预算约束**为:

$$c_t = w_t + (1 + r_t)a_t - a_{t+1}$$

当个体选择借入, 那么他今天能够消费的更多, 但是由于需要支付本息, 因此未来的消费降低。另一个规范化的假设是假定借款上限, 即 $a_{t+1} \geq \underline{a}$, 其中 $\underline{a}$ 是外生常数。这一假设的存在通常是为了排除庞氏骗局, 一般将最弱的 $\underline{a}$ 取值称为自然债务限制 (Natural Debt Limit), 我们将在本章后面和第4章完全市场的讨论中详细研究这一概念。若假设有限期的 T , 则终期必须要求 $a_{T+1} \geq 0$, 否则个体在 T 时刻会直接选择借入至限制并且不还款, 这在均衡时是不可能实现的, 因为金融市场上将不再存在贷出方。我们可以将动态优化问题写为:

$$\begin{aligned} \max_{\{c_t, a_{t+1}\}_{t=0}^T} & \sum_{t=0}^T \beta^t u(c_t) \\ \text{s.t. } & c_t = w_t + (1 + r_t)a_t - a_{t+1}, \forall t \in \{0, \dots, T\} \\ & c_t \geq 0, \forall t \in \{0, \dots, T\} \\ & a_{t+1} \geq \underline{a}, \forall t \in \{0, \dots, T\} \\ & a_{T+1} \geq 0 \end{aligned} \tag{P1}$$

¹也可直接假设外生禀赋流 $\{y_t\}_{t=0}^T$, 没有本质区别。

在上述问题中，我们假设个体在决策时知道价格（工资和利率）序列，并将其视为给定。在第4章竞争均衡的讨论中将详细研究价格的决定。我们的目标是得到最大化终身效用的消费和资产的最优序列 $\{c_t, a_{t+1}\}_{t=0}^T$ 。下面进行求解。

1.1.2 两期情形下的序列解

假设 $T < \infty$ ，自然想到利用库恩塔克定理进行序列问题优化。事实上，如果目标函数严格凹并且约束集是有界闭凸集，那么库恩塔克条件是最优性的充分必要条件。不失一般性，假设两期模型 $t = 0, 1$ ，即经济从第 0 期初开始，在第 1 期末结束， $T = 1$ 。假设 $\bar{a} = 0$ ，初始资产 $a_0 = 0$ 。为了方便解释，假设禀赋递减，即 $w_0 \geq w_1$ 和 $r_t = r$ 。因此，预算约束序列为：

$$c_0 = w_0 - a_1 \quad \text{and} \quad c_1 = w_1 + (1+r)a_1$$

其中，第二个预算约束中我们用到了末期借款上限约束为紧 $a_2 = 0$ 。这是符合直觉的，因为如果经济在第 1 期末结束，那么个体不可能在第一期决策时选择储蓄 $a_2 > 0$ ，否则其效用一定有提升的空间。我们可以将序列约束合并为终身预算约束：

$$c_0 + \frac{c_1}{1+r} = w_0 + \frac{w_1}{1+r}$$

它表明折现后的终身消费价值等于折现后的终身收入，折现因子 $1/(1+r)$ 是第 0 期和第 1 期消费的相对价格。此外， $a_1 \geq 0$ 等价于 $w_0 - c_0 \geq 0$ 。拉格朗日方程为：

$$\begin{aligned} \mathcal{L} = & u(c_0) + \beta u(c_1) + \mu \left\{ w_0 + \frac{w_1}{1+r} - c_0 - \frac{c_1}{1+r} \right\} \\ & + \lambda \{w_0 - c_0\}, \end{aligned}$$

我们无需考虑消费的非负约束，因为效用函数的 Inada 条件 $\lim_{c_t \rightarrow 0} u'(c_t) = \infty$ 保证了个体用于会选择 $c_t > 0$ 。关于 c_0 和 c_1 的一阶条件为：

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial c_0} : & \quad u'(c_0) - \mu - \lambda = 0 \\ \frac{\partial \mathcal{L}}{\partial c_1} : & \quad \beta u'(c_1) - \mu \frac{1}{1+r} = 0 \end{aligned}$$

相关的 KT 条件为：

$$\begin{aligned} \lambda [w_0 - c_0] &= 0 \\ w_0 - c_0 &\geq 0 \quad \text{and} \quad \lambda \geq 0 \end{aligned}$$

考虑内点解情形 $w_0 - c_0 > 0$, 即 $\lambda = 0$ 。由于假设工资禀赋递减, $w_0 > w_1$, 结合消费的边际消费效用递减和一个关于 $\beta(1+r)$ 的温和的假设, 可以保证内点解的存在, 进而可以写出消费欧拉方程:

$$u'(c_0) = \beta(1+r)u'(c_1)$$

方程左侧是多储蓄一单位在 $t=0$ 的边际成本, 右侧是其在 $t=1$ 带来的边际效用。注意到, 当 $\beta(1+r) = 1$, 个体每期会选择消费其终身效用的一个常数部分, 即:

$$c_0 = c_1 = \frac{w_0 + \beta w_1}{1 + \beta}$$

带回预算约束验证可以发现: $w_0 - c_0 \equiv a_1 = \frac{w_0 - w_1}{r+2} > 0$ 。

1.1.3 一般化形式的动态优化问题

我们可以将经济中各主体面临的动态优化问题写为如下更一般化的形式:

$$\begin{aligned} \max_{\{y_t, x_{t+1}\}_{t=0}^T} \quad & \sum_{t=0}^T \beta^t \hat{\mathcal{F}}(y_t) \\ \text{s.t.} \quad & x_{t+1} = h(x_t, y_t) \\ & x_{t+1} \in \Gamma(x_t). \end{aligned} \tag{P2}$$

其中, $\sum_{t=0}^T \beta^t \hat{\mathcal{F}}(y_t)$ 称为目标函数 (Objective Function)。 β 是折现因子, $1/\beta - 1$ 被称为折现率。由于任意两期间折现因子的比值仅依赖于两期间的间隔, 而不依赖具体时刻, 因此它们又被称为平稳的。简单说, $\frac{\beta^{t+k}}{\beta^t} = \beta^k$ 。 T 可以取无穷。

序列 $\{y_t\}_{t=0}^T$ 是需要决定的变量, 被称为控制变量, 例如上面的消费、储蓄。序列 $\{x_t\}_{t=0}^T$ 表征了当前系统的状态, 被称为状态变量, 例如上面每期的初始资产 (债务)。控制变量和状态变量由约束 $x_{t+1} = h(x_t, y_t)$ 相联系, 例如 h 可能是上面的预算约束。初始状态 x_0 是外生给定的。一般, 控制变量和状态变量是不难区分开的: 注意到, 如果个体在第 0 期选择了 y_0 , 那么由于 x_0 外生给定, 下期的状态 x_1 自动由约束 $x_1 = h(x_0, y_0)$ 确定下来; 同理, 在第 1 期, 个体选择的 y_1 和已经确定的 x_1 决定了下期的状态 x_2 , 依次类推。简单说, t 期选择的最优控制变量决定了 $t+1$ 期的状态变量。 $\Gamma(x_t)$ 是可行集, 它表示: 给定当前状态 x_t , x_{t+1} 的可行取值范围。

我们希望建立的优化问题是良定义的 (解存在), 这需要一些假设。由瓦尔斯特拉斯定理: 连续函数在非空紧集上可以取到最大和最小值。其中, 紧集即为有界闭集。使这一定理适用的充分条件如下: (1) $\hat{\mathcal{F}}(y_t)$ 对所有 y_t 连续; (2) $h(x_t, y_t)$ 连续, 关于所有 (x_t, y_t) 严格单调; (3) $\Gamma(x_t)$ 对所有 x_t 是非空有界闭集。其中第 2 条假设使我们可以将 y_t 表达

为 (x_t, x_{t+1}) 的（连续）函数，进而单期目标函数 $\hat{\mathcal{F}}(y_t)$ 可以写成关于向量 (x_t, x_{t+1}) 的连续函数。因此，我们得到了总体上连续的函数（关于序列 $\{x_1, x_2, \dots, x_T, x_{T+1}\}$ ），并要在非空紧集上对其最大化。由定理，这是可以实现的。

我们可以将前面建立的消费-储蓄模型对应到这一一般形式上。其中，单期目标函数 $\hat{\mathcal{F}}(\cdot)$ 即为效用函数 $u(\cdot)$ ；控制变量 y_t 由消费序列 $\{c_t\}_{t=0}^T$ 构成；状态变量 x_t 是资产： $x_t = a_t$ ；约束 $h(a_t, c_t) = w_t + (1 + r_t)a_t - c_t$ ；可行集为 $\Gamma(a_t) = [\underline{a}, w_t + (1 + r_t)a_t]$ ，其中上界确保了储蓄不超过当期收入，即消费的非负性。

1.1.4 有限期情形下的序列解

我们已经利用拉格朗日函数和库恩塔克定理求解出了一个特定的两期、线性约束的序列问题。但是，对一般化形式的动态优化问题，若其中的约束 h 是非线性的，我们可能无法构建终身预算约束，这样的序列问题还能够求解吗？事实上，对一般化问题，只要 T 取有限值，库恩塔克定理依然使用。我们直接给出相应结论：²

性质 1.1 对一般化的动态优化问题式 (P2)：

$$\begin{aligned} \max_{\{y_t, x_{t+1}\}_{t=0}^T} \quad & \sum_{t=0}^T \beta^t \hat{\mathcal{F}}(y_t) \\ \text{s.t.} \quad & x_{t+1} = h(x_t, y_t) \\ & x_{t+1} \in \Gamma(x_t). \end{aligned}$$

在有限期情形下，记 $\Gamma(x_t) = [\underline{x}, \gamma(x_t)]$ ，利用约束 $x_{t+1} = h(x_t, y_t)$ 可以解得 y_t ，记为 $y_t = \hat{h}(x_t, x_{t+1})$ ，将其带入当期目标函数，可记 $\mathcal{F}(x_t, x_{t+1}) \equiv \hat{\mathcal{F}}(\hat{h}(x_t, x_{t+1}))$ ，从而我们可得改写后的最大化问题：

$$\max_{\{x_{t+1} \in \Gamma(x_t)\}_{t=0}^T} \sum_{t=0}^T \beta^t \mathcal{F}(x_t, x_{t+1})$$

假设 $\mathcal{F}(x_t, x_{t+1})$ 关于第一个参数递增，关于第二个参数递减，连续可微，并且关于 (x_t, x_{t+1}) 凹。若成立：

- $\mathcal{F}_2(x_t^*, x_{t+1}^*) + \beta \mathcal{F}_1(x_{t+1}^*, x_{t+2}^*) = 0, \forall t < T$ ，其中 $\{x_{t+1}^*\}_{t=0}^{T-1} \in \text{int } \Gamma(x_t)$ ；
- $x_{T+1}^* = \underline{x}$ ；

那么序列 $\{x_{t+1}^*\}_{t=0}^T$ 最大化目标。

²在无限期情形下也存在类似结论，我们届时将会证明。而证明过程中也包含有限期情形，因此此处证明略去。

这一结论表明，对**有限期动态优化问题**：末期的最优选择是可行集的下界 $\underline{x}$ ； $t < T$ 时的**内点解**满足一阶条件，这一条件是一般化问题的**欧拉方程**。注意到，共有关于 $T + 2$ 个未知变量（即状态序列）的 $T + 2$ 个方程，以及一个期初和一个终期条件。通常称之为状态变量序列的**差分方程**。由于方程中存在 x 的两期滞后项，因此这是一个二阶差分方程。又由于未知量数目等于方程数目，因此这一差分系统是有解的。

1.1.5 无限期情形、非庞氏条件与横截性条件

无限期情形相比于有限期情形的优点在于：个体问题是**平稳的**，即 t 期的最优化问题与 $t + 1$ 期的最优化问题结构完全一致（只要两期起始的资本存量水平相同）；而在有限期情形下，最优决策是与剩余时间相关的（在后面我们将举例）。但是，无限期设定也会带来相应问题，其中最为核心的是：由于要求解的（无穷）最优序列不再是欧几里得空间中的元素，动态优化问题的解是否还存在？具体看：假设需要最大化函数 $U(x)$ ， $x \in S$ ，其中 S 是包含无穷序列的集合。我们提到，若函数 U 连续， S 是非空紧集，那么可以利用威尔斯特拉斯定理。这里的连续、紧、开闭对于有限维序列集合是容易定义的；但是对无穷维序列，如何定义连续、集合开闭、紧集等？事实上，对无限期情形，的确需要一些额外条件来保证问题是良定义的，Stokey & Lucas（1989）解决了这些问题，我们不再具体讨论。我们给出一些导致解不存在的例子来帮助理解。

例 1.1 无界效用/无界报酬：目标函数的连续性需要有界性来保障。确保终身效用 U 有界的一个必要条件是：消费流不会产生无限效用。若存在两个消费流，他们都产生无限效用，那么他们就无法被比较，导致最大化问题不是良定义的。考虑如下一个消费流： $\{c_t\}_{t=0}^{\infty} = \{\bar{c}\}_{t=0}^{\infty}$ 。只有 $\beta < 1$ 时， $U = \sum_{t=0}^{\infty} \beta^t u(\bar{c})$ 才是有界的。

例 1.2 可行集过大：可行集范围过大也可能导致问题不是良定义的。典型的例子就是上面消费储蓄模型中的借款上限，这一约束条件使得可行集有界，进而确保了解的存在性。但是，对任意时刻 t 施加 $a_{t+1} \geq \underline{a}$ 过于严格，可能导致一些可行方案被挤出。我们可以只对**终端**施加约束 $a_{T+1} \geq 0$ ，即个体在最后不能借款。这一**终端约束**（Terminal Constraint）十分重要，否则个体存在积累无穷债务至终期的激励。但是，由于债权方知道债务方的这一计划，即一定会被违约，因此无人会提供资金。

在**无限期情形**下，由于没有终结时间，因此上述终端约束失去了意义，但我们可以将其进行适当拓展来排除庞氏骗局（Ponzi Scheme），即债务现值超过收入现值（个体无限地滚动债务来借新还旧）。我们称这样的条件为**非庞氏条件**（No Ponzi Game Condition），它确保了可行集不会过大，否则个体将能获得任意高的效用水平。下面的例子说明了如何得到这一条件。

例 1.3 非庞氏条件：假设个体初始净资产为 a_0 ，代表对其他个体的索取权，假设没有其余收入来源，利率 $r > 0$ ，从而预算约束为：

$$c_t + a_{t+1} = (1 + r)a_t, \forall t \geq 0$$

假设个体最优消费有如下一组待选解 $\{c_t^*\}_{t=0}^\infty$ 。若没有其余约束，那么个体可以用如下方案改善消费：

- 令 $\tilde{c}_0 = c_0^* + \epsilon$, $\epsilon > 0$ ，进而令 $\tilde{a}_1 = a_1^* - \epsilon$ ；
- 对每一期 $t \geq 1$ ，保留 $\tilde{c}_t = c_t^*$ 即可并令 $\tilde{a}_{t+1} = a_{t+1}^* - \epsilon(1 + r)^t$ 。

给定严格递增的效用函数，在新消费配置下，个体明显效用更好，并且预算约束序列全部满足。但是，这一改善方案对任一可行消费序列均成立，因此不可能找到最大值。并且注意到，在这一配置方案下，个体的债务以 $1 + r$ 无界增长：即在每期 t 都借 $(1 + r)a_t$ 来滚动债务，这正是上面所说的**庞氏骗局**。因此在**无限期情形下**，必须施加**非庞氏条件**，它具有如下形式：

$$\lim_{t \rightarrow \infty} \frac{a_{t+1}}{(1 + r)^t} \geq 0 \quad (1.1)$$

这一约束的作用十分直观：个体在借贷过程中终端（无穷远处）资产的现值不能为负，否则他们不会偿还债务。

利用非庞氏条件可以简化原来的无穷预算约束序列：首先，用第 1 期的预算约束表达出 a_1 ，即 $a_1 = (c_1 + a_2)/(1 + r)$ ，将其表达式代回第 0 期的预算约束，从而得到包含 c_0, c_1, a_0, a_2 的第 0 期预算约束为：

$$c_0 + \frac{c_1}{1 + r} = a_0(1 + r) - \frac{a_2}{1 + r}$$

其次，用第 2 期的预算约束表达出 a_2 ，即 $a_2 = (c_2 + a_3)/(1 + r)$ ，将其表达式代入上一步更新的预算约束可得：

$$c_0 + \frac{c_1}{1 + r} + \frac{c_2}{(1 + r)^2} = a_0(1 + r) - \frac{a_3}{(1 + r)^2}$$

依次类推，在 T 次后，第 0 期的预算约束被更新为：

$$\sum_{t=0}^T c_t \frac{1}{(1 + r)^t} = a_0(1 + r) - \frac{a_{T+1}}{(1 + r)^T}$$

取极限得到：

$$\sum_{t=0}^{\infty} c_t \frac{1}{(1+r)^t} = a_0(1+r) - \lim_{T \rightarrow \infty} \frac{a_{T+1}}{(1+r)^T} \leq a_0(1+r) \quad (1.2)$$

其中不等号是根据非庞氏条件而来。式 (1.2) 就是无限期情形下的终身预算约束。

无限期情形下的非庞氏博弈条件是由有限期情形下的终端条件 $a_{T+1} \geq 0$ 扩展而来的。更一般化的，宏观经济学家提出了**自然债务限制**（Natural Debt Limit）的概念，它是保证个体还款的最弱条件（即设置未来消费全部为 0 时，能够偿还的数额的现值），它同时适用于有限期和无限期。在上面特定的例子中，自然债务限制时刻为 0。不过一般来说，它依赖于未来的非资产收入流，我们在第4章中将会看到。

更进一步看，只要效用函数严格递增， $\lim_{T \rightarrow \infty} a_{T+1}/(1+r)^T$ 就不可能为正数：因为资产本身不会带来效用，只要其为正，最优的选择就是将其消费完，即：

$$\lim_{T \rightarrow \infty} \frac{a_{T+1}}{(1+r)^T} \leq 0 \quad (1.3)$$

式 (1.3) 被称为**横截性条件**（Transversality Condition, TCV），它保证了选择的最优性。又由于非庞氏条件式 (1.1) 表明 $\lim_{T \rightarrow \infty} a_{T+1}/(1+r)^T \geq 0$ ，因此有：

$$\lim_{T \rightarrow \infty} \frac{a_{T+1}}{(1+r)^T} = 0 \quad (1.4)$$

也就是说，只要效用函数严格递增，终身预算约束式 (1.2) 就会取等号，即消费完所有资源：

$$\sum_{t=0}^{\infty} c_t \frac{1}{(1+r)^t} = a_0(1+r) \quad (1.5)$$

换句话说，预算约束取等就是由式 (1.2)（由非庞氏条件式 (1.1) 而来）和横截性条件式 (1.3) 组合得到的。

需要注意：非庞氏条件和 TVC 在本质上是不同的：前者是对个体消费路径的限制，保证解的存在性；后者则是个体自我施加的条件（Self-imposed Condition），或者说是保证最优性的条件。在有限期情形下，个体终期选择不进行储蓄是直观的；但在无限期情形下，没有这样的终期条件来帮助我们确定解序列，因此符合一阶条件的差分方程可能有无穷多解。为了确定一组解，我们施加 **TVC** 这一额外的最优性条件。

下面将给出一个充分性的性质，这一性质表明：对凸优化问题（目标函数凹，可行集凸），若某一序列满足库恩塔克一阶条件和 TVC，那么这一序列达到了优化问题的最大值。

性质 1.2 考虑一般化形式的动态优化问题式 (P2):

$$\begin{aligned} \max_{\{y_t, x_{t+1}\}_{t=0}^T} \quad & \sum_{t=0}^T \beta^t \hat{\mathcal{F}}(y_t) \\ \text{s.t.} \quad & x_{t+1} = h(x_t, y_t) \\ & x_{t+1} \in \Gamma(x_t). \end{aligned}$$

用 $x_{t+1} = h(x_t, y_t)$ 替换目标中的 y_t , 从而最大化目标可以写为:

$$\max_{\{x_{t+1} \in \Gamma(x_t)\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t \mathcal{F}(x_t, x_{t+1})$$

若对所有 t , $x_{t+1}^* \in \text{int } \Gamma(x_t)$ 满足如下条件:

- **欧拉方程:** $\mathcal{F}_2(x_t^*, x_{t+1}^*) + \beta \mathcal{F}_1(x_{t+1}^*, x_{t+2}^*) = 0, \forall t$
- **TVC:** $\lim_{t \rightarrow \infty} \beta^t \mathcal{F}_1(x_t^*, x_{t+1}^*) x_t^* = 0$

并且 $\mathcal{F}(x_t, x_{t+1})$ 关于 (x_t, x_{t+1}) 联合凹, 关于第一个变量递增, 可行集 $\Gamma(x)$ 对所有 x 是凸集, 那么 $\{x_{t+1}^*\}$ 使得目标函数最大化。

证明. 考虑另一个可行的内点序列 $\mathbf{x} \equiv \{x_{t+1}\}_{t=0}^{\infty}$, 即序列中所有元素都是可行集 $\Gamma(x_t)$ 的内点, 往证对任意这样的序列, 成立:

$$\lim_{T \rightarrow \infty} \sum_{t=0}^T \beta^t [\mathcal{F}(x_t^*, x_{t+1}^*) - \mathcal{F}(x_t, x_{t+1})] \geq 0$$

定义:

$$A_T(\mathbf{x}) \equiv \sum_{t=0}^T \beta^t [\mathcal{F}(x_t^*, x_{t+1}^*) - \mathcal{F}(x_t, x_{t+1})]$$

我们只需证明, 当 T 趋向于无穷, $A_T(\mathbf{x})$ 的下界由 0 保证。

由于目标 $\mathcal{F}$ 是凹的, 因此:

$$A_T(\mathbf{x}) \geq \sum_{t=0}^T \beta^t [\mathcal{F}_1(x_t^*, x_{t+1}^*)(x_t^* - x_t) + \mathcal{F}_2(x_t^*, x_{t+1}^*)(x_{t+1}^* - x_{t+1})]$$

注意到对任意 t , x_{t+1} 在求和中出现了两次, 上式可整理为:

$$\begin{aligned} A_T(\mathbf{x}) \geq & \sum_{t=0}^{T-1} \beta^t \left\{ (x_{t+1}^* - x_{t+1}) [\mathcal{F}_2(x_t^*, x_{t+1}^*) + \beta \mathcal{F}_1(x_{t+1}^*, x_{t+2}^*)] \right\} \\ & + \mathcal{F}_1(x_0^*, x_1^*) (x_0^* - x_0) + \beta^T \mathcal{F}_2(x_T^*, x_{T+1}^*) (x_{T+1}^* - x_{T+1}) \end{aligned}$$

又由一阶条件 (欧拉方程):

$$\mathcal{F}_2(x_t^*, x_{t+1}^*) + \beta \mathcal{F}_1(x_{t+1}^*, x_{t+2}^*) = 0$$

以及 $x_0^* - x_0 = 0$ (因为 x_0 是给定的), 从而化简可得:

$$A_T(\mathbf{x}) \geq \beta^T \mathcal{F}_2(x_T^*, x_{T+1}^*) (x_{T+1}^* - x_{T+1})$$

此外, 根据 $\mathcal{F}_2(x_T^*, x_{T+1}^*) = -\beta \mathcal{F}_1(x_{T+1}^*, x_{T+2}^*)$:

$$A_T(\mathbf{x}) \geq \beta^{T+1} \mathcal{F}_1(x_{T+1}^*, x_{T+2}^*) (x_{T+1} - x_{T+1}^*) \geq -\beta^{T+1} \mathcal{F}_1(x_{T+1}^*, x_{T+2}^*) x_{T+1}^*$$

对此前 T 有限的情形, 终期的最优选择显然为 $x_{T+1}^* = 0$, 即不再储蓄 (或积累资本); 而当 T 趋于无穷, 根据 TVC, 最后一个不等式右侧趋于 0。也就是说, 新的可行路径 $\mathbf{x} \equiv \{x_{t+1}\}_{t=0}^{\infty}$ 比 $\{x_{t+1}^*\}$ 下获得的效用低。□

1.1.6 无限期情形下的消费-储蓄模型

我们之前利用拉格朗日函数和库恩塔克条件得到了有限期 (两期) 消费储蓄模型的解; 在此基础上引出了动态优化问题的一般化形式, 并分别讨论了有限期和无限期情形下动态优化问题最优解的相关条件。在本节, 我们将利用相应结论, 完整求解无限期的消费-储蓄模型。

假设对数效用函数 $u(c) = \log c$, 个体优化问题为:³

$$\begin{aligned} \max_{\{c_t, a_{t+1}\}_{t=0}^{\infty}} & \sum_{t=0}^{\infty} \beta^t \log c_t \\ \text{s.t.} & c_t + a_{t+1} = a_t(1+r), \forall t \geq 0 \\ & \text{non-ponzi-game condition.} \end{aligned}$$

这里, 预算约束取等号已经蕴含了 TVC 条件 (在无穷远处拥有现值为正的储蓄不是最

³为了得到显示解方面理解, 我们进行了部分改动, 省去了外省禀赋流。

优的)。与例 1.3 一致, 我们将预算约束序列写为终身预算约束:

$$\sum_{t=0}^{\infty} c_t \left(\frac{1}{1+r} \right)^t = a_0(1+r)$$

利用拉格朗日函数容易得到一阶条件为:

$$\beta^t \frac{1}{c_t} = \lambda \left(\frac{1}{1+r} \right)^t, \quad \forall t \geq 0$$

其中 λ 是与终身预算约束对应的拉格朗日乘子。令 $t = 0$, 从而 $\lambda = 1/c_0$, 因此:

$$c_t = [\beta(1+r)]^t c_0, \quad \forall t \geq 1$$

将上式代入终身预算约束可得:

$$\begin{aligned} \sum_{t=0}^{\infty} \beta^t (1+r)^t \frac{1}{(1+r)^t} c_0 &= a_0(1+r) \\ c_0 \sum_{t=0}^{\infty} \beta^t &= a_0(1+r) \end{aligned}$$

从而我们解得了:

$$c_0 = a_0(1-\beta)(1+r)$$

后续消费序列均可由 $c_t = [\beta(1+r)]^t c_0$ 得到。

1.2 新古典增长理论基础

接下来, 我们将通过另一个重要模型来深入对序列视角下动态优化问题的认知, 这就是新古典增长模型。新古典理论是在 Solow 等人的工作之上建立起来的。在当时, 美国长期稳定的资本产出比引起了许多经济学家的关注。早期增长理论如哈罗德-多马模型将这一特征直接作为模型的前提假设: 资本与劳动必须按固定比例结合(互补)才能进行生产。但是索罗发现, 资本和劳动明显是可替代的, 传统理论不能解释现实问题: 数据上看, 劳动的价格(工资)趋势性上升, 在生产要素互补的情形下, 资本租金率也应当上升, 这与观察到的稳定的资本租金率不符。

索洛认为, 这些现象可以由**新古典**视角加以解释。如果一个生产函数关于其投入要素是**边际报酬递减的**, 我们通常称其具有**新古典特征**。在这一生产函数下, 当人均资本提高, 资本的边际产出会降低, 在竞争市场上这会反应为要素价格的变化。而如果同时存在

劳动增进的技术进步，就可以解释特征事实中要素数量和价格的相关特征。由此，一个将新古典特征和技术进步相结合的理论诞生了。Solow (1956) 和 Swan (1956) 在 Ramsey (1928)、哈罗德-多马模型等理论的基础上，建立了 Solow-Swan 模型，奠定了新古典增长理论 (Neoclassical Growth) 和现代宏观经济学的基础。

在本节我们将重点介绍新古典增长模型的起源——索洛模型，并引出相关宏观经济学的概念。我们将在下一节重点研究新古典增长模型（最优增长模型）的序列化解法。

1.2.1 索洛模型

索洛模型的核心要素是**总量生产函数** (Aggregate Production Function)，通常由总资本 K_t ，总劳动投入 L_t （人口乘人均工作时间）和技术 A_t 构成。我们从最简单的情形开始来介绍相关概念。在这一模型中，没有技术进步或人口和工人技能特征，从而总量生产函数为：

$$Y_t = F(K_t, L_t)$$

其中 Y_t 可以理解为经济的 GDP。对于函数 $F(K, L)$ ，有如下假设：

假设 1.4 $F(K, L)$ 关于 k 和 L 严格递增

假设 1.5 $F(K, L)$ 关于 (K, L) 严格拟凹

假设 1.6 $F(K, L)$ 关于 (K, L) 规模报酬不变

假设 1.7 $F(0, L) = 0$

假设 1.8 Inada 条件： $\lim_{K \rightarrow 0} F_1(K, L) = \infty$, $\lim_{K \rightarrow \infty} F_1(K, L) = 0$

在基准模型中，假设人口总数 N_t 和人均工作时间 l_t 为常数，因此 L_t 为常数。将人口总数和人均工时正则化为 1，从而生产函数中剩下的变量只有 K_t ，结合规模报酬不变，可以写出人均形式：

$$F(K_t, 1) = F(k_t, 1) \equiv f(k_t)$$

我们以小写字母表示人均测度，生产函数可以表示为：

$$y_t = f(k_t) \tag{1.6}$$

索洛模型的另一个核心构成是**资本运动方程**：

$$k_{t+1} = i_t + (1 - \delta)k_t \tag{1.7}$$

其中 i_t 表示 t 期的（人均）投资， δk_t 表示既有资本的折旧， $\delta \in (0, 1)$ 表示折旧率。索

洛模型隐性地假定了产品的同质性，可被用于消费或投资，根据供给等于需求：

$$y_t = c_t + i_t \quad (1.8)$$

在索洛模型中，并没有对消费者的消费-储蓄问题建模，而是假设外生储蓄率 $s \in (0, 1)$ 。由于 y_t 不仅是产品供给，同时也是消费者的总收入，即它不是被用于消费就是被用于储蓄。因此总投资等于总储蓄：

$$i_t = sy_t \quad (1.9)$$

从而我们可以得到资本运动方程的差分形式：

$$k_{t+1} = (1 - \delta)k_t + sf(k_t) \quad (1.10)$$

这是索洛模型的核心方程：右侧唯一的内生变量是资本存量 k_t ，下期的内生资本水平仅由当期资本水平决定。注意到，对于外生给定的 k_0 ，我们可以由上式得到资本序列 $\{k_{t+1}\}_{t=0}^{\infty}$ ，进而同时也能得到人均产出、消费和投资（储蓄）。

1.2.2 稳态与动态

对式 (1.10)，考虑 k_t 不随时间变化这一特殊情形，我们称其为**稳态**，记为 $k_t = \bar{k}$, $\forall t$ 。它是如下方程的解：

$$\bar{k} = (1 - \delta)\bar{k} + sf(\bar{k})$$

这表明在稳态时， $\delta\bar{k} = sf(\bar{k})$ 。方程左侧是一条通过原点的直线；方程右侧是通过原点、严格递增并且严格凹的曲线，它在 0 处斜率趋近无穷， $\bar{k} \rightarrow \infty$ 时斜率趋近 0。这样的 **Inada 条件**保证了严格正的解 $\bar{k}$ 存在且唯一。不难看出，Inada 条件是一个充分条件，它可以减弱为： $\lim_{k \rightarrow 0} F_1(k, 1) > \delta/s$ 和 $\lim_{k \rightarrow \infty} F_1(k, 1) < \delta/s$ 。同时，在稳态下， k_t/y_t 为常数，这与特征事实相符。假设柯布-道格拉斯生产函数的话，稳态时资本产出比为：

$$\frac{\bar{k}}{\bar{y}} = \frac{s}{\delta}$$

接下来，我们利用**相图**（Diagram）分析当初始 $k_0 > 0$ 不处于稳态值时， k_t 的**动态**。图 1.1 绘制了资本运动方程式 (1.10) 和 45 度线，其中横轴是当期资本，纵轴是下期资本，因此 45 度线代表资本处于稳态。给定横轴上一个初始 k_0 ，由式 (1.10) 可以在纵轴上得到下期的 k_1 ；再将 k_1 做为新的初始状态，利用式 (1.10) 在纵轴上得到 k_2 ，依次进行下去，可以得到资本序列 $\{k_{t+1}\}_{t=0}^{\infty}$ 。显然，只要初始 $k_0 > 0$ ，无论从何处开始，系统最终都会收敛至稳态 $\bar{k}$ 。更严谨的论证如下：假设 $k_t < \bar{k}$ ，从而有 $sf(k_t) > \delta k_t$ ，进而 $k_{t+1} > k_t$ 。




图 1.1: 索洛模型的动态

同时，由于 $k_t < \bar{k}$ ，因此 $k_{t+1} = (1 - \delta)k_t + sf(k_t) < (1 - \delta)\bar{k} + sf(\bar{k}) = \bar{k}$ 。重复上述程序，可以得到一个单调有界序列 $\{k_t, k_{t+1}, k_{t+1}, \dots\}$ ，其界为 $[k_t, \bar{k}]$ 。由单调收敛定理可知这一序列存在极限，并且根据给定的条件，极限唯一，因此必为 $\bar{k}$ 。同理可证 $k_t > \bar{k}$ 的情形。

直觉上讲，收敛的原因在于生产函数关于资本的边际报酬递减（假设 1.5）。根据资本运动方程：

$$k_{t+1} - k_t = i_t - \delta k_t$$

有两种相反力量影响资本的运动：总投资和折旧。给定外生储蓄率，当资本存量较低时，单位资本的产出较高， $i_t = sf(k_t)$ 相对于折旧的资本更高，从而资本存量逐渐提高。但在这一过程中，由于资本边际报酬递减，单位资本的产出逐渐降低，当 k_t 足够大时，对应资本存量下的总投资不再能覆盖折旧，资本存量最终达到稳态。进一步将资本运动方程变换为增长率形式：

$$\frac{k_{t+1} - k_t}{k_t} = \frac{sf(k_t)}{k_t} - \delta$$

根据 $f''(k_t) < 0$ 和 $f(0) = 0$ 的假设， $f(k_t)/k_t$ 关于 k_t 递减，这带来了投资对于资本存量的推动和折旧随资本存量水平提高而增加这两种相反力量。

1.2.3 技术进步与平衡增长路径

在基础模型中，我们省去了技术进步 A_t 和劳动投入 L_t ，经济在长期达到恒定稳态。在本节，我们引入两个新的特征：一是允许劳动投入 L_t （人口乘人均工时）随时间增长；二是引入技术进步 A_t 。从而生产函数形式为：

$$Y_t = F(K_t, A_t L_t)$$

也就是说，技术进步表现为劳动投入的改善。 $A_t L_t$ 通常被称为**有效劳动**（Efficiency Labor）；这一形式的技术进步被称为**劳动增广型**或**哈罗德中性**（Harrod-Neutral）。⁴ 假设技术 A_t 的进步率为 γ ，劳动投入 L_t 的增长率为 n 。⁵ 总量形式的资本运动方程为：

$$K_{t+1} = (1 - \delta)K_t + sF(K_t, A_t L_t)$$

由于技术进步的存在，显然是不存在上面所看到的严格意义的稳态的。不过，通过正则化相关变量，我们能够将其转化为**平稳的变量**。两边同时除以有效劳动 $A_t L_t$ ：

$$\frac{K_{t+1}}{A_t L_t} = (1 - \delta) \frac{K_t}{A_t L_t} + s \frac{F(K_t, A_t L_t)}{A_t L_t}$$

通常称这一正则化后的变量为**有效人均劳动**，记为：

$$\tilde{k}_t \equiv \frac{K_t}{A_t L_t}$$

从而资本运动方程可以改写为**有效人均形式**：

$$\frac{A_{t+1}}{A_t} \frac{L_{t+1}}{L_t} \frac{K_{t+1}}{A_{t+1} L_{t+1}} = (1 - \delta) \frac{K_t}{A_t L_t} + sF\left(\frac{K_t}{A_t L_t}, 1\right)$$

即：

$$(1 + \gamma)(1 + n)\tilde{k}_{t+1} = (1 - \delta)\tilde{k}_t + sf(\tilde{k}_t) \quad (1.11)$$

其中， $f(\tilde{k}_t) \equiv F(\tilde{k}_t, 1)$ 。对正则化后的资本和上述运动方程，可以得到稳定的稳态值，进而可以再将其转化为宏观变量。

事实上，对应于基准模型下的稳态，我们使用**平衡增长路径**（Balanced Growth Path）

⁴事实上，劳动增广型技术进步是唯一与平衡增长相合的技术进步形式（即所有总量变量以相同速率增长）。

⁵ n 可能有两个来源：一是人口的变化；二是人均工时的变化。

来刻画这类带有增长特征模型的长期行为。⁶ 在平衡增长路径下, $\tilde{k}_t$ 是常数, 宏观变量如 Y_t , K_t , C_t 以相同的常速率增长。将平衡增长路径下的有效人均资本记为: $\tilde{k}_{t+1} = \tilde{k}_t = \bar{k}$, 它是如下方程的解:

$$(1 + \gamma)(1 + n)\bar{k} = (1 - \delta)\bar{k} + sf(\bar{k})$$

对于转换后的平稳变量, 其动态特征与基准模型相近: 从任意 $\tilde{k}_0$ 开始, $\{\tilde{k}_{t+1}\}_{t=0}^{\infty}$ 单调收敛到 $\bar{k}$ 。

进一步分析哈罗德中性模型中经济变量的特征。假设所有劳动力都工作 1 单位, 即 L_t 只表示总人口, 人均产出定义为 $y_t \equiv Y_t/L_t$ 。由于在长期 $Y_t/(A_t L_t) = f(\tilde{k}_t)$ 收敛到 $f(\bar{k})$, 因此人均资本收敛到:

$$y_t = f(\bar{k})A_t$$

在长期, 人均产出的增长率为:

$$\frac{y_{t+1} - y_t}{y_t} = \frac{f(\bar{k})A_{t+1} - f(\bar{k})A_t}{f(\bar{k})A_t} = \frac{A_{t+1} - A_t}{A_t} = \gamma$$

也就是说, 在平衡增长路径上, 人均产出以 γ 的速率增长, 其余参数如储蓄率 s 不会影响长期速率。

需要注意的是, 上述结果并不是说外生储蓄率对经济没有影响: 它会影响人均产出的水平值。同时, 当经济尚未收敛到平衡增长路径时, 外生储蓄率的水平也会影响经济短期的增长率, 因为经济会对短期内 $\tilde{k}_t$ 的变动作出反应:

$$\frac{y_{t+1} - y_t}{y_t} = \frac{f(\tilde{k}_{t+1})A_{t+1} - f(\tilde{k}_t)A_t}{f(\tilde{k}_t)A_t} = \frac{f(\tilde{k}_{t+1})}{f(\tilde{k}_t)}(1 + \gamma) - 1$$

根据有效人均形势下的资本运动方程式 (1.11): 当 $\tilde{k}_t < \bar{k}_t$, $\tilde{k}_t$ 随时间增长, 即 $\tilde{k}_{t+1} > \tilde{k}_t$ 。此时 $f(\tilde{k}_{t+1})/f(\tilde{k}_t) > 1$, 短期内人均产出增长率高于 γ 。同理, 当 $\tilde{k}_t > \bar{k}_t$, 短期内人均产出增长率小于 γ 。

1.2.4 特征事实: 数据与模型

回顾索洛模型的动机之一: 解释资本产出比的长期稳定性。在长期平衡增长路径下, $Y_t/(A_t L_t) = f(\tilde{k}_t)$ 和 $K_t/(A_t L_t) = \tilde{k}_t$ 都是常数, 从而 $K_t/Y_t = \tilde{k}_t f(\tilde{k}_t)$ 也是常数。因此索洛模型可以解释稳定的资本产出比这一特征事实。同时, 在平衡增长路径下, 人均产出增速稳定为 γ , 这也与特征事实相匹配。

⁶部分学者仍使用稳态来表示平衡增长路径, 因为正则化后的变量具有严格稳定的稳态值。

另外一层特征事实是要素价格方面的：物质资本回报率几乎稳定。我们首先需要在模型中对其进行计算。假设厂商在竞争市场上最大化其利润：

$$\max_{K_t, A_t L_t} F(K_t, A_t L_t) - r_t K_t - w_t A_t L_t \quad (1.12)$$

简单起见，假设消费者拥有资本并将其出售给厂商，即 r_t 代表资本回报率。根据一阶条件：资本回报率等于资本的边际产出，即：

$$r_t = F_1(K_t, A_t L_t)$$

对 $f(K_t/A_t L_t) \equiv F(K_t, A_t L_t)/(A_t L_t)$ 两侧同时对 K_t 微分可知： $\frac{f'(\tilde{k}_t)}{A_t L_t} = \frac{F_1(K_t, A_t L_t)}{A_t L_t}$ ，从而成立：

$$r_t = f'(\tilde{k}_t)$$

在长期平衡增长路径下， $\tilde{k}_t$ 为常数， $f'(\tilde{k}_t)$ 为常数， r_t 也为常数，与特征事实相符。

此外，当时美国经济的另一特征事实在于劳动和资本份额的稳定性。在模型中，资本份额可以表示为 $r_t K_t / Y_t$ ，由于我们已经证明了 K_t / Y_t 和 r_t 在长期平衡增长路径下都是稳定的，因此模型中资本份额的长期特征也能与特征事实相匹配。对于劳动份额，在模型中可以表示为 $w_t A_t L_t / Y_t$ 。由厂商问题的一阶条件：

$$w_t = F_2(K_t, A_t L_t)$$

同时，对于规模报酬不变的生产函数，它是一次齐次的，即：

$$qF(K_t, A_t L_t) = F(qK_t, qA_t L_t)$$

两边同时对 q 微分：

$$F(K_t, A_t L_t) = K_t F_1(qK_t, qA_t L_t) + A_t L_t F_2(qK_t, qA_t L_t)$$

由于上式恒成立，因此在 $q = 1$ 处有：

$$Y_t = F(K_t, A_t L_t) = K_t F_1(K_t, A_t L_t) + A_t L_t F_2(K_t, A_t L_t)$$

结合劳动的一阶条件，并将两边同时除以 Y_t ，可知劳动份额等于 1 减去资本份额：

$$w_t A_t L_t / Y_t = 1 - r_t K_t / Y_t$$

实际上，与证明资本份额类似，通过直接计算的方式也可以得到模型中劳动份额的特征。对 $f(K_t/A_t L_t) \equiv F(K_t, A_t L_t)/(A_t L_t)$ 两侧同时对 $A_t L_t$ 微分可知：

$$-\frac{f'(\tilde{k}_t)K_t}{(A_t L_t)^2} = \frac{F_2(K_t, A_t L_t)A_t L_t - F(K_t, A_t L_t)}{(A_t L_t)^2}$$

结合一阶条件可得：

$$w_t = f(\tilde{k}_t) - \tilde{k}_t f'(\tilde{k}_t)$$

在平衡增长路径下 $\tilde{k}_t = \bar{k}$ ，工资为常数，从而资本份额 $w_t A_t L_t / Y_t = w_t / f(\tilde{k}_t)$ 为常数，与特征事实相符。特别的，对柯布-道格拉斯生产函数 $Y_t = K_t^\alpha (A_t L_t)^{1-\alpha}$ ，即使在平衡增长路径外，资本和劳动份额始终恒定为 α 和 $1 - \alpha$ 。

1.2.5 收敛性分析

我们已经看到，在索洛模型中，经济会单调收敛至稳态或平衡增长路径。在本小节，我们对收敛性进行一些更详细的说明。回忆最简单的基准情形，我们将劳动投入 L_t 正则化为 1，以人均形式描述经济过程。由一阶泰勒展开，资本运动方程式 (1.10) 在稳态附近可以进行如下估计：

$$\Delta k_{t+1} = (1 - \delta + s f'(\bar{k})) \Delta k_t \quad (1.13)$$

其中 Δk_t 表示 k_t 对其稳态值的偏离（当偏离很小时），即 $k_t - \bar{k}$ 。两边同除以 $\bar{k}$ 得到：

$$\frac{k_{t+1} - \bar{k}}{\bar{k}} = (1 - \lambda) \frac{k_t - \bar{k}}{\bar{k}} \quad (1.14)$$

其中， $\lambda = \delta - s f'(\bar{k})$ 表示收敛速度。 λ 越大， Δk_{t+1} 缩小（绝对值）得更快，即系统向稳态收敛速度快。如图 1.2 所给出的， λ 越大，资本运动方程在稳态附近斜率更平，更快到达稳态。假设柯布-道格拉斯生产函数，一阶展开可写为：

$$\Delta k_{t+1} = (1 - \delta(1 - \alpha)) \Delta k_t \quad (1.15)$$

收敛速度方程为：

$$\lambda = \delta(1 - \alpha) \quad (1.16)$$

因此，资本份额 α 越低、折旧率 δ 越大，则收敛速度越快。

一般而言， k_t 如何影响 k_{t+1} 决定了收敛速度。例如，若 k_t 对 k_{t+1} 无影响，那么收敛会立刻实现，即在图 1.2 反应为水平的直线。不难看出，外生储蓄率 s 在柯布-道格拉斯生产函数下不会影响收敛速度，这是两个相反力量所导致的：对给定的一个 k_t ，高的




图 1.2: 收敛速度

储蓄率 s 意味着 k_t 对 k_{t+1} 的影响更大；但更高的储蓄率也带来更高的稳态 $\bar{k}$ ，进而稳态时资本的边际产出 $f'(\bar{k})$ 低，这意味着 k_t 对 k_{t+1} 的影响更小。在 CD 生产函数下，这两种作用相互抵消。

进一步回忆带有增长特征的索洛模型：对其有效人均形式的资本运动方程式 (1.11) 在稳态附近进行一阶泰勒展开可得：

$$(1 + \gamma)(1 + n)\Delta\tilde{k}_{t+1} = \left(1 - \delta + sf'(\bar{k})\right)\Delta\tilde{k}_t \quad (1.17)$$

两边同时除以 $\tilde{k}$ ，得到收敛速度方程：

$$\frac{\tilde{k}_{t+1} - \bar{k}}{\bar{k}} = (1 - \lambda)\frac{\tilde{k}_t - \bar{k}}{\bar{k}}$$

其中收敛速度为：

$$\lambda = 1 - \frac{1 - \delta + sf'(\bar{k})}{(1 + \gamma)(1 + n)}$$

类似的，在柯布-道格拉斯生产函数下，一阶展开可写为：

$$\Delta\tilde{k}_{t+1} = \left(\alpha + \frac{(1 - \alpha)(1 - \delta)}{(1 + \gamma)(1 + n)}\right)\Delta\tilde{k}_t$$

收敛速度为：

$$\lambda = (1 - \alpha)\left(1 - \frac{1 - \delta}{(1 + \gamma)(1 + n)}\right)$$

1.2.6 应用索洛模型：增长核算

更一般化的，Solow (1957) 提出增长核算 (Growth Accounting) 的概念，用于研究不同生产要素对经济增长的作用。假设如下：

假设 1.9 总产出 Y_t 由总量生产函数 $F_t(K_t, L_t)$ 决定， F 的时间记号保留了技术进步促进生产函数向上移动的可能；

假设 1.10 F 规模报酬不变及其余新古典性质；

假设 1.11 投入要素完全竞争，即厂商最大化其利润。

微观经济学证明了，在完全竞争均衡情形下，规模报酬不变最终带来零利润，这也是索洛增长核算的起点。与前面的记号类似，以小写字母表示人均测度，假设人口总量为 N_t ，根据规模报酬不变，我们可以将人均产出表示为 $y_t = F_t(k_t, l_t)$ ，其中 $k_t \equiv K_t/N_t$ 和 $l_t \equiv L_t/N_t$ 表示人均资本和人均工作时间。假设人口总量不变，并将其正则化为 1，可以得到 $y_t = Y_t$ 。⁷ 对此处的人均产出进行全微分可得：

$$\begin{aligned} dy &= \frac{\partial F}{\partial t} dt + \frac{\partial F}{\partial k} dk + \frac{\partial F}{\partial l} dl \\ &= \frac{\partial F}{\partial t} dt + \frac{\partial F}{\partial k} k \frac{dk}{k} + \frac{\partial F}{\partial l} l \frac{dl}{l} \end{aligned} \quad (1.18)$$

其中所有的全微分都在 (t, k_t, l_t) 处取得。在此处，为了方便取导数，我们假设了时间连续，但离散情形下并没有本质区别，只是记号的差异。记 r_t, w_t 为完全竞争市场上的资本租金率和工资，厂商最大化利润问题为：

$$\max_{k, \ell} F_t(k, \ell) - rk - wl$$

根据一阶条件可得：

$$r = \partial F / \partial k \quad (1.19)$$

$$w = \partial F / \partial l \quad (1.20)$$

两边同时除以总产出可得：

$$\frac{dy}{y} = \frac{\partial F}{\partial t} \frac{dt}{y} + \frac{rk}{y} \frac{dk}{k} + \frac{wl}{y} \frac{dl}{l} \quad (1.21)$$

假设 $1 - \alpha$ 为劳动收入份额（可能时变，根据数据可计算），那么由规模报酬不变的零利

⁷在基准模型中，我们额外假设了人均工时为常数，进而将其也正则化为 1，因此基准模型是没有考虑劳动的。

润条件可知：资本份额为 α ，从而得如下**增长核算方程**：

$$\frac{dy}{y} = \frac{\partial F}{\partial t} \frac{dt}{F} + \alpha \frac{dk}{k} + (1 - \alpha) \frac{dl}{l} \quad (1.22)$$

其中， $\frac{\partial F}{\partial t} \frac{dt}{F}$ 被称为**索洛剩余**（Solow Residual），因为它是不能由资本和劳动增长核算得到的部分，但可以通过作差得到，它测度了生产可能前沿如何随时间变动。

上述形式是一般化地将时间对生产函数的影响进行表示。我们可能对以下形式更为熟悉： $F_t(k_t, l_t) \equiv A_t F(k_t, l_t)$ ，由于 F 为一次齐次，因此这一形式被称为**希克斯中性**（Hicks-Neutral）， A 被称为**全要素生产率**（Total Factor Productivity, TFP）。 $F(k_t, l_t)$ 是时间独立的函数，通过全微分可得到核算方程为：

$$\frac{dy}{y} = \frac{dA}{A} + \alpha \frac{dk}{k} + (1 - \alpha) \frac{dl}{l} \quad (1.23)$$

若生产函数形式是**哈罗德中性**： $F_t(k_t, l_t) = F(k_t, A_t l_t)$ ，此时 F 也是时间独立的，由厂商一阶条件 $\frac{\partial F}{\partial l} = w/A$ 以及 $wl = (1 - \alpha)F$ ，可类似的得到增长核算方程：

$$\frac{dy}{y} = (1 - \alpha) \frac{dA}{A} + \alpha \frac{dk}{k} + (1 - \alpha) \frac{dl}{l} \quad (1.24)$$

1.3 确定性最优增长：RCK 模型

Solow (1956) 和 Swan (1956) 的工作标志新古典增长理论的诞生。但 Solow 模型的主要问题在于，模型中储蓄率是外生给定的。Cass (1965) 和 Koopmans (1965) 在 Solow 工作的基础上，通过引入微观基础对新古典理论进行了拓展，将储蓄作为理性选择下的内生结果，建立了确定性情形下的**最优增长模型**，因此最优增长模型通常被称为 RCK 模型（Ramsey-Cass-Koopmans Model），它与另一个典型的动态优化问题——消费-储蓄模型的核心区别在于：经济是生产经济而不是禀赋经济；我们将利用这一模型，深入研究序列视角下的动态优化问题。

确定性最优增长模型形式如下：生产函数 $F(K, L)$ 与索洛模型中类似，具有新古典特征，同样假设总劳动投入被正则化为 $L = 1$ ，从而人均形式生产函数为： $y_t = f(k_t)$ 。不难证明，索洛模型对 F 的假设对 f 同样成立：

假设 1.12 f 关于 k 严格增；

假设 1.13 f 关于 k 严格拟凹；

假设 1.14 $f(0)=0$ ；

假设 1.15 生产函数 Inada 条件： $\lim_{k \rightarrow 0} f'(k) = \infty$, $\lim_{k \rightarrow \infty} f'(k) = 0$ ；

假设 1.16 方便起见额外假设： $f(k)$ 连续，二次可微。

假设时间是离散的，由 $t = 0, 1, \dots, T$ 表示， T 可取无穷，第 0 期资本存量 $k_0 > 0$ 给定。资本运动方程为：

$$k_{t+1} = (1 - \delta)k_t + i_t$$

资源约束 $c_t + i_t \leq y_t$ 可进一步写为：

$$c_t + k_{t+1} = f(k_t) + (1 - \delta)k_t$$

实际上，模型中对于资本和消费的设定形式是多样的。例如：可以假设厂商拥有并积累资本；也可以假设家庭拥有资本，进行投资决策并将其租赁给厂商。在类似的设定下，经济主体在市场上互动，价格使市场出清，通常我们称之为**分散经济**（Decentralized Economy）。我们将在第4章详细讨论。本节的重点在于分析动态优化问题，因此我们进行简化，假设经济中存在一个计划者（Social Planner）来为代表性家庭进行决策。我们将这样的设定称为**计划者问题**（Planning Problem），它与分散经济的最主要区别在于：经济中没有显示的价格变量，因为计划者可以直接调配资源。计划者面临的动态优化问题为：

$$\begin{aligned} \max_{\{c_t, k_{t+1}\}_{t=0}^T} & \sum_{t=0}^T \beta^t u(c_t) \\ \text{s.t. } & c_t + k_{t+1} \leq f(k_t) + (1 - \delta)k_t, \forall t \in \{0, \dots, T\} \\ & c_t, k_{t+1} \geq 0, \forall t \in \{0, \dots, T\} \end{aligned} \tag{P3}$$

其中关于当期效用函数 $u(\cdot)$ 有如下规范化假设：

假设 1.17 效用函数 u 连续，二次可微且 $u'(c) > 0$, $u''(c) < 0$

假设 1.18 效用函数 Inada 条件： $\lim_{c \rightarrow 0} u'(c) = \infty$, $\lim_{c \rightarrow \infty} U'(c) = 0$

这一问题的核心就是**求解最优消费和资本序列** $\{c_t, k_{t+1}\}_{t=0}^T$ 。消费者（计划者）面临的权衡是：减少今天的消费降低了当期边际效用，但是它被用于储蓄，进而投资于新的资本，带来未来更多的产出 $f'(k_t) + 1 - \delta$ 。这与消费储蓄模型的逻辑一致。此外，由于我们假设严格正的边际效用，因此资源约束必定取等号，不再详细证明。

我们可以将最优增长模型对应到此前建立的一般形式的动态优化问题上，其中：当期目标 $\hat{\mathcal{F}}(\cdot)$ 即为当期效用函数 $u(\cdot)$ ；控制变量是消费序列 $\{c_t\}_{t=0}^T$ ；状态变量是（期初）资本存量 k_t ；将状态变量与控制变量相连接的方程为 $h(k_t, c_t) = f(k_t) + (1 - \delta)k_t - c_t$ ；可行集为 $\Gamma(k_t) = [0, f(k_t) + (1 - \delta)k_t]$ ，其下界确保了 $k_{t+1} \geq 0$ ，上界确保了 $c_t \geq 0$ 。下面求解最优序列。

1.3.1 有限期情形

与消费-储蓄模型类似，我们希望利用 Lagrangian 函数和库恩塔克定理求解序列问题。对有限期情形这是容易的，正如我们已经给出的：只要目标函数是严格凹并且约束集是有界闭凸集，那么库恩塔克条件是最优解的充分必要条件。但当问题拓展到无穷期形式时，需要一些额外条件来确保问题的可解性。我们将从有限期情形开始，逐步推广至无限期的情形。

在有限期情形下，计划者问题为：

$$\begin{aligned} \max_{\{k_{t+1}\}_{t=0}^{\infty}} \quad & \sum_{t=0}^T \beta^t u(f(k_t) + (1 - \delta)k_t - k_{t+1}) \\ \text{s.t.} \quad & k_{t+1} \geq 0 \quad t \leq T \end{aligned}$$

由效用函数的 Inada 条件， $c_t \geq 0$ 必然满足；同时，关于效用函数和生产函数的假设确保了目标函数的凹性和可行集是有界闭凸集，从而存在唯一的最大值，不再证明。⁸ 上述问题的拉格朗日函数为：

$$\mathcal{L} = \sum_{t=0}^T \beta^t \{u(f(k_t) + (1 - \delta)k_t - k_{t+1}) + \mu_t k_{t+1}\}$$

其中第 t 期非负资本约束的拉格朗日（库恩塔克）乘子为 $\beta^t \mu_t$ 。两个一阶条件为：

$$\frac{\partial \mathcal{L}}{\partial k_{t+1}} : -u'(c_t) + \beta u'(c_{t+1}) [f'(k_{t+1}) + 1 - \delta] + \mu_t = 0, \quad t \in \{0, \dots, T-1\} \quad (1.25)$$

$$\frac{\partial \mathcal{L}}{\partial k_{T+1}} : -u'(c_T) + \mu_T = 0 \quad (1.26)$$

最后一期 T 的一阶条件与其余期不同是因为经济在终期 T 后结束。此外，库恩塔克条件还包括**互补松弛条件**（Complementary Slackness Condition）：

$$\begin{aligned} \mu_t k_{t+1} &= 0, t \in \{0, \dots, T\} \\ k_{t+1} &\geq 0, t \in \{0, \dots, T\} \\ \mu_t &\geq 0, t \in \{0, \dots, T\} \end{aligned} \quad (1.27)$$

由于我们假设效用函数 $u(c_t)$ 关于第一个变量递增，因此式 (1.26) 意味着 $\mu_T > 0$ 。根据

⁸证明目标函数关于 (k_t, k_{t+1}) 是联合凹的需要检查黑塞矩阵负定。

$t = T$ 时的互补松弛条件可知，终端条件为：

$$k_{T+1} = 0$$

这表明，在最后一期，计划者不会选择积累资本，而是会选择消费完所有资源。这与有限期消费-储蓄模型的逻辑是一致的；并且这一条件对理解后续无限期 RCK 模型的终端条件也有重要含义。

给定两个 Inada 条件： $\lim_{k \rightarrow 0} f'(k) = \infty$ 和 $\lim_{c \rightarrow 0} u'(c) = \infty$ ，任意 $t < T$ 时，最优选择下的 $k_{t+1} > 0$ 。因此资本非负约束不会为紧，从而 $\mu_t = 0, \forall t < T$ 。将其代入式 (1.25)，即可得到 $t \in \{0, 1, \dots, T-1\}$ 时的欧拉方程：

$$u'[f(k_t) + (1 - \delta)k_t - k_{t+1}] = \beta u'[f(k_{t+1}) + (1 - \delta)k_{t+1} - k_{t+2}] [f'(k_{t+1}) + 1 - \delta] \quad (1.28)$$

注意到，系统共有 $T + 2$ 个方程和 $T + 2$ 个未知量。其中， $T + 2$ 个方程包括 $T - 1$ 个欧拉方程和给定的初始条件 k_0 以及终端条件 $k_{T+1} = 0$ ，它们决定了资本序列 $\{k_{t+1}\}_{t=0}^T$ （即 $T + 2$ 个未知量）。由于一阶条件是充分的，因此式 (1.28) 有唯一解。事实上，我们可以把欧拉方程写成更为熟悉的形式：

$$\underbrace{u'(c_t)}_{\substack{\text{marginal cost} \\ \text{of investment}}} = \underbrace{\beta u'(c_{t+1})}_{\substack{\text{utility increase} \\ \text{per unit invested}}} \cdot \underbrace{[f'(k_{t+1}) + 1 - \delta]}_{\text{return on investment}}$$

它由三部分构成：左侧是在今天将 1 单位消费品用于投资的边际成本，导致效用损失 $u'(c_t)$ ；右侧是这一投资带来的边际收益，更多的投资在下期带来更多的产出（包括未折旧部分） $f'(k_{t+1}) + 1 - \delta$ ，使消费提高，效用增加一个折现量 $\beta u'(c_{t+1})$ 。

目前，我们得到了能够决定最优解序列的差分系统，但具体如何求解？一个常用方法是后向法（Backwards）：从终期 T 开始，利用资源约束和欧拉方程迭代向后。我们通过一个具有解析解的具体例子来看。

例 1.4 $T < \infty$ ，效用函数 $u(c) = \log c$ ，生产函数是柯布道格拉斯型 $f(k) = Ak^\alpha$ ，假设完全折旧 $\delta = 1$ 。从而 $t < T$ 时的欧拉方程为：

$$\frac{1}{Ak_t^\alpha - k_{t+1}} = \beta \frac{1}{Ak_{t+1}^\alpha - k_{t+2}} \cdot \alpha Ak_{t+1}^{\alpha-1}$$

对 $t = T - 1$ ，将 $k_{T+1} = 0$ 代入上式右侧，化简可得：

$$k_T = \frac{\alpha\beta}{1 + \alpha\beta} A k_{T-1}^\alpha$$

利用这一结果，并结合欧拉方程，可知对 $t = T - 2$ 成立：

$$k_{T-1} = \frac{\alpha\beta(1 + \alpha\beta)}{1 + \alpha\beta + (\alpha\beta)^2} A k_{T-2}^\alpha$$

依次向后代入可得：

$$k_{T-t} = \frac{\alpha\beta(1 + \alpha\beta + \dots + (\alpha\beta)^t)}{1 + \alpha\beta + \dots + (\alpha\beta)^{t+1}} A k_{T-t+1}^\alpha$$

由于 $\alpha\beta < 1$ ，根据几何级数知识，并将变量时间脚标适当变换，可得如下关系：

$$k_{t+1} = \alpha\beta \frac{1 - (\alpha\beta)^{T-t}}{1 - (\alpha\beta)^{T-t+1}} A k_t^\alpha$$

从而消费序列的关系为：

$$c_t = \frac{1 - \alpha\beta}{1 - (\alpha\beta)^{T-t+1}} A k_t^\alpha$$

1.3.2 无限期情形

本节转向无限期最优增长模型的序列化求解。回忆消费-储蓄模型，我们发现有限期情形下的最优终期选择正是终端条件 $a_{T+1} = 0$ ，建立了有限期情形下最优解的存在条件；依照这一终端条件，为了避免无限期情形下出现庞氏骗局，我们给出了非庞氏条件；最后我们找到了确保解的最优性的横截性条件。

对有限期最优增长模型，我们也已经得到终端条件为 $k_{T+1} = 0$ ，并在此基础上提出了后向解法和具体例子。在无限期情形下，只需对有限期中的解取极限并确保 TVC 成立即可。我们仍然利用上面的例子：

例 1.5 $T = \infty$ ，效用函数 $u(c) = \log c$ ，生产函数是柯布道格拉斯型 $f(k) = A k^\alpha$ ，假设完全折旧 $\delta = 1$ 。显然，在 $t = T$ 处截断的话，资本序列最优条件和解析解与之前相

同，记为 k_{t+1}^T 。取极限，可得无限期情形下的候选解 k_{t+1} ：

$$\lim_{T \rightarrow \infty} k_{t+1}^T = \lim_{T \rightarrow \infty} \alpha\beta \frac{1 - (\alpha\beta)^{T-t}}{1 - (\alpha\beta)^{T-t+1}} A k_t^\alpha$$

$$k_{t+1} = \alpha\beta A k_t^\alpha$$

下面需要检查 TVC 成立，即确保这一解是最优的。我们只需检查极限（无穷远处）即可。一方面，由于 $\alpha\beta < 1$ ，因此资本序列 $k_{t+1} = \alpha\beta A k_t^\alpha$ 必然收敛，从而消费也收敛；另一方面，回忆性质 1.2 中给出的最优序列的 TVC： $\lim_{t \rightarrow \infty} \beta^t \mathcal{F}_1(x_t^*, x_{t+1}^*) x_t^* = 0$ 。在本例中，对应 TVC 左侧为：

$$\lim_{t \rightarrow \infty} \beta^t u'(c_t) f'(k_t) k_t = \lim_{t \rightarrow \infty} \beta^t \frac{A\alpha k_t^{\alpha-1}}{A k_t^\alpha - k_{t+1}} k_t = \lim_{t \rightarrow \infty} \beta^t \frac{\alpha}{1 - \alpha\beta}$$

由于 $\beta \in (0, 1)$ ，从而 $\lim_{t \rightarrow \infty} \beta^t \alpha / (1 - \alpha\beta) = 0$ ，因此性质中要求的 TVC 条件成立，即

$$\lim_{t \rightarrow \infty} \beta^t u'(c_t) f'(k_t) k_t = 0$$

对于 RCK 模型这类较为简单的模型，我们可以利用相图分析动力系统的特征，其解系统可以表示为关于两个变量 (k_t, c_t) 的两组差分方程：

$$k_{t+1} - k_t = f(k_t) - \delta k_t - c_t$$

$$u'(c_t) = \beta u'(c_{t+1}) (f'(k_{t+1}) + 1 - \delta)$$

求解的过程就是寻找符合差分方程的 (k_t, c_t) 的路径的过程，如果不加限制，可能存在很多解。但事实上，正如我们所证明的，符合两个边界条件（给定的 k_0 和 TVC）的解是唯一的。

求解无限期模型解析解的另一个方法是**猜测定系数法**（Guess and Verify），也称待定系数法。此处给出一个带有解析解的例子。

例 1.6 待定系数法：模型环境与上一例子中相同。假设 $u(c) = \log c$ ，生产函数为柯布-道格拉斯型 $f(k) = A k^\alpha$ ，假设完全折旧 $\delta = 1$ 。在 $t = T$ 时刻截断，记此时资本为 k_{t+1}^T 。**猜测：**

$$k_{t+1} = s A k_t^\alpha$$

其中 s 是未知的待定系数。将这一猜测代入欧拉方程式 (1.28) 可得：

$$\frac{1}{A k_t^\alpha - s A k_t^\alpha} = \beta \alpha A \frac{k_{t+1}^{\alpha-1}}{A k_{t+1}^\alpha - s A k_{t+1}^\alpha}$$

代数运算后即可知 $s = \alpha\beta$ ，即：

$$k_{t+1} = \alpha\beta A k_t^\alpha$$

猜测法通常与在 T 时刻截断的方法相结合：先依据最优条件后向求解几期模型，寻找一个可能的形式，然后验证。不过，有解析解的例子在宏观模型中十分少见，因此我们在后面需要详细学习动态规划和数值方法。此外，我们还留下一个问题没有处理：RCK 模型是否像 Solow 模型那样全局收敛至某一稳态？稳态的存在是显然的。根据欧拉方程式 (1.28)，对恒定水平的消费（资本），成立：

$$1 = \beta (f'(\bar{k}) + 1 - \delta) \quad (1.29)$$

由 f 的凹性和 Inada 条件，上式存在唯一解。对于收敛性的讨论，我们将在下一章动态规划的学习中讨论。

1.3.3 RCK 模型中的平衡增长路径

在上面的基准 RCK 模型中：一方面我们简化了长期中增长的可能；另一方面假设没有随机技术冲击。在本小节我们将研究 RCK 模型下的平衡增长问题；对于随机冲击模型的讨论将在数值方法章节讨论，用于引出相关数值求解技巧。

假设经济中人口和技术分别以 n 和 γ 的速度增长，计划者最大化如下目标：

$$\sum_{t=0}^{\infty} \beta^t L_t u(c_t)$$

即计划者同时关注当代人口和未来出生的人口。其中 $c_t = C_t/L_t$ 表示人均消费。经济的资源约束为：

$$C_t = F(K_t, A_t L_t) + (1 - \delta)K_t - K_{t+1}$$

定义有效人均劳动变量： $\tilde{x}_t = X_t/(A_t L_t)$ ，从而可将预算约束写为平稳形式：

$$\tilde{c}_t = f(\tilde{k}_t) + (1 - \delta)\tilde{k}_t - (1 + \gamma)(1 + n)\tilde{k}_{t+1} \quad (1.30)$$

假设瞬时效用函数为 $u(c_t) = c_t^{1-\sigma}/(1-\sigma)$ ， $\sigma > 0$ 且 $\sigma \neq 1$ 。⁹ 正则化 $A_0 = 1$ 和 $L_0 = 1$ ，

⁹这一效用函数形式被证明是唯一与平衡增长相合的形式。

则计划者目标可写为：

$$\begin{aligned} \sum_{t=0}^{\infty} \beta^t L_t \frac{c_t^{1-\sigma}}{1-\sigma} &= \sum_{t=0}^{\infty} \beta^t (1+n)^t \frac{((1+\gamma)^t \tilde{c}_t)^{1-\sigma}}{1-\sigma} \\ &= \sum_{t=0}^{\infty} \tilde{\beta}^t \frac{\tilde{c}_t^{1-\sigma}}{1-\sigma}, \end{aligned} \quad (1.31)$$

其中定义了调整后的折现因子：

$$\tilde{\beta} \equiv \beta(1+n)(1+\gamma)^{1-\sigma} \quad (1.32)$$

不难得到如下欧拉方程：

$$(1+n)(1+\gamma)(\tilde{c}_t)^{-\sigma} = \tilde{\beta}(\tilde{c}_{t+1})^{-\sigma} \left[f'(\tilde{k}_{t+1}) + (1-\delta) \right]$$

将 $\tilde{\beta}$ 代入可得：

$$(\tilde{c}_t)^{-\sigma} = \beta(1+\gamma)^{-\sigma}(\tilde{c}_{t+1})^{-\sigma} \left[f'(\tilde{k}_{t+1}) + (1-\delta) \right]$$

这表明，计划者的最优条件并未受到人口增长和技术进步的影响。

在平衡增长路径上，所有变量以相同速率增长。对上面平稳化后的模型，通过向 $(\tilde{c}_t, \tilde{k}_{t+1})$ 施加稳态条件即可得到平衡增长路径，此时欧拉方程简化为：

$$(1+n)(1+\gamma) = \tilde{\beta} \left[f'(\tilde{k}) + 1 - \delta \right]$$

令 $n = \gamma = 0$ ，可验证与无人人口增长与技术进步模型的稳态相同。

2 递归方法与动态规划

第一章提出了处理动态优化问题的两个视角：序列视角和递归视角，并对序列化求解进行了介绍。本章从递归的视角对动态优化问题进行进一步研究。我们继续借助最优增长模型：将原始的序列问题转化为递归形式，建立贝尔曼方程，引入确定性动态规划的基本理论方法；接着，对序列问题和递归形式的关系进行研究，证明解的存在性和其他相关相应性质；最后介绍模型的线性解法并初步讲解数值解法，为后续学习奠定基础。

2.1 递归与动态规划的基本概念

对于第一章中所要求解的动态优化问题，我们的目标是寻找一个最优值序列，通常我们把这样的问题称为**序列问题**。但这一问题形式的求解存在一定不足：处理无限期情形过于复杂，将面临无穷的差分方程序列，我们希望降维。Stocky、Lucas 等人基于贝尔曼建立的动态规划理论，将序列问题转化为递归形式求解，由此建立了现代宏观的核心方法，而递归也成为绝大多数宏观模型的核心特征。

具体看：无穷序列问题可以分解为一期一期的小问题：对于 $t+1$ 期，可以在第 t 期进行选择而不用在第 0 期进行，即定义从当期到下期的映射，这一问题形式被称为**递归形式** (Recursive Formulation)。序列问题求解后，我们得到了无穷个数值 (Number)；对于递归问题，我们求解所得的是一个方程 (Function)，其本质是一个泛函问题。利用泛函方程 (Function Equation) 对动态优化问题进行研究就是**动态规划** (Dynamic Programming)，这一概念最早由 Richard E. Bellman 提出。在本节，我们将建立一般化形式的递归问题，进而对动态规划中的基本概念进行初步介绍。

2.1.1 由序列问题转向递归形式

回忆第1章建立的一般化形式的动态优化问题式 (P2)：

$$\begin{aligned} \max_{\{y_t, x_{t+1}\}_{t=0}^T} & \sum_{t=0}^T \beta^t \hat{F}(y_t) \\ \text{s.t. } & x_{t+1} = h(x_t, y_t) \\ & x_{t+1} \in \Gamma(x_t). \end{aligned}$$

利用 $x_{t+1} = h(x_t, y_t)$, 可将控制变量 y_t 表示为 $y_t = \hat{h}(x_t, x_{t+1})$, 将其替换到目标函数中, 记 $\mathcal{F}(x_t, x_{t+1}) \equiv \hat{\mathcal{F}}(\hat{h}(x_t, x_{t+1}))$, 从而无穷期序列问题可写为:

$$\max_{\{x_{t+1} \in \Gamma(x_t)\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t \mathcal{F}(x_t, x_{t+1})$$

在序列问题形式下, 我们在初始时刻选择 x_{t+1} 的全部路径; 而递归问题和动态规划的核心想法是: 动态决策不是一次全部做出的, 而是一期一期进行的, 即 x_{t+1} 的值不是在第 0 期而是在第 t 期决定的。为了使这一想法更清晰, 我们将最优化的序列问题记为:

$$v(x_0) \equiv \max_{\{x_{t+1} \in \Gamma(x_t)\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t \mathcal{F}(x_t, x_{t+1}) \quad (2.1)$$

给定 x_t , $\Gamma(x_t)$ 是 x_{t+1} 的可行集。在这一表达式中, 我们称 $V(x_0)$ 为**值函数** (Value Function), 它代表给定起初条件 x_0 , 取最优处时目标函数的值。我们可以将这一高维问题化简降维:

$$\begin{aligned} v(x_0) &= \max_{\{x_{t+1} \in \Gamma(x_t)\}_{t=0}^{\infty}} \left\{ \mathcal{F}(x_0, x_1) + \beta \sum_{t=1}^{\infty} \beta^{t-1} \mathcal{F}(x_t, x_{t+1}) \right\} \\ &= \max_{x_1 \in \Gamma(x_0)} \left\{ \mathcal{F}(x_0, x_1) + \beta \left[\max_{\{x_{t+1} \in \Gamma(x_t)\}_{t=1}^{\infty}} \sum_{t=1}^{\infty} \beta^{t-1} \mathcal{F}(x_t, x_{t+1}) \right] \right\} \\ &= \max_{x_1 \in \Gamma(x_0)} \left\{ \mathcal{F}(x_0, x_1) + \beta \underbrace{\left[\max_{\{x_{t+2} \in \Gamma(x_{t+1})\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t \mathcal{F}(x_{t+1}, x_{t+2}) \right]}_{\equiv v(x_1)} \right\} \end{aligned} \quad (2.2)$$

其中利用了 $\max_{x,y} f(x,y) = \max_y \{\max_x f(x,y)\}$ 。注意到, 最后一行等式的中括号中最大化问题的结构和式 (2.1) 完全相同, 唯一不同的是初始条件变为了 x_1 。换句话说, 它代表给定初始条件为 x_1 时, 决策者选择最优序列 x_{t+1} 下目标函数的值。由于时间是无穷的, 并且当期目标函数和可行集 Γ 都不随时间改变, 因此中括号中的表达式正是 $V(x_1)$, 进而我们得到:

$$v(x_0) = \max_{\{x_1 \in \Gamma(x_0)\}} \{ \mathcal{F}(x_0, x_1) + \beta v(x_1) \}$$

一个自然的问题是: 序列问题和递归问题的两种表达形式等价吗? 答案是, 只要问题是**平稳的** (Stationary), 等价性就存在。直观上讲, 但只要第 t 期的问题和 $t+1$ 期的问题结构相同, 动态优化问题就是平稳的, 或者说, 决策者所有决策相关的信息都与时间无关。因此, 平稳性实际包括另一层含义: **值函数不依赖于时间**。实际上, 并非所有问题都是平稳的, 例如在有限期的最优增长模型中, 计划者选择资本时会关注剩余的时

间。随着终期接近，决策问题也随之变化。此时，问题虽然仍可表征为递归形式，但值函数会依赖于时间，即 v_t 。而在无限期情形下，任意时刻后剩余的时间都是相同的。虽然决策会随值函数自变量的不同而改变，但不会受作出这一决策的时刻的影响，在任意时刻与决策唯一相关的就是当期的资本水平。

2.1.2 状态变量、贝尔曼方程与决策规则

一般，我们称对决策者而言前定的（Predetermined）、回报相关度（Payoff-Relevant）的信息为**状态变量**（State Variable）。例如最优增长模型中的当期资本存量 k_t 、一般化形式问题中的 x_t 。当我们把序列问题转化为递归问题时，选择合适的状态变量来确保转化后的问题确实具有递归形式是十分重要的。当问题是平稳的，决策的形式也是平稳的：

$$x_{t+1} = g(x_t)$$

即决定未来资本如何依赖于当期状态的函数不依赖于时间。我们称函数 $g(\cdot)$ 为**决策规则**（Decision Rule）或**策略函数**（Policy Function）。

对任意给定的初始条件 x_t ，我们可以将递归问题写为：

$$v(x_t) = \max_{x_{t+1} \in \Gamma(x_t)} \{ \mathcal{F}(x_t, x_{t+1}) + \beta v(x_{t+1}) \}$$

这一问题形式被称为**动态规划**（Dynamic Programming）。不难看出，对平稳的无限期问题，时间记号并不重要，以记号 x 表示状态变量的当期值，以记号 x' 表示下期值，从而动态规划问题可以写为：¹

$$v(x) = \max_{x' \in \Gamma(x)} \{ \mathcal{F}(x, x') + \beta v(x') \} \quad (2.3)$$

这一方程就是**贝尔曼方程**（Bellman Equation）。注意到，方程左右两侧都包含值函数 $v(\cdot)$ ，但是我们并不知道其具体形式，即方程的未知量是函数 $v(\cdot)$ ：对任意 x ， $v(\cdot)$ 都需满足式 (2.3)。因此，贝尔曼方程本质是一个**泛函方程**（Functional Equation）。记函数 $g(\cdot)$ 使贝尔曼方程取最大化，即：

$$g(x) = \operatorname{argmax}_{x' \in \Gamma(x)} \{ \mathcal{F}(x, x') + \beta v(x') \}$$

因此对所有 x ，下期 x' 的决策规则为： $x' = g(x)$ 。需要注意，在当前记号下，我们实际

¹我们也可以将贝尔曼方程形式写为如下形式 $v(x) = \max_{y \in \Gamma(x)} \{ \mathcal{F}(x, y) + \beta v(y) \}$ ，只是记号差异，分析并没有本质不同。因为一旦确定了 y_t ，就相当于确定了 x_{t+1} 。我们在后面将频繁看到这一记号的使用。

假定了最大值存在并且唯一。否则， g 可能不存在或者说不是一个函数而是对应（Correspondence）。

2.1.3 欧拉泛函

在序列问题下，通过求解一阶条件得到的欧拉方程是刻画解特征的关键。自然的，我们希望通过求解贝尔曼方程求解一阶条件来寻找决策规则的特征。但是一个核心问题在于：我们并不知道 v 的形式，进而也不知道 v' 的形式，求解得到一阶条件难以发挥作用。具体看，对如下贝尔曼方程：

$$v(x) = \max_{x' \in \Gamma(x)} \{ \mathcal{F}(x, x') + \beta v(x') \}$$

若假设值函数 $v(\cdot)$ 已知，那么贝尔曼方程就被简化为一个两期优化问题：

$$\max_{x' \in \Gamma(x)} \{ \mathcal{F}(x, x') + \beta v(x') \}$$

对 x' 求导可得一阶条件：

$$\mathcal{F}_2(x, x') + \beta v'(x') = 0 \quad (2.4)$$

也就是说，内点解必须满足上式。假设存在决策规则 $g(x)$ 是内点解，因此有：

$$\mathcal{F}_2(x, g(x)) + \beta v'(g(x)) = 0 \quad (2.5)$$

但是，在对 v 或 v' 有更多了解前，我们无法做更多分析。幸运的是，利用**包络定理**可以解决这一问题。

注意到，根据决策规则的定义，在最优处时（ $x' = g(x)$ ）最大化算子消失，下式对所有 x 恒成立：

$$v(x) = \mathcal{F}(x, g(x)) + \beta v(g(x)) \quad (2.6)$$

对其两侧同时关于 x 全微分得到：

$$v'(x) = \mathcal{F}_1(x, g(x)) + \underbrace{g'(x) [\mathcal{F}_2(x, g(x)) + \beta v'(g(x))]}_{\text{间接效应}}$$

策略函数导数的出现似乎使问题变得更加复杂，但根据一阶条件的最优性（即式 (2.5)），中括号中的项正为 0，从而我们得到：

$$v'(x) = \mathcal{F}_1(x, g(x))$$

实际上, x 的变动对值函数有两方面影响: 一方面是直接对当期目标函数产生作用; 另一方面是其导致决策规则变化, 进而间接影响未来的效用, 然而一阶条件的最优性使得间接效用消失——这本质上是**包络定理**的运用。在动态规划问题中, 上述条件也被称为 **Benveniste-Schenkman 条件**。

现在, 我们得到了值函数导数的表达式, 进而也可知 $v'(g(x)) = \mathcal{F}_1(g(x), g(g(x)))$ 。因此, 最优处时的一阶条件式 (2.5) 可以进一步写为:

$$\mathcal{F}_2(x, g(x)) + \beta \mathcal{F}_1(g(x), g(g(x))) = 0, \forall x \quad (2.7)$$

回顾序列问题中欧拉方程的形式:

$$\mathcal{F}_2(x_t, x_{t+1}) + \beta \mathcal{F}_1(x_{t+1}, x_{t+2}) = 0, \forall t$$

其未知成分是数值构成的序列 $\{x_t\}_{t=1}^{\infty}$ 。在递归形式下, 式 (2.7) 并不包含特定的未知量如 x_t, x_{t+1}, x_{t+2} , 而是对所有 x 成立, 其未知是策略函数 g 。因此, 它实际是将欧拉方程表达为泛函, 通常称之为**欧拉泛函** (Functional Euler Equation)。

2.1.4 递归问题解法的启示: 贝尔曼方程 vs 欧拉泛函

对于动态优化问题, 在**序列视角**下: 我们通过利用非线性差分方程 (欧拉方程) 和横截性条件来求解最优序列; 在本章的**递归视角**下: 我们首先建立了关于值函数的贝尔曼方程:

$$v(x) = \max_{x' \in \Gamma(x)} \{\mathcal{F}(x, x') + \beta v(x')\}$$

接着利用最优处的一阶条件和包络定理推导出了关于决策规则的欧拉泛函:

$$\mathcal{F}_2(x, g(x)) + \beta \mathcal{F}_1(g(x), g(g(x))) = 0, \forall x$$

他们都是泛函方程, 但前者的未知量是值函数, 后者的未知量是策略函数 (决策规则)。这实际上对应了两种动态规划问题求解思路: 直接利用贝尔曼方程求解值函数或利用欧拉泛函求解策略函数, 二者是不同的。通过求解值函数, 我们可以进一步得到决策规则 $k' = g(k)$, 这是一维动力系统; 而直接处理泛函的话, 我们面对的是一个二维动力系统。在后面我们将看到, 贝尔曼方程符合压缩映射定理的条件, 可以迭代求得唯一解, 较为稳健; 欧拉泛函并不是压缩映射, 它只是最优策略函数 g 的一个必要条件, 因此存在多重解的可能, 但求解速度更快。

从下一节开始, 我们将运用本节提出的思路及工具, 对递归形式的 RCK 模型展开

分析。并且，我们将在 RCK 模型的基础上，深入讨论值函数性质、动态规划求解等关键问题。

2.2 递归形式下的最优增长模型

通常，将序列问题转化为递归形式能够帮助我们更好地进行分析。当一个动态问题被写为递归形式后，经济的行为唯一依赖的就是**状态变量**。此外，目前已经发展出了许多与递归问题相关的方便的计算方法，我们将在后面的章节详细学习。在本节，我们会把无限期最优增长模型写为递归形式，基于上一节的思路 and 工具，深入研究动态规划的相关理论方法。

2.2.1 贝尔曼方程与一阶条件

对于无限期最优增长模型，不难看出问题是平稳的，状态变量是每期的期初资本存量 k ，值函数仅依赖于 k ，给定不同的资本存量将会得到不同的最优化序列和最优值。因此我们可以将值函数记为 $v(k)$ 。控制变量是 $c = f(k) + (1 - \delta)k - k'$ 。为了记号方便，记 $\gamma(k) \equiv f(k) + (1 - \delta)k$ ，从而 RCK 模型的贝尔曼方程为：

$$v(k) = \max_{k' \in \Gamma(k)} [u(\gamma(k) - k') + \beta v(k')] \quad (2.8)$$

其中，可行集 $\Gamma(k) = [0, \gamma(k)]$ ， $\forall k$ 。记其决策规则为 $k' = g(k)$ ：

$$g(k) \equiv \operatorname{argmax}_{k' \in \Gamma(k)} [u(\gamma(k) - k') + \beta v(k')]$$

与上一节类似，假设值函数 $v(\cdot)$ 已知，那么贝尔曼方程就被简化为一个两期优化问题：

$$\max_{k' \in \Gamma(k)} [u(\gamma(k) - k') + \beta v(k')]$$

对 k' 求导可得一阶条件：

$$u'(\gamma(k) - k') = \beta v'(k') \quad (2.9)$$

假设存在决策规则时内点解，从而 $k' = g(k)$ 满足一阶条件，即最优处的一阶条件为：

$$u'(\gamma(k) - g(k)) = \beta v'(g(k)) \quad (2.10)$$

在序列问题下，结合一阶条件和边界条件，理论上可以解得最优序列。但是，对于

递归问题，正如上一节指出的，**核心问题在于**： v 未知，进而 v' 也未知。换句话说，我们需要得到 v' 。不过我们已经知道，通过包络定理，我们可以很方便的得到 v' ，进而得到欧拉泛函。下面进一步求解这一最优条件。

2.2.2 包络定理与欧拉泛函

注意到，在问题取到最优，即 $k' = g(k)$ 时，贝尔曼方程的最大化算子消去，对任意 k 下式恒成立：

$$v(k) = u(\gamma(k) - g(k)) + \beta v(g(k)), \quad \forall k$$

方程两边同时对 k 做微分可得：

$$\begin{aligned} v'(k) &= u'(\gamma(k) - g(k))(\gamma'(k) - g'(k)) + \beta v'(g(k))g'(k) \\ &= u'(\gamma(k) - g(k))\gamma'(k) - u'(\gamma(k) - g(k))g'(k) + \beta v'(g(k))g'(k) \\ &= u'(\gamma(k) - g(k))\gamma'(k) + g'(k)[-u'(\gamma(k) - g(k)) + \beta v'(g(k))] \\ &= \underbrace{u'(c)[f'(k) + (1 - \delta)]}_{k \text{ 变化的直接效应}} + \underbrace{[-u'(c) + \beta v'(g(k))]}_{\text{选择最优 } k' = g(k) \text{ 的间接效应}} g'(k) \end{aligned} \quad (2.11)$$

由于决策规则满足一阶条件，即有式 (2.10) 成立将其带入全微分的恒等式，发现右侧第二项中括号部分为 0——即由选择最优 $k' = g(k)$ 带来的间接影响为 0，进而得到值函数导数为：

$$\begin{aligned} v'(k) &= u'(\gamma(k) - g(k))\gamma'(k) \\ &\equiv u'(c)[f'(k) + 1 - \delta] \end{aligned} \quad (2.12)$$

同样，推导过程实际就是**包络定理**的应用：状态变量 k 的变化会通过两条途径影响值函数：

- 直接路径： k 变化-当期产出 $f(k)$ 变化-消费 c 变化
- 间接路径： k 变化-最优选择 k' 变化-影响未来效用 $v(k')$

而包络定理表明，由于一阶条件的最优性，间接效应被抵消，只剩下直接效应。基于所得到的值函数导数式 (2.12)，可进一步知道在 $g(k)$ 处有：

$$v'(g(k)) = u'(\gamma(g(k)) - g(g(k)))\gamma'(g(k))$$

进而可以将最优时的一阶条件式 (2.10) 进一步写为欧拉泛函：

$$\begin{aligned} u'(\gamma(k) - g(k)) &= \beta v'(g(k)) \\ &= \beta u'(\gamma(g(k)) - g(g(k)))\gamma'(g(k)) \end{aligned} \quad (2.13)$$

也即：

$$u'(c) = \beta u'(c') [f'(k') + (1 - \delta)]$$

回顾此前序列问题中得到的欧拉方程：

$$\frac{u'(c_t)}{\beta u'(c_{t+1})} = f'(k_{t+1}) + 1 - \delta$$

二者形式十分近似，但有着重要区别：前者要求解的未知量是资本的无穷序列值；后者是一个泛函，未知量是策略函数 g 。

与前一节类似，贝尔曼方程与欧拉泛函对应了两种不同的解法思路：基于值函数求解和基于策略函数求解。我们将在后面展开具体研究。但在此之前，我们需要先掌握一些泛函分析的数学工具，进而建立值函数与策略函数的相关性质，为分析模型性质和具体求解奠定基础。

2.2.3 引利：连续逼近法求解

为了理解使用数学工具的必要性，在此处先抛出一个引例。事实上，如果能够解决这个问题，值函数的性质与解法自然得到证明。目前，我们虽然推出了欧拉泛函这一最优条件，但对于最为关注的初始目标——值函数 v 的形式、存在性与唯一性等还没有任何认识。

上述递归问题的古典方法是连续逼近法（Method of Successive Approximations）。对于 RCK 模型的贝尔曼方程：

$$v(k) = \max_{k' \in \Gamma(k)} [u(\gamma(k) - k') + \beta v(k')]$$

我们的一种思路是从这个泛函中直接求解值函数 v 。假设有任意的一个备选函数 $v_0(k)$ 。接着，定义一个新的值函数：

$$v_1(k) = \max_{k'} [u(\gamma(k) - k') + \beta v_0(k')]$$

如果对所有 $k \geq 0$ ，都有 $v_0(k) = v_1(k)$ ，那么我们幸运地解决了问题。但通常 $v_0(k) \neq v_1(k)$ ，继续迭代：

$$v_{n+1}(k) = \max_{k'} [u(\gamma(k) - k') + \beta v_n(k')], \quad n = 0, 1, \dots$$

我们感兴趣的是：当迭代次数 n 趋于无穷时， v_n 如何变化？

为了分析这一问题，首先，假设有一个可行（feasible）策略 $g_0(k)$ ，这个策略未必

是最优的，因此被称为次优策略（Suboptimal Policy），引入的目的是作为逼近法的初始猜测。定义 $v_0(k)$ 是这个次优策略下对应的值函数值：

$$v_0(k_0) = \sum_{t=0}^{\infty} \beta^t u(\gamma(k_t) - g_0(k_t))$$

其中资本路径由 $k_{t+1} = g_0(k_t)$ 生成。显然，如下递归形式恒成立：

$$v_0(k) = u(\gamma(k) - g_0(k)) + \beta v_0(g_0(k))$$

此时，我们通过假定一个可行的次优策略 $g_0(k)$ ，得到了上面所说的备选值函数 $v_0(k)$ 。接着，根据上面 n 的迭代法则，可得到：

$$\begin{aligned} v_1(k) &= \max_{k'} [u(\gamma(k) - k') + \beta v_0(k')] \\ &\geq [u(\gamma(k) - g_0(k)) + \beta v_0(g_0(k))] \\ &= v_0(k) \end{aligned}$$

其中大于等于号是因为：若我们今天能取到方程最大化的最优值，它一定优于任意取的可行次优策略（计划者不会比始终遵循策略 $g_0(k)$ 做得更差）。类似地，继续进行迭代：

$$\begin{aligned} v_2(k) &= \max_{k'} [u(\gamma(k) - k') + \beta v_1(k')] \\ &\geq \max_{k'} [u(\gamma(k) - k') + \beta v_0(k')] \\ &= v_1(k) \end{aligned}$$

最终不难得到：

$$v_{n+1}(k) \geq v_n(k), \quad n = 0, 1, \dots$$

需要注意，这里的 n 是迭代次数而不是时间标记。回到贝尔曼方程上：

$$v(k) = \max_{k'} [u(\gamma(k) - k') + \beta v(k')]$$

定义其右侧为：

$$Tv(k) \equiv \max_{k'} [u(\gamma(k) - k') + \beta v(k')] \quad (2.14)$$

T 是一个算子（Operator）：其输入是一个函数 v ，返回的是一个函数 Tv 。我们称

之为贝尔曼算子 (Bellman Operator)。类似地, 第 $n+1$ 次迭代过程的右侧可以定义为:

$$Tv_n(k) \equiv \max_{k'} [u(\gamma(k) - k') + \beta v_n(k')]$$

利用这一记号可得: $v_{n+1} = Tv_n$, $n = 0, 1, \dots$ 。进一步将贝尔曼方程左侧纳入观察, 不难看出, 对于贝尔曼方程的求解等价于求解如下的不动点问题 (Fixed Point Problem):

$$v = Tv$$

另外, 对上面次优策略下的迭代过程我们已经得到:

$$v_{n+1} = Tv_n \geq v_n$$

与不动点问题相结合来看, 我们现在的目标就是证明: 当 n 趋于无穷大时, 单调递增的函数序列 $\{v_n\}$ 收敛, 且极限 v 满足贝尔曼方程。这样我们不仅证明了贝尔曼方程的可解性, 而且通过迭代实现了一个算法 (构造了一个不动点), 得到数值解。为了研究类似于式 (2.14) 定义的算子, 我们需要运用相关数学工具。例如, 为了证明算子 T 将一个函数空间 C 映射到其自身, 我们必须选择合适的函数空间进行研究。此外, 我们可能还需要相应空间上算子 T 的不动点定理。后续将看到, 我们所需的两个核心工具就是压缩映射定理和 Blackwell 充分条件。

2.3 数学准备

上面的例子其实引出了两个问题:

- 通过定义贝尔曼算子, 我们将递归问题变为不动点问题 $v = Tv$ 的求解, 但是这个解在理论上是否存在和唯一?
- 给定初始猜测的 $v_0(k)$, 由算子 T 生成的值函数序列 $\{v_n\}$ 是否收敛到 v ? 即这一算法是否可行?

证明这两个问题需要做一些泛函分析的数学准备, 例如, 如何定义函数间的距离、函数序列的收敛性等。

2.3.1 度量空间中的收敛性

定义 2.1 度量空间 (Metric Space) 由一个非空集合 S 和某一度量或称为距离 (distance function) $d: S \times S \rightarrow \mathbb{R}$ 所定义, 其中度量 d 满足: $\forall x, y, z \in S$

- $d(x, y) \geq 0$, 当且仅当 $x = y$ 时取等
- $d(x, y) = d(y, x)$
- $d(x, y) \leq d(x, z) + d(z, y)$

在这里, 集合 S 不止于数集, 也可能是函数集 (例如我们感兴趣的值函数集) 等。因此, 度量空间的定义比普通欧氏距离 (Euclidean Distance) 更复杂。但显然, 实数集 $S = \mathbb{R}$ 和绝对距离 $d(x, y) = |x - y|$ 构成一个度量空间。

例 2.1 常见的度量空间例子:

- 任意有限维空间 $\mathbb{R}^n$ 和其上定义的距离:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}, \quad 1 \leq p < \infty$$

$$d(x, y) = \max_i (|x_i - y_i|), \quad p = \infty$$

- 定义在 $[a, b]$ 上的连续函数集 (常记为 $C[a, b]$) 和其上定义的距离:

$$d(x, y) = \left(\int_a^b |x(t) - y(t)|^p dt \right)^{1/p}, \quad 1 \leq p < \infty$$

$$d(x, y) = \max_{a \leq t \leq b} (|x(t) - y(t)|), \quad p = \infty$$

定义 2.2 赋范向量空间 (Normed Vector Space) 由一个向量空间 S 和范数 $\|\cdot\| : S \rightarrow \mathbb{R}$ 所定义, 其中范数满足: $\forall x, y \in S$ 和 $a \in \mathbb{R}$

- $\|x\| = 0$ 当且仅当 $x = \mathbf{0}$
- $\|x\| = |a| \cdot \|x\|$
- $\|x + y\| \leq \|x\| + \|y\|$

不难看出, 若令距离 $d(x, y) = \|x - y\|$, 那么任意赋范向量空间都是度量空间。

例 2.2 常见的赋范向量空间例子:

- 任意有限维空间 $\mathbb{R}^n$ 和其上定义的范数:

$$\|x\| = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}, \quad 1 \leq p < \infty$$

$$\|x\| = \max_i (|x_i|), \quad p = \infty$$

- 定义在 $[a, b]$ 上的连续函数集 $C[a, b]$ 和其上定义的范数:

$$\|x\| = \left(\int_a^b |x(t)|^p dt \right)^{1/p}, \quad 1 \leq p < \infty$$

$$\|x\| = \max_{a \leq t \leq b} (|x(t)|), \quad p = \infty$$

定义 2.3 (收敛性) 我们称 S 中的序列 $\{x_n\}_{n=0}^\infty$ 收敛到 $x \in S$: 若对 $\forall \epsilon > 0$, 存在 N_ϵ , 使得:

$$d(x_n, x) < \epsilon, \quad n \geq N_\epsilon$$

注意序列 $\{x_n\}$ 不只限于实数 (事实上在动态规划中, 我们感兴趣的是函数序列)。但从另一角度看, 序列 $\{x_n\}$ 收敛到 $x \in S$ 等价于由距离构成的实数序列 $\{d(x_n, x)\}$ 收敛到 0。

定义 2.4 (柯西序列) S 中的序列 $\{x_n\}_{n=0}^\infty$ 被称为柯西序列 (Cauchy Sequence) 若其满足柯西准则: 对 $\forall \epsilon > 0$, 存在 N_ϵ , 使得:

$$d(x_n, x_m) < \epsilon, \quad n, m \geq N_\epsilon$$

定理 2.1 所有收敛序列都是柯西序列。

定理 2.2 所有柯西序列都有界。

定义柯西序列的好处在于, 只利用序列本身信息就可以进行判断收敛性, 而不用知道实际极限。但是需要注意, **并非所有柯西序列都收敛**。实际上, 这与序列所处空间的完备性 (Completeness) 密切相关。

例 2.3 考虑 $[0, 1]$ 上的连续函数集合 $C[0, 1]$ 。定义 L^1 度量:

$$d(f, g) = \int_0^1 |f(x) - g(x)| dx$$

构造函数序列 $\{f_n\}$:

$$f_n(x) = \begin{cases} 0 & x \in [0, \frac{1}{2} - \frac{1}{n}] \\ n(x - (\frac{1}{2} - \frac{1}{n})) & x \in (\frac{1}{2} - \frac{1}{n}, \frac{1}{2}] \\ 1 & x \in (\frac{1}{2}, 1] \end{cases}$$

由于对任意 $m > n$, 成立:

$$d(f_m, f_n) = \int_0^1 |f_m(x) - f_n(x)| dx \leq \frac{1}{n} \rightarrow 0 \quad (n \rightarrow \infty)$$

$\{f_n\}$ 在 L^1 度量下是柯西序列, 但其收敛到极限为:

$$f(x) = \begin{cases} 0 & x \in [0, \frac{1}{2}] \\ 1 & x \in (\frac{1}{2}, 1] \end{cases}$$

在 $x = \frac{1}{2}$ 处不连续, 因此极限函数 $f \notin C[0, 1]$ 。从而 $\{f_n\}$ 在 $C[0, 1]$ 中无极限, 不是收敛序列。

定义 2.5 (完备性) 如果 S 中任意柯西序列都收敛到 S 中某一极限, 则称度量空间 (S, d) 是完备的 (Complete)。完备的赋范向量空间被称为巴拿赫 (Banach) 空间。

定理 2.3 令 $X \subseteq \mathbb{R}^n$, 定义了上确界范数: $\|f\| = \sup_{x \in X} (|f(x)|)$ 的所有有界连续函数 $f: X \rightarrow \mathbb{R}$ 的集合 $C(X)$ 是一个完备空间。

定义完备空间的方便之处在于, 只要其中的序列符合柯西准则, 那么它在这一空间中就存在极限。

2.3.2 压缩映射定理

我们已经指出, 贝尔曼方程式 (2.8) 的本质是求解一个泛函中的不动点问题: $v = Tv$ 。其中 T 是贝尔曼算子:

$$Tv(k) \equiv \max_{k'} [u(\gamma(k) - k') + \beta v(k')]$$

同时, 从算法层面 (寻找不动点) 我们已经构造了递增的值函数序列 $\{v_n\}$:

$$\begin{aligned} Tv_n(k) &\equiv \max_{k'} [u(\gamma(k) - k') + \beta v_n(k')] \\ v_{n+1} &= Tv_n \geq v_n \end{aligned}$$

我们希望证明, 随着迭代次数 n 足够大, 值函数序列 $\{v_n\}$ 收敛到唯一极限 v 。这需要用到**压缩映射定理** (Contraction Mapping Theorem)。什么是压缩映射? 和前面定义的度量空间和完备性有什么关系?

定义 2.6 (压缩映射) 令 (S, d) 为度量空间, 并定义 $T : S \rightarrow S$ 。如果对某一 $\beta \in (0, 1)$, 成立:

$$d(Tx, Ty) \leq \beta d(x, y)$$

则称 T 为压缩映射, β 为压缩系数。

例 2.4 令 $S = [a, b]$, $d(x, y) = |x - y|$ 。当对某一 $\beta \in (0, 1)$:

$$|Tx - Ty| \leq \beta |x - y|$$

则 $T : S \rightarrow S$ 为压缩映射。考虑 $a = 0, b = 1$, $Tx = 0.2 + 0.6x$:

$$|Tx - Ty| = 0.6(x - y) \leq \beta |x - y|, \quad \forall \beta \in [0.6, 1)$$

因此 T 是压缩映射。

定义 2.7 若 $x \in S$ 满足: $Tx = x$, 则称 x 为不动点。

定理 2.4 (压缩映射定理) 令 (S, d) 为完备度量空间, 令 $T : S \rightarrow S$ 为压缩映射, 压缩系数为 β , 则

- T 在 S 中有唯一不动点;
- 对任意 $x_0 \in S$, 成立: $d(T^n x_0, x) \leq \beta^n d(x_0, x)$, $n = 0, 1, 2, \dots$

证明. 先证明不动点存在, 接着利用压缩映射定义可得第二条。前者分三步证明:

Step1: 证明迭代算子 T 后形成的序列是一个柯西序列

任取一个初始 $x_0 \in S$, 令 $x_n = T^n x_0$, 进而得到了序列 $\{x_n\}_{n=0}^{\infty}$ 并且满足 $x_{n+1} = Tx_n$ 。由于 T 是压缩映射, 因此有: $d(x_2, x_1) = d(Tx_1, Tx_0) \leq \beta d(x_1, x_0)$, 以此类推, 对 $n \geq 1$ 成立:

$$d(x_{n+1}, x_n) \leq \beta^n d(x_1, x_0)$$

因此对任意 $m > n$, 应用距离的三角不等式性质:

$$\begin{aligned} d(x_m, x_n) &\leq d(x_m, x_{m-1}) + \dots + d(x_{n+2}, x_{n+1}) + d(x_{n+1}, x_n) \\ &\leq [\beta^{m-1} + \dots + \beta^{n+1} + \beta^n] d(x_1, x_0) \\ &= \beta^n [\beta^{m-n-1} + \dots + \beta + 1] d(x_1, x_0) \\ &\leq \frac{\beta^n}{1 - \beta} d(x_1, x_0) \end{aligned}$$

由于 $\beta \in (0, 1)$, 显然 $\{x_n\}$ 为柯西序列。又由于 S 是完备的, 因此 $x_n \rightarrow x \in S$

Step2: 证明极限是 T 的不动点

再次运用不三角不等式和压缩映射的定义:

$$\begin{aligned} d(Tx, x) &\leq d(Tx, T^n x_0) + d(T^n x_0, x) \\ &= d(Tx, T(T^{n-1} x_0)) + d(T^n x_0, x) \\ &\leq \beta d(x, T^{n-1} x_0) + d(T^n x_0, x) \end{aligned}$$

显然当 $n \rightarrow \infty$, 右边两项的距离都趋于 0, 因此:

$$d(Tx, x) = 0, \quad Tx = x$$

从而序列 $\{x_n\}$ 的极限 x 是 T 的不动点。

Step3: 证明不动点的唯一性

反证, 假设存在另一不动点 $Tx' = x', x' \neq x$, 则:

$$0 < \delta \equiv d(x, x') = d(Tx, Tx') \leq \beta d(x, x') = \beta \delta$$

但由于 $\beta \in (0, 1)$, 显然矛盾, 从而唯一性得证。

最后, 由压缩映射的定义立得:

$$d(T^n x_0, x) = d(T(T^{n-1} x_0), Tx) \leq \beta d(T^{n-1} x_0, x)$$

□

压缩映射定理 (Contraction Mapping Theorem) 表明: (1) 完备空间上定义的压缩映射存在唯一不动点; (2) 从完备空间 S 中任意初始点 $x_0 \in S$ 出发, 在其上迭代压缩映射 T , 可以无限接近唯一的不动点。即我们找到了一个求解不动点的算法。

再次回顾目标: 我们通过迭代贝尔曼算子:

$$Tv(k) \equiv \max_{k'} [u(\gamma(k) - k') + \beta v(k')]$$

得到了递增的值函数序列 $v_{n+1} = Tv_n \geq v_n$, 我们希望这一序列收敛到贝尔曼方程的不动点 $v = Tv$ 。我们已经指出, 首先需要证明贝尔曼方程 (不动点问题) 确实存在唯一解; 其次去证明递增的值函数序列 $\{v_n\}$ 收敛到不动点。显然, 如果能够证明贝尔曼算子是压缩映射, 那么直接应用压缩映射定理即可。但是利用定义证明贝尔曼算子是压缩映射的难度较大, 在这里给出一个充分条件:

定理 2.5 (Blackwell 充分条件) 令 $X \subseteq \mathbb{R}^n$, 令 $B(X)$ 为有界函数集合 $f : X \rightarrow \mathbb{R}$, 其上定义了上确界范数 (sup norm): $\|f\| = \sup_{x \in X} (|f(x)|)$ 。令 $T : B(X) \rightarrow B(X)$, 且满足:

- 单调性: 对 $\forall f, g \in B(X)$, $f \leq g$, 则 $Tf \leq Tg$
- 折扣性: 存在 $\beta \in (0, 1)$, 使得: $T(f + a) \leq Tf + \beta a$, $\forall f \in B(X)$ 。其中, 函数 $(f + a) \equiv f(x) + a$, $a \geq 0$ 。

那么 T 为压缩映射。

证明. 令 $v, w \in B(X)$, 从而:

$$\begin{aligned} v(x) &= v(x) + w(x) - w(x) \\ &\leq w(x) + |v(x) - w(x)| \\ &\leq w(x) + \|v - w\|, \quad \text{for all } x \in X \end{aligned}$$

由于映射 T 满足单调性和折扣性, 因此:

$$Tv \leq T(w + \|v - w\|) \leq Tw + \beta\|v - w\|$$

同理:

$$Tw \leq T(v + \|v - w\|) \leq Tv + \beta\|v - w\|$$

根据这两个不等式可知:

$$|Tv(x) - Tw(x)| \leq \beta\|v - w\|, \quad \text{for all } x \in X$$

也即:

$$\|Tv - Tw\| \leq \beta\|v - w\|$$

从而 T 是压缩映射。 □

2.3.3 应用 CMT

重新考虑递归形式的最优增长模型。我们定义了贝尔曼方程右边为贝尔曼算子:

$$Tv(k) \equiv \max_{k'} [u(\gamma(k) - k') + \beta v(k')]$$

下面验证这一算子的性质.

(1) T 满足单调性:

若 $v \leq w$, 则:

$$u(\gamma(k) - k') + \beta v(k') \leq u(\gamma(k) - k') + \beta w(k'), \quad \forall x$$

从而有:

$$\max_{k'} [u(\gamma(k) - k') + \beta v(k')] \leq \max_{k'} [u(\gamma(k) - k') + \beta w(k')]$$

因此:

$$Tv(k) \leq Tw(k)$$

(2) **T 满足 discounting:**

对 $\forall a \geq 0$, 成立:

$$\begin{aligned} T(v+a)(k) &= \max_x [u(f(k) - x) + \beta(v(x) + a)] \\ &= \max_x [u(f(k) - x) + \beta v(x)] + \beta a \\ &= Tv(k) + \beta a \end{aligned}$$

因此, 贝尔曼算子 T 满足 Blackwell 充分条件, 从而是压缩映射。

再次回忆此前提到所面临的两个问题:

- 理论层面, 贝尔曼方程 $v = Tv$ 有解吗, 即是否存在唯一不动点
- 算法层面, 构造的值函数序列是否收敛

在证明了贝尔曼算子 T 是压缩映射后, 直接应用压缩映射定理, 似乎我们已经完成了证明。但实际上, 还存在两个确实缺陷: 一个存在于证明贝尔曼算子压缩性质 (即运用 Blackwell 充分条件) 的过程中; 另一个则存在于运用压缩映射定理的过程中。具体看:

(1) **Blackwell 充分条件应用的前提:** 算子 T 是定义在有界函数空间上的。

对于递归形式下的最优增长模型, 我们所分析的也是一个函数空间, 即 S 中的元素是值函数 v 。但是, 值函数是否有界? 答案是肯定的, 这与我们对生产函数和效用函数的假设密切相关。根据 Inada 条件、 $\beta < 1$ 和消费与资本的非负性, 由级数收敛性知识, 下界的存在是显然的。对于上界: 由生产函数的凹性, 资本积累存在上界, 记为 $k \leq k^*$, 从而 $f(k) \leq f(k^*)$; 消费的最大可能取值则为 $f(k)$, 即下期资本取 0, 从而有: $u(c) \leq u(f(k)) \leq u(f(k^*))$ 。因此,

$$v(k) = \sum_{t=0}^{\infty} \beta^t u(c) \leq \sum_{t=0}^{\infty} \beta^t u(f(k^*)) = \frac{u(f(k^*))}{1-\beta} < \infty$$

从而值函数有界, 可以对贝尔曼算子应用 Blackwell 充分条件。

(2) **压缩映射定理应用的前提**: 压缩映射 T 是定义在完备空间 (S, d) 上的。

值函数是有界的, 但是值函数空间否是完备的呢? 我们曾在定理 2.3 中指出, 定义了上确界范数 $\|f\| = \sup_{x \in X} (|f(x)|)$ 的有界连续函数集合空间 $C(X)$ 是一个完备空间。那么, 只要能证明值函数是连续的, 我们就能在 Blackwell 条件的基础上进一步应用压缩映射定理: 证明不动点的存在性和唯一性, 并且运用其推广证明值函数序列的收敛性。

2.4 值函数的存在性与性质

值函数连续性和相关性质的证明相对较为复杂, 我们通过引入最优性原理 (Principal of Optimality) 进而展开。

2.4.1 最优性原理: 序列解与递归解的关系

首先, 将序列问题 (Sequential Problem, **SP**) 写为一般化形式:

$$\begin{aligned} \sup_{\{x_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t F(x_t, x_{t+1}) \\ \text{s.t. } x_{t+1} \in \Gamma(x_t), \quad \forall t \\ x_0 \in X \quad \text{给定} \end{aligned} \tag{SP}$$

其中, X 是 x 所有可能取值集合; $\Gamma: X \rightarrow X$ 是描述可行性的对应 (Correspondence), 即给定当前状态 x_t , 下期 x_{t+1} 的所有可行取值; F 是当期回报函数。我们称从 x_0 开始, 任意可行的序列 $\{x_{t+1}\}_{t=0}^{\infty}$ 为一个可行计划 (Feasible Plans)。记所有可行计划构成的集合为:

$$\pi(x_0) = \{\{x_{t+1}\}_{t=0}^{\infty} : x_{t+1} \in \Gamma(x_t), t = 0, 1, 2, \dots\}$$

其元素是一个序列, 记为 $\mathbf{x} \in \pi(x_0)$ 。

其次, 我们写出与序列问题 SP 相对应的递归问题 R , 或称为泛函方程 (Functional Equation, FE):²

$$v(x) = \sup_{y \in \Gamma(x)} [F(x, y) + \beta v(y)] \quad \forall x \in X \tag{FE}$$

其中 x 是状态变量, y 是控制变量。

那么, SP 与 FE 是否等价? 更一般的想法是:

- 问题 FE 的解 (函数) v 在 $x = x_0$ 处的取值达到 SP 的上界;

²在前面我们研究一般化的贝尔曼方程时使用的记号是 $\mathcal{F}(x, x')$, 因为我们使用 $h(x, y)$ 将控制变量进行了替换, 这里并没有本质区别, 只是记号的差异。

- 序列 $\{x_{t+1}\}_{t=0}^{\infty}$ 达到问题 SP 上界, 当且仅当 $v(x_t) = F(x_t, x_{t+1}) + \beta v(x_{t+1})$, $t = 0, 1, 2, \dots$

贝尔曼将这一想法称为**最优性原理**。当然, 这一结果的成立需要一些假设。

假设 2.1 集合 $\Gamma(x)$ 对任意 $x \in X$ 非空

假设 2.2 对任意 $\{x_0, x_1, \dots\} \in \Pi(x_0)$, $x_0 \in X$, 目标极限 $\lim_{n \rightarrow \infty} \sum_{t=0}^n \beta^t F(x_t, x_{t+1})$ 存在 (可能为无穷)

不难看出, 假设 2.2 成立的一个充分条件是: $F(x, y)$ 有界 (bounded) 且 $0 < \beta < 1$ 。对任意 $n = 0, 1, \dots$, 定义 $u_n : \pi(x_0) \rightarrow \mathbb{R}$:

$$u_n(\mathbf{x}) \equiv \sum_{t=0}^n \beta^t F(x_t, x_{t+1}), \quad \mathbf{x} = \{x_0, x_1, \dots\} \in \pi(x_0)$$

由假设 2.2, 可定义极限:

$$u(\mathbf{x}) \equiv \lim_{n \rightarrow \infty} u_n(\mathbf{x})$$

如果假设 2.1 和假设 2.2 均成立, 那么序列问题 SP 是良定义的。因此我们可以定义**上确界函数**:

$$v^*(x_0) \equiv \sup_{\mathbf{x} \in \pi(x_0)} u(\mathbf{x})$$

这样, $v^*(x_0)$ 是 SP 问题的上确界。根据上确界定义, 其满足:

$$\begin{aligned} \forall \epsilon > 0, \forall \mathbf{x} \in \pi(x_0) : v^*(x_0) &\geq u(\mathbf{x}) \\ \forall \epsilon > 0, \exists \mathbf{x} \in \pi(x_0) : v^*(x_0) &\leq u(\mathbf{x}) + \epsilon \end{aligned}$$

我们希望研究 SP 问题的**上确界函数** v^* 和 FE 问题的解 v 的关系。需要注意: v^* 是唯一定义的, 但 FE 问题的解 v 可能有很多个。简单起见, 以下不考虑无穷大的情形, 即考虑 $|v^*(x_0)| < \infty$ 。那么, v^* 是 FE 问题的解等价于如下条件成立:

$$\begin{aligned} \forall y \in \Gamma(x_0) : v^*(x_0) &\geq F(x_0, y) + \beta v^*(y) \\ \forall \epsilon > 0, \exists y \in \Gamma(x_0) : v^*(x_0) &\leq F(x_0, y) + \beta v^*(y) + \epsilon, \end{aligned}$$

为了证明 v^* 满足 FE , 引入如下引理:

引理 2.1 令 X, Γ, F, β 符合假设 2.2, 则对 $\forall x_0 \in X, \forall (x_0, x_1, \dots) = \mathbf{x} \in \pi(x_0)$, 成立:

$$u(\mathbf{x}) = F(x_0, x_1) + \beta u(\mathbf{x}'), \quad \mathbf{x}' = (x_1, x_2, \dots)$$

定理 2.6 (SP-FE) 令 X, Γ, F, β 符合假设 2.1 和假设 2.2, 则上确界函数 v^* 满足 FE。

证明. 前面提到, 上确界函数 v^* 是 FE 问题的解等价于成立如下两个条件:

$$\begin{aligned} \forall y \in \Gamma(x_0) : v^*(x_0) &\geq F(x_0, y) + \beta v^*(y) \\ \forall \epsilon > 0, \exists y \in \Gamma(x_0) : v^*(x_0) &\leq F(x_0, y) + \beta v^*(y) + \epsilon \end{aligned}$$

先证明第一个条件:

$$\forall y \in \Gamma(x_0) : v^*(x_0) \geq F(x_0, y) + \beta v^*(y)$$

由 $v^*(x_0) \equiv \sup_{\mathbf{x} \in \pi(x_0)} u(\mathbf{x})$, 根据上确界的定义, 成立如下两条:

$$\begin{aligned} \forall \epsilon > 0, \forall \mathbf{x} \in \pi(x_0) : v^*(x_0) &\geq u(\mathbf{x}) \\ \forall \epsilon > 0, \exists \mathbf{x} \in \pi(x_0) : v^*(x_0) &\leq u(\mathbf{x}) + \epsilon \end{aligned}$$

根据后者, 任取 $x_1 \in \Gamma(x_0)$, 任取 $\epsilon > 0$:

$$\exists \mathbf{x}' = (x_1, x_2, \dots) \in \pi(x_1), \quad u(\mathbf{x}') \geq v^*(x_1) - \epsilon$$

又由于 $\mathbf{x} = (x_0, x_1, \dots) \in \pi(x_0)$, 根据前者和上述引理:

$$v^*(x_0) \geq u(\mathbf{x}) = F(x_0, x_1) + \beta u(\mathbf{x}') \geq F(x_0, x_1) + \beta v^*(x_1) - \beta \epsilon$$

由于 ϵ 任意, 可知:

$$\forall y \in \Gamma(x_0) : v^*(x_0) \geq F(x_0, y) + \beta v^*(y)$$

再证明第二个条件:

$$\forall \epsilon > 0, \exists y \in \Gamma(x_0) : v^*(x_0) \leq F(x_0, y) + \beta v^*(y) + \epsilon$$

任取 $x_0 \in X$ 和 $\epsilon > 0$, 根据上确界函数定义的第二条和引理可知:

$$\exists \mathbf{x} = (x_0, x_1, \dots) \in \pi(x_0), \quad v^*(x_0) \leq u(\mathbf{x}) + \epsilon = F(x_0, x_1) + \beta u(\mathbf{x}') + \epsilon$$

其中, $\mathbf{x}' = (x_1, x_2, \dots)$ 。从而, 结合上确界定义的第一条可知:

$$v^*(x_0) \leq F(x_0, x_1) + \beta v^*(x_1) + \epsilon$$

由 ϵ 任意性和 $x_1 \in \Gamma(x_0)$ (因为 x_1 在计划中):

$$\forall \epsilon > 0, \exists y \in \Gamma(x_0) : v^*(x_0) \leq F(x_0, y) + \beta v^*(y) + \epsilon$$

从而我们证明了 v^* 是 FE 问题的解。 □

至此, 我们证明了 SP 的解满足 FE , 但反过来是否成立? 一般来说不一定, 虽然 v^* 是 FE 的解, 但 FE 可能存在很多解。不过下面的定理表明: 若 FE 满足特定有界条件, 那么 $v = v^*$ 是其唯一解。

定理 2.7 (Partial Converse: FE-SP) 令 X, Γ, F, β 符合假设 2.1 和假设 2.2。如果值函数 v 是 FE 的一个解且满足 $\lim_{n \rightarrow \infty} \beta^n v(x_n) = 0, \forall x_0 \in X, \forall \mathbf{x} = (x_0, x_1, \dots) \in \pi(x_0)$, 则 $v = v^*$ 。其中:

$$\begin{aligned} v^*(x_0) &\equiv \sup_{\mathbf{x} \in \pi(x_0)} u(\mathbf{x}) \\ u(\mathbf{x}) &\equiv \lim_{n \rightarrow \infty} u_n(\mathbf{x}) \\ u_n(\mathbf{x}) &\equiv \sum_{t=0}^n \beta^t F(x_t, x_{t+1}), \quad \mathbf{x} = \{x_0, x_1, \dots\} \in \pi(x_0) \end{aligned}$$

证明. 方便起见仍考虑 $v(x_0)$ 有限情形。我们此前提到, v 是 FE 的解等价于如下条件成立:

$$\forall y \in \Gamma(x_0) : v(x_0) \geq F(x_0, y) + \beta v(y)$$

$$\forall \epsilon > 0, \exists y \in \Gamma(x_0) : v(x_0) \leq F(x_0, y) + \beta v(y) + \epsilon$$

我们的目标是证明 FE 的这一解 v 是 SP 的解, 即证明 $v(x_0) = \sup_{\mathbf{x} \in \pi(x_0)} u(\mathbf{x})$, 也即往证 FE 的解 v 符合 SP 中上确界的定义:

$$\forall \epsilon > 0, \forall \mathbf{x} \in \pi(x_0) : v(x_0) \geq u(\mathbf{x})$$

$$\forall \epsilon > 0, \exists \mathbf{x} \in \pi(x_0) : v(x_0) \leq u(\mathbf{x}) + \epsilon$$

注意到对任意 $\mathbf{x} \in \pi(x_0)$, 成立:

$$\begin{aligned} v(x_0) &\geq F(x_0, x_1) + \beta v(x_1) \\ &\geq F(x_0, x_1) + \beta F(x_1, x_2) + \beta^2 v(x_2) \\ &\geq \cdots \\ &\geq u_n(\mathbf{x}) + \beta^{n+1} v(x_{n+1}) \end{aligned}$$

取极限并利用 $\lim_{n \rightarrow \infty} \beta^n v(x_n) = 0, \forall x_0 \in X, \forall \mathbf{x} = (x_0, x_1, \dots) \in \pi(x_0)$ 可知上确界定义的前一半成立:

$$\forall \epsilon > 0, \forall \mathbf{x} \in \pi(x_0) : v(x_0) \geq u(\mathbf{x})$$

下面证明上确界定义的后一半, 即:

$$\forall \epsilon > 0, \exists \mathbf{x} \in \pi(x_0) : v(x_0) \leq u(\mathbf{x}) + \epsilon$$

对此, 任取一个 $\epsilon > 0$, 从正实数集中选择 $\{\delta_t\}_{t=1}^\infty$, 使得 $\sum_{t=1}^\infty \beta^{t-1} \delta_t \leq \epsilon/2$ 。由与 v 是 FE 的解, 即:

$$\forall \epsilon > 0, \exists y \in \Gamma(x_0) : v(x_0) \leq F(x_0, y) + \beta v(y) + \epsilon,$$

从而可以取到 $x_1 \in \Gamma(x_0), x_2 \in \Gamma(x_1), \dots$:

$$v(x_t) \leq F(x_t, x_{t+1}) + \beta v(x_{t+1}) + \delta_{t+1}, \quad t = 0, 1, \dots$$

也就是说, $\exists \mathbf{x} = (x_0, x_1, \dots) \in \pi(x_0)$:

$$\begin{aligned} v(x_0) &\leq \sum_{t=0}^n \beta^t F(x_t, x_{t+1}) + \beta^{n+1} v(x_{n+1}) + (\delta_1 + \cdots + \beta^n \delta_{n+1}) \\ &\leq u_n(\mathbf{x}) + \beta^{n+1} v(x_{n+1}) + \epsilon/2, \quad n = 1, 2, \dots \end{aligned}$$

当 n 足够大, 由条件 $\lim_{n \rightarrow \infty} \beta^n v(x_n) = 0$ 可知: $v(x_0) \leq u_n(\mathbf{x}) + \epsilon$ 。由 ϵ 的可知任意性, 上确界后半的定义成立:

$$\forall \epsilon > 0, \exists \mathbf{x} \in \pi(x_0) : v^*(x_0) \leq u(\mathbf{x}) + \epsilon$$

从而:

$$v(x_0) = \sup_{\mathbf{x} \in \pi(x_0)} u(\mathbf{x})$$

也即 FE 的解 v 是 SP 的解。 □

至此，我们可以对序列问题（ SP ）和递归（泛函）问题（ FE ）解的关系进行一个总结。方便起见，再次写下这两个一般化的问题：

• SP :

$$\sup_{\{x_{t+1}\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \beta^t F(x_t, x_{t+1}), \text{ s.t. } x_{t+1} \in \Gamma(x_t), \forall t, x_0 \in X \text{ 给定}$$

• FE :

$$v(x) = \sup_{y \in \Gamma(x)} [F(x, y) + \beta v(y)], \forall x \in X$$

在假设 2.1 和假设 2.2 下，我们通过构造极限函数的上确界找到了 SP 的解：

$$v^*(x_0) = \sup_{\mathbf{x} \in \pi(x_0)} u(\mathbf{x}), \quad u(\mathbf{x}) = \lim_{n \rightarrow \infty} \sum_{t=0}^n \beta^t F(x_t, x_{t+1})$$

同时证明了它至少也是 FE 的一个解，即 $SP \rightarrow FE$ 。另一方面， FE 可能存在很多解 v ，我们证明了其中符合有界条件 $\lim_{n \rightarrow \infty} \beta^n v(x_n) = 0, \forall x_0 \in X, \forall \mathbf{x} = (x_0, x_1, \dots) \in \pi(x_0)$ 的解正是 SP 的解 v^* ，即部分可逆。而 FE 的其余解一定违反了这一有界条件。

2.4.2 最优策略间的关系

最优性原理（定理 2.6 和定理 2.7）给出了序列问题和递归（泛函）问题目标值函数间的关系。我们希望进一步研究两个问题最优策略（Plan）间的关系。

定义 2.8 (最优计划) 如果可行计划 $\mathbf{x}^* = \{x_{t+1}^*\} \in \pi(x_0)$ 能达到 SP 问题的上确界，即 $u(\mathbf{x}^*) \equiv \sum_{t=0}^{\infty} \beta^t F(x_t^*, x_{t+1}^*) = v^*(x_0)$ ，则称 $\mathbf{x}^*$ 为从 x_0 开始的最优计划（Optimal Plan）。

下面两个定理给出了最优计划和 FE 问题中满足 $v = v^*$ 的决策规则间的关系。

定理 2.8 令 X, Γ, F, β 符合假设 2.1 和假设 2.2。令 $\mathbf{x}^* \in \pi(x_0)$ 为一个达到 SP 问题上确界的可行计划，则：

$$v^*(x_t^*) = F(x_t^*, x_{t+1}^*) + \beta v^*(x_{t+1}^*), \quad t = 0, 1, 2, \dots \quad (2.15)$$

证明. 由于 $\mathbf{x}^*$ 达到了上确界，因此由定理 2.6， $v^*(x_t^*)$ 满足 FE ，即对 $\forall \mathbf{x} \in \pi(x_0)$ ：

$$\begin{aligned} v^*(x_0^*) &= u(\mathbf{x}^*) = F(x_0, x_1^*) + \beta u(\mathbf{x}'^*) \\ &\geq u(\mathbf{x}) = F(x_0, x_1) + \beta u(\mathbf{x}'), \end{aligned}$$

又由于 $(x_1^*, x_2, x_3, \dots) \in \pi(x_1^*)$, 从而 $(x_0, x_1^*, x_2, x_3, \dots) \in \pi(x_0)$, 进而有:

$$u(\mathbf{x}^*) \geq u(\mathbf{x}'), \forall \mathbf{x} \in \pi(x_1^*)$$

从而 $u(\mathbf{x}^*) = v(x_1^*)$, 带入上式就得到了 $t = 0$ 时定理的结论。其余可依此类推即可。 $\square$

定理 2.8 表明, SP 问题的最优计划可以构成 FE 的决策规则。下面一个定理则提供了相反方向的直觉: 它表明, 在一定的有界条件下, 符合式 (2.15) 的序列是一个最优计划。

定理 2.9 令 X, Γ, F, β 符合假设 2.1 和假设 2.2。令 $\mathbf{x}^* \in \pi(x_0)$, 且满足:

$$v^*(x_t^*) = F(x_t^*, x_{t+1}^*) + \beta v^*(x_{t+1}^*), \quad t = 0, 1, 2, \dots$$

并且有 $\limsup_{t \rightarrow \infty} \beta^t v^*(x_t^*) \leq 0$ 成立。那么, $\mathbf{x}^*$ 达到 SP 的上确界, 即是最优计划。

证明. 由条件:

$$\begin{aligned} v^*(x_0) &= u(\mathbf{x}^*) = F(x_0^*, x_1^*) + \beta v^*(x_1^*) \\ &= \dots \\ &= u_n(\mathbf{x}^*) + \beta^{n+1} v^*(x_{n+1}^*) \end{aligned}$$

又由有界条件可知: $v^*(x_0) \leq u(\mathbf{x}^*)$ 。由于 $\mathbf{x}^* \in \pi(x_0)$: $v^*(x_0) \geq u(\mathbf{x}^*)$ 从而: $v^*(x_0) = u(\mathbf{x}^*)$, 由定义得证。 $\square$

定义 2.9 如果对任意非空对应 $G: X \rightarrow X$, 成立 $G(x) \subseteq \Gamma(X)$, 则称 G 为策略对应 (Policy Correspondence)。若 G 为单值的, 我们称其为策略函数 (Policy Function), 记为 g 。如存在序列 $\mathbf{x} = (x_0, x_1, \dots)$ 满足 $x_{t+1} \in G(x_t), t = 0, 1, 2, \dots$, 则称 $\mathbf{x}$ 由 G 从 x_0 生成。可以定义最优策略对应 (Optimal Policy Correspondence) G^* :

$$G^*(x) = \{y \in \Gamma(x) : v^*(x) = F(x, y) + \beta v^*(y)\}$$

定理 2.8 表明: 每个最优计划 $\{x_t^*\}$ 都由 G^* 生成; 定理 2.9 表明: 每个由 G^* 生成的计划 $\{x_t^*\}$, 若满足有界条件, 就是一个最优计划。

2.4.3 最大化定理和不动点的存在与唯一性

我们在 2.3 节最后提出, 对于递归形式的最优增长问题, 我们希望利用 Blackwell 定理证明 T 是压缩映射, 进而运用压缩映射定理证明贝尔曼方程 $v = Tv$ 这一不动点问题

解的存在和唯一性。我们已经证明了贝尔曼算子 T 是压缩映射，但是在运用压缩映射定理时遇到了困难：我们希望值函数处于连续空间，确保空间的完备性，这样才能使用压缩映射定理。在2.4节，我们将动态规划写成了更一般化的形式，只要完成一般化形式下的证明，那么 RCK 模型中相关结论自然成立。我们还需要一些额外假设和定理的辅助。方便起见，在此处写下我们所需研究的一般化形式泛函方程：

$$v(x) = \max_{y \in \Gamma(x)} [F(x, y) + \beta v(y)] \quad (2.16)$$

假设 2.3 (凸性假设) 状态变量所有可能取值集合 X 是 $\mathbb{R}^l$ 的凸子集，可行性约束对应 $\Gamma: X \rightarrow X$ 是非空、连续、紧集。

假设 2.4 (有界回报) 函数 $F: A \rightarrow \mathbb{R}$ 是有界连续的，且 $0 < \beta < 1$ 。

显然，假设 2.3和假设 2.4蕴含了假设 2.1和假设 2.2。为了应用压缩映射定理，我们不仅希望值函数有界，更希望在完备空间中研究值函数，因此一个自然的想法就是定义了上确界范数 $\|f\| = \sup_{x \in X} |f(x)|$ 的有界连续函数 $f: X \rightarrow \mathbb{R}$ 构成空间 $C(X)$ 。定义空间 $C(X)$ 上的算子 T ：

$$Tf(x) = \max_{y \in \Gamma(x)} [F(x, y) + \beta f(y)] \quad (2.17)$$

由此，我们将式 (2.16) 简化为不动点问题 $v = Tv$ 。我们将借助最大化定理 (Maximum Theorem) (定理 2.10)、Blackwell 充分条件 (定理 2.5) 和压缩映射定理 (定理 2.4) 证明：算子 T 将 $C(X)$ 中的元素 (函数) 映射到 $C(X)$ 上，即 $T: C(X) \rightarrow C(X)$ ，从而 T 在有界连续函数空间 $C(X)$ 上存在唯一不动点。

定理 2.10 (Maximum Theorem) 令 $X \subseteq \mathbb{R}^l$, $Y \subseteq \mathbb{R}^m$ ，令 $f: X \times Y \rightarrow \mathbb{R}$ 是连续函数，令 $\Gamma: X \rightarrow Y$ 是紧值连续对应 (Correspondence)，那么：

- 从 $X \rightarrow \mathbb{R}$ 的函数 $h(x) \equiv \max_{y \in \Gamma(x)} f(x, y)$ 是连续的
- 由 $G(x) \equiv \operatorname{argmax}_{y \in \Gamma(x)} f(x, y) = \{y \in \Gamma(x) : f(x, y) = h(x)\}$ 给定的解对应 $G: X \rightarrow Y$ 是非空、紧值和上半连续的。

对于形如： $h(x) \equiv \max_{y \in \Gamma(x)} f(x, y)$ ，最大化定理给出了 $h(x)$ 和相应最优 y 值的集合 $G(x)$ 随 x 连续变化的条件。同时，若 $f(x, y)$ 关于 y 严格凹，并且 $\Gamma(x)$ 是凸的，那么 G 是单值的，可记为函数 $g(x)$ 。

定理 2.11 (FE 问题解的存在及唯一性) 令 X, Γ, F, β 满足假设 2.3和假设 2.4， $C(X)$ 为定义了上确界范数的有界连续函数空间，那么：

- 算子 T 将 $C(X)$ 映射到自身
- T 有唯一不动点 $v \in C(X)$
- 任意给定 $v_0 \in C(X)$, 成立: $\|T^n v_0 - v\| \leq \beta^n \|v_0 - v\|$

证明. **Step1: 证明算子 T 将有界连续函数空间映射到自身**

注意到在假设 2.3 和假设 2.4 下, F 和 f 均有界连续, 集合 Γ 是非空、紧值和连续的。因此, 对任意 $f \in C(X), x \in X$, 如下问题:

$$Tf(x) = \max_{y \in \Gamma(x)} [F(x, y) + \beta f(y)]$$

等价于在紧集 $\Gamma(x)$ 上最大化一个连续函数, 从而最大值必能取到。同时, 由于 F 和 f 均有界, 从而 Tf 有界。最后, 由最大化定理 (定理 2.10), Tf (即定理中的函数 h) 连续。从而证明了: $T: C(X) \rightarrow C(X)$ 。

Step2: 利用 Blackwell 条件, 证明算子 T 是压缩映射

Blackwell 充分条件 (定理 2.5) 的前提: 定义了上确界范数的有界函数空间, 显然 $C(X)$ 符合。接着验证两个条件:

(1) 单调性:

令 $f, h \in C(X), f \leq h$, 对 f 应用算子 T :

$$Tf(x) = \max_{y \in \Gamma(x)} [F(x, y) + \beta f(y)]$$

对 $\forall x \in X$, 令 $g(x; f)$ 为达到最大值的 y 的集合:

$$g(x; f) \equiv \{y \in \Gamma(x) | Tf(x) = F(x, y) + \beta f(y)\}$$

由于: $f(y) \leq h(y), \forall y \in \Gamma(x)$ 从而:

$$Tf(x) = F(x, g(x; f)) + \beta f(g(x; f)) \leq F(x, g(x; f)) + \beta h(g(x; f)), \forall x \in X$$

注意到:

$$F(x, g(x; f)) + \beta h(g(x; f)) \leq \max_{y \in \Gamma(x)} [F(x, y) + \beta h(y)] = Th(x), \forall x \in X$$

因此有: $Tf(x) \leq Th(x), x \in X$, 即 T 满足单调性。

(2) 折扣性:

对任意 $f \in C(X)$:

$$\begin{aligned} T(f+a)(x) &= \max_{y \in \Gamma(x)} [F(x, y) + \beta(f(y) + a)] \\ &= \max_{y \in \Gamma(x)} [F(x, y) + \beta(f(y))] + \beta a \end{aligned}$$

即: $T(f+a)(x) = T(f)(x) + \beta a, \quad f \in C(X)$ 。

因此, 算子 T 符合 Blackwell 充分条件, 从而是 $C(X)$ 上的压缩映射。

Step3: 应用压缩映射定理

我们已经证明, 定义了上确界范数的有界连续函数空间 $C(X)$ 是完备空间。因此由压缩映射定理 (定理 2.4) 立得后两条结论。 $\square$

定理 2.11 是说明值函数存在和唯一性的关键一步, 它表明:

(1) 对于形如式 (2.16) 的泛函问题 (FE) $v(x) = \max_{y \in \Gamma(x)} [F(x, y) + \beta v(y)]$: 不动点存在且唯一;

(2) 数值解法的合理性: 给定一个初始猜测, 通过迭代算子 T 可以收敛到不动点。

回顾定理 2.7: 满足特定有界条件的 FE 问题的解 v 就是 SP 问题的解 v^* (上确界函数)。根据这一最优性原理: 在定理 2.11 的假设下, 满足一般化 FE 问题式 (2.16): $v(x_t) = F(x_t, x_{t+1}) + \beta v(x_{t+1}), t = 0, 1, 2, \dots$ 的唯一有界连续函数 v 就是对应序列问题 (SP) 的上确界函数。也就是说, 在假设 2.3 和假设 2.4 下, 定理 2.7 和定理 2.11 共同证明: 上确界函数有界并且连续。

回顾定理 2.9: 满足 $v^*(x_t^*) = F(x_t^*, x_{t+1}^*) + \beta v^*(x_{t+1}^*), t = 0, 1, 2, \dots$ 和特定有界性条件的任意序列是一个最优计划。因此, 结合定理 2.9 和定理 2.11 可知, 至少存在一个最优计划: 由非空对应 G 产生的任意计划是最优的。

2.4.4 值函数与策略函数的性质

在相关规范化假设下 (如 F 的单调性、凹性等), 结合上面的论证, 我们可以总结出如下性质:

性质 2.1 值函数 v 存在且唯一; 任给初始函数, 通过迭代贝尔曼算子, 可以收敛至值函数 v 。

证明. 由定理 2.11 立得。 $\square$

引理 2.2 令 (S, d) 为完备度量空间, 令 $T: S \rightarrow S$ 是不动点 $v \in S$, 那么:

- 若 S' 是 S 的闭子集, 且 $T(S') \subseteq S'$, 则有 $v \in S'$;

- 若 $T(S') \subseteq S'' \subseteq S'$, 则有 $v \in S''$ 。

性质 2.2 值函数 v 严格递增、严格凹并且对应的决策规则 g 是单值函数。

证明. 这两条结论均可由压缩映射的性质得到。直观的证明思路是：假设初始函数 v_0 具有严格递增且严格凹的性质，并且在迭代过程中贝尔曼算子保留这些性质，从而极限（不动点处）也会保留这些性质。

先证明单调性：对贝尔曼方程：

$$v(x) = \max_{y \in \Gamma(x)} [F(x, y) + \beta v(y)], \forall x \in X$$

令 $f \in C(X)$, 令 $x < x'$, 从而有：

$$\begin{aligned} Tf(x) &= \max_{y \in \Gamma(x)} [F(x, y) + \beta f(y)] \\ &\leq \max_{y \in \Gamma(x')} [F(x, y) + \beta f(y)] \\ &< \max_{y \in \Gamma(x')} [F(x', y) + \beta f(y)] = Tf(x') \end{aligned}$$

也就是说，算子 T 将有界连续函数映射到严格增的函数空间上。记 $C'(X)$ 为 X 上的有界连续非减函数空间，令 $C''(X) \subset C'(X)$ 是有界连续严格增函数空间。那么，由于 T 将 $f \in C'(X)$ 映射到 $Tf \in C''(X)$ ，从而不动点 $v = Tv \in C''(X)$ ，即值函数 v 严格增。

下面证明凹性：令 $x \neq x'$, $x_\theta = \theta x + (1 - \theta)x'$, $\theta \in (0, 1)$ ；令 $y \in \Gamma(x)$ 使得 $Tf(x) = F(x, y) + \beta f(y)$ ；类似的，令 $y' \in \Gamma(x')$ 使得 $Tf(x') = F(x', y') + \beta f(y')$ ，从而有：

$$\begin{aligned} Tf(x_\theta) &\geq F(x_\theta, y_\theta) + \beta f(y_\theta) \\ &> \theta[F(x, y) + \beta f(y)] + (1 - \theta)[F(x', y') + \beta f(y')] \\ &= \theta Tf(x) + (1 - \theta)Tf(x') \end{aligned}$$

即 Tf 严格凹。与上面类似，记 $C'(X)$ 为有界连续凹函数空间，令 $C''(X) \subset C'(X)$ 是有界连续严格凹函数空间。那么，由于 T 将 $f \in C'(X)$ 映射到 $Tf \in C''(X)$ ，从而不动点 $v = Tv \in C''(X)$ ，即值函数 v 严格凹。

又由于 F 关于 y 严格凹，可行集 $\Gamma(x)$ 为凸集，根据最大化定理可知存在唯一 $y = g(x)$ 达到最大值。□

性质 2.3 策略函数 g 单调递增。

证明. 由一阶条件式 (2.4):

$$-\mathcal{F}_2(x, x') = \beta v'(x')$$

由于 $\mathcal{F}(x, x')$ 关于第二个变量严格凹, 因此左侧关于 x' 递增; 由于 v 是凹的, 因此右侧关于 x' 严格递减。又由于右侧独立于 x , 左侧关于 x 递增, 因此决策规则 $x' = g(x)$ 关于 x 递增。□

2.5 最优增长模型的稳态

在上一章, 我们并未像分析索洛模型那样对 RCK 模型的稳态进行分析。在本节, 我们对其存在性和特征进行研究。

定义 2.10 (稳态) 如果 $\bar{k}$ 满足: $\bar{k} = g(\bar{k})$, 则称 $\bar{k}$ 为一个稳态 (Steady State)。

定理 2.12 (稳态存在性) 确定性最优增长模型存在唯一非零稳态。在稳态下, 资本存量 $k = \bar{k}$, 其中 $\bar{k}$ 满足:

$$1 = \beta [f'(\bar{k}) + 1 - \delta]$$

也即:

$$f'(\bar{k}) - \delta = \rho \equiv \frac{1}{\beta} - 1 \quad (2.18)$$

其中 ρ 被称为时间贴现因子 (time discount rate)。这一等式也就是黄金率 (Golden Rule), 它表明: 稳态时储蓄的社会回报等于储蓄的社会成本 (时间贴现因子)。

证明. 首先注意到, RCK 模型存在唯一的最大可行资本存量 k_u : 若资本存量从低于或等于 k_u 开始, 那么未来它不可能超过 k_u 。原因在于: 对任意状态 k , $f(k) + (1 - \delta)k$ 是 k' 的最大可行值, 而根据 f 单调递增和凹性, $f(k_u) + (1 - \delta)k_u = k_u$ 存在严格正的 k_u 和 0 两个解, 从而我们可以将关注点缩小到有界闭集 $[0, k_u]$ 上。

由 RCK 模型的欧拉泛函条件式 (2.13), 在任意非零稳态时必定成立:

$$u'(\gamma(\bar{k}) - g(\bar{k})) = \beta u'(\gamma(\bar{k}) - g(g(\bar{k}))) (f'(\bar{k}) + 1 - \delta)$$

由 $u' > 0$ 和 $\bar{k} = g(\bar{k})$, 若稳态存在必然成立:

$$\beta (f'(\bar{k}) + 1 - \delta) = 1$$

根据 f 单调递增和凹性, 上式存在唯一非零解, 即存在唯一非零稳态。□

性质 2.4 (稳态时 $\bar{k}$ 的决定) 稳态时的资本存量 $\bar{k}$ 关于 ρ 和 δ 都递减。

证明. 由式 (2.18) 立得. □

接下来, 我们对稳态的全局或局部稳定性进行研究。

定理 2.13 (全局稳定性) 稳态是全局稳定的, 并且转移路径是单调的: 当 $k_0 \in (0, \bar{k})$, 资本路径逐渐递增至 $\bar{k}$; 当 $k_0 > \bar{k}$, 资本路径逐渐递减到 $\bar{k}$ 。

证明. 由值函数的凹性, 下式成立:

$$[v'(k) - v'(g(k))] [k - g(k)] \leq 0, \forall k \in [0, k_u]$$

包络定理表明:

$$v'(k) = u'(f(k) + (1 - \delta)k - g(k)) [f'(k) + (1 - \delta)]$$

贝尔曼方程在最优处的一阶条件表明:

$$v'(g(k)) = u'(f(k) + (1 - \delta)k - g(k)) \frac{1}{\beta}$$

因此左侧第一个中括号可以表示为:

$$v'(k) - v'(g(k)) = u'(f(k) + (1 - \delta)k - g(k)) \left[f'(k) + 1 - \delta - \frac{1}{\beta} \right]$$

从而有:

$$u'(f(k) + (1 - \delta)k - g(k)) \left[f'(k) + 1 - \delta - \frac{1}{\beta} \right] [k - g(k)] \leq 0, \forall k \in [0, k_u] \quad (2.19)$$

由稳态的特征: (1) 当 $k = \bar{k}$, $f'(k) + 1 - \delta = \frac{1}{\beta}$ 和 $k = g(k)$ 成立; (2) 当 $k < \bar{k}$, 根据 f 的凹性有 $f'(k) + 1 - \delta > \frac{1}{\beta}$, 由式 (2.19) 可知 $g(k) > k$, 即资本逐渐上升; (3) 反之当 $k > \bar{k}$, 根据 f 的凹性有 $f'(k) + 1 - \delta < \frac{1}{\beta}$, 由式 (2.19) 可知 $g(k) < k$, 即资本逐渐递减。又结合策略函数 g 是递增的, 因此系统是全局稳定的, 单调收敛到稳态 $\bar{k}$ 。□

2.6 数值解法初步: 值函数迭代

在大多数情形下, 我们都无法得到动态规划问题的解析解, 只能对其进行逼近。整体层面看, 求解思路可以分为全局解和局部解: 前者主要基于数值逼近, 后者主要基于

稳态附近的泰勒展开。局部算法虽然速度较快，但其准确度和适用范围相对欠缺，例如当经济偏离稳态或受到较大冲击是，局部算法可能不再有效。因此我们将先把精力集中于数值方法或者说全局算法。

事实上，模型解法的分类是多样的，更细致层面看，全局算法也可分为基于值函数和策略函数的方法。本节将先介绍最基本的**值函数迭代方法** (Value Function Iteration, VFI) 及其改进，这是由压缩映射定理保证的；在下一节，我们将**进一步基于策略函数** (欧拉方程) 来求解 RCK 模型；最后，本章将介绍**投影法** (Projection) 中**配置算法** (Collocation Method) 的实现 (事实上 VFI 本身就是一种特殊的投影法)。

2.6.1 值函数迭代基本算法

考虑如下一般形式的优化问题：个体通过决定控制变量的路径 $\{y_t\}_{t=0}^{\infty}$ 来最大化其未来回报 $u(y_t, x_t)$ 之和，

$$v(x_t) = \max_{\{y_{t+s} \in \mathbb{D}(x_{t+s})\}_{s=0}^{\infty}} \sum_{s=0}^{\infty} \beta^s u(y_{t+s}, x_{t+s})$$

其中， β 是折现因子， $\mathbb{D}(\cdot)$ 是控制变量的可行集， x_t 是控制变量且运动方程满足：

$$x_{t+1} = h(x_t, y_t), x_0 \text{ 给定}$$

我们已经知道如何将这一问题转化为动态规划形式，并可得到一般化的贝尔曼方程：

$$v(x) = \max_{y \in \mathbb{D}(x)} u(y, x) + \beta v(x') \quad (2.20)$$

以及对应的决策规则 (策略函数)：

$$y = g(x) = \operatorname{argmax}_{y \in \mathbb{D}(x)} u(y, x) + \beta v(x')$$

我们的目标是从 Bellman 方程中解出值函数 v 。在此前，我们以连续逼近法作为引例，证明了值函数的存在与唯一性，并构造了找到贝尔算子不动点的一个算法。简单回忆这一构造流程：

Step 1. 任意挑选一个初始值函数 $v^0(x)$ 作为猜测，例如 $v^0(x) = 0, \forall x$

Step 2. 构造单调递增的值函数序列：对所有 x ，定义：

$$v^{n+1}(x) = \max_{y \in \mathbb{D}(x)} [u(y, x) + \beta v^n(x')], \quad n = 0, 1, \dots$$

我们已经证明了值函数序列 $\{v^n(x)\}$ 是单调递增的, 即 $v^{n+1} = Tv^n \geq v^n$; 并且利用压缩映射定理证明了不动点 $v = Tv$ 的存在性, 进而也就从算法层面证明了上述步骤最终会收敛。³ 用数学语言表述的话, 计算贝尔曼方程解的直观方法是迭代算子 T 直至 v^{n+1} 和 v^n 距离足够小。具体而言, 迭代所得的序列满足:

- $\{v^j(x)\}_{j=0}^{\infty}$ 收敛至动态规划问题的真实解 $v(x)$;
- 值函数序列与真实解 $v(x)$ 的距离以一个常数速率越来越小: $\|v^{n+1} - v\| \leq \beta \|v^n - v\|$ 。

在实践中, 计算机并不能存储连续的 (无限维) 函数, 因此要先对连续的状态变量空间等进行离散化 (Discretation)。下方给出了利用值函数迭代求解贝尔曼方程的基本算法:

算法: 值函数迭代

输入: 模型参数 (折现率、折旧率、风险偏好等); 算法参数 (格点维数、停止准则等)

输出: 值函数 v 和策略函数 g

1. 初始化:

将状态变量 x 的取值空间离散化为格点:

$$\mathbb{X} = \{x_1 < x_2 < \cdots < x_i < \cdots < x_N\}$$

设定迭代次数 $iter = 0$, 猜测初始值函数向量 $v^0(x)$

$$[v^0(x_1), v^0(x_2), \cdots, v^0(x_i), \cdots, v^0(x_N)]'$$

选择停止准则 $\varepsilon > 0$

2. 求解贝尔曼方程右侧:

对任意 $x_i \in \mathbb{X}$, $i = 1, \cdots, x_N$, 计算最大化后 (迭代后) 的值函数:

$$v^{iter+1}(x_i) \equiv v_i^{iter+1} = \max_{x'} u(y(x_i, x'), x_i) + \beta v^{iter}(x')$$

记录并更新与之对应的策略函数:

$$g(x_i) \equiv g_i = \arg\max_j u(y(x_i, x'), x_i) + \beta v^{iter}(x')$$

3. 检验停止准则:

³Blackwell 充分条件对单调性做出了要求, 这是构造单例序列的原因。

若 $\|v^{iter+1}(x) - v^{iter}(x)\| < \varepsilon$ ，则进行停止迭代，输出值函数和策略函数；否则回到第 2 步。

由于贝尔曼算子是压缩映射，上述过程一定会收敛。同时，我们可以记录下了与 x_i 相对应的最优的 $y = g(x_i)$ ，进而也就得到了策略函数。我们称上述过程为**值函数迭代**。为了加深理解，下方给出一个确定性 RCK 模型的示例及相应代码。

例 2.5 值函数迭代求解 RCK：假设效用函数形式为：

$$u(c) = \frac{c^{1-\sigma} - 1}{1 - \sigma}$$

资本积累方程为：

$$k' = f(k) - c + (1 - \delta)k = k^\alpha - c + (1 - \delta)k$$

由消费和资本的非负性，贝尔曼方程为：

$$\begin{aligned} v(k) &= \max_{0 \leq c \leq k^\alpha + (1-\delta)k} \frac{c^{1-\sigma} - 1}{1 - \sigma} + \beta v(k') \\ &= \max_{0 \leq k' \leq k^\alpha + (1-\delta)k} \frac{(k^\alpha + (1 - \delta)k - k')^{1-\sigma} - 1}{1 - \sigma} + \beta v(k') \end{aligned}$$

我们希望求解出值函数和策略函数。

首先，将资本 k 的取值空间离散化为 n_k 维格点：

$$\mathbb{K} = \{k_1 < \dots < k_{n_k}\}$$

设定迭代次数 $iter = 0$ ，猜测在这些格点上取值的 n_k 维初始值函数向量：

$$v^0(k) = \left[v_1^0 = v_{k_1}^0, v_2^0, \dots, v_i^0 = v^0(k_i), \dots, v_n^0 = v_{k_{n_k}}^0 \right]'$$

选择算法的停止准则 $\varepsilon > 0$ 。

接着，对每一个 $i = 1 \dots, n_k$ ，计算当前第 $iter$ 次迭代中可行 j 下的：

$$v_{ij} \equiv \frac{(k_i^\alpha + (1 - \delta)k_i - k_j)^{1-\sigma} - 1}{1 - \sigma} + \beta v^{iter}(k_j)$$

这里要特别注意可行 j 的概念：消费的非负性和最大值对下期资本可行集的范围做出

了限制，即：

$$0 \leq k' \leq k^\alpha + (1 - \delta)k$$

进而限定了下期资本可选的脚标 j 下界和上界。就下界而言，可以通过选择合适的格点 k_1 使得 $j = 1$ ；就上界而言，假设取值格点是均匀分布的，即

$$k_h = k_1 + (h - 1)d_k, \quad h = 1, \dots, n_k$$

其中 d_k 是间隔，从而对任意当前格点 k_i ，可以由上式和资本取值范围计算与之对应的下期资本脚标 j 的上界（由于格点递增，这相当于给定当前 k_i ，找到保证消费非负的最大下期资本的取值）：

$$\begin{aligned} k_j &\equiv k_1 + (j - 1)d_k \leq k_i^\alpha + (1 - \delta)k_i \\ &\Leftrightarrow \\ j &\leq \frac{k_i^\alpha + (1 - \delta)k_i - k_1}{d_k} + 1 \end{aligned}$$

由于格点脚标是正整数并且最大为 n_k ，因此有：

$$\bar{j} = \min\{\text{floor}(\frac{k_i^\alpha + (1 - \delta)k_i - k_1}{d_k}) + 1, n_k\}$$

从而可以得到：

$$v_{ij}^* = \max_{j=1, \dots, \bar{j}} v_{ij} = \max_{j=1, \dots, \bar{j}} \frac{(k_i^\alpha + (1 - \delta)k_i - k_j)^{1-\sigma} - 1}{1 - \sigma} + \beta v^{iter}(k_j)$$

即完成了任意给定当前资本存量 k_i 下的一次迭代，可设定：

$$v^{iter+1}(k_i) = v_{ij}^*$$

并记录下对应的最优脚标 $j^* = \operatorname{argmax}_{j=1, \dots, \bar{j}} v_{ij}$ ，也即策略函数：

$$k'(k_i) = k_{j^*}$$

最后，计算误差，若 $\|v^{iter+1}(k) - v^{iter}(k)\| < \varepsilon$ ，停止迭代；否则令迭代次数 $iter + 1$ 并返回上一步。直至收敛。下面给出了对应的 Matlab 代码。

```
1 clear ; clc ;
```

```

2    %% setup
3    % economic parpam
4    alpha = 0.3;
5    sigma = 1.5;
6    beta = 0.95;
7    delta = 0.1;
8
9    ks = ((1-beta*(1-delta)) / (alpha*beta))^(1/(alpha-1));
10   csy = 1-alpha*beta*delta/(1-beta*(1-delta));
11
12   % numerical param
13   nk = 1000;
14   epsilon = 1e-6;
15   dev = 0.9;
16
17   % discretize k
18   kmin = (1-dev)*ks;
19   kmax = (1+dev)*ks;
20   dk = (kmax-kmin)/(nk-1);
21   kgrid = linspace(kmin,kmax,nk)';
22
23   %% iteration on bellman operator
24   % initialize
25   error = 1;
26   %v = zeros(nk,1);    % value function
27   v = ((csy*kgrid.^alpha).^(1-sigma)-1)./((1-sigma)*(1-beta));
28   tv = zeros(nk,1);
29   g = zeros(nk,1);    % decision rule: index
30   iter = 1;
31
32   % iteration
33   tic
34   while error > epsilon
35   for i = 1:nk
36       % compute min index for next period k
37       jmin = max(ceil(((1-delta)*kgrid(i)-kmin)/dk)+1,1);
38       % compute max index for next period k because consumption>0
39       tmp = kgrid(i)^alpha + (1-delta)*kgrid(i) - kmin;
40       jmax = min(floor(tmp/dk)+1, nk);
41
42       % all possible to be compared: (jmax-jmin)*1 dimension
43       c = kgrid(i)^alpha + (1-delta)*kgrid(i) - kgrid(jmin:jmax);

```

```

44     u = (c.^(1-sigma)-1) / (1-sigma);
45
46     % bellman operator: 用 itmp 是因为 v 的 index 从 1 而不是 jmin 开始
47     [tv(i),jtmp] = max(u + beta*v(jmin:jmax));
48     g(i) = jmin-1+jtmp;
49 end
50 error = max(abs(tv-v));
51 v = tv;
52 iter = iter + 1;
53 end
54 toc
55
56 %% solution
57 kprime = kgrid(g); % policy function
58 c = kgrid.^alpha + (1-delta)*kgrid - kprime;

```

在上述代码中，设定了取 $n_k = 1000$ 个格点来代表资本 k 的取值空间，设定对稳态上下偏离 90% 作为格点的最大和最小值，用时 4.8 秒。图 2.1 绘制了由 VFI 得到的值函数和策略函数，它具备前文所证明的相关性质。




图 2.1: 值函数与策略函数

2.6.2 改进值函数迭代：插值

上述方法的潜在问题之一是：真实下期最优资本存量未必在我们设定的格点上，我们也就无法得到值函数在这些实际位置的取值。一个改进思路是利用插值法对值函数进行估计。将状态变量格点取得相对宽松，而将控制变量格点取得较为精细，这样可减少对函数的估计次数，从而降低运算时间。对如下形式的贝尔曼方程：

$$v(x) = \max_{y \in \mathbb{D}(x)} u(y, x) + \beta v(x')$$

改进算法如下：

算法：改进值函数迭代

输入：模型参数（折现率、折旧率、风险偏好等）；算法参数（格点维数、停止准则等）

输出：值函数 v 和策略函数 g

1. 离散化状态变量和控制变量：

将状态变量 x 的取值空间离散化为较宽松的 N 个格点：

$$\mathbb{X} = \{x_1 < x_2 < \cdots < x_i < \cdots < x_N\}$$

将控制变量 y 的取值空间离散化为较为精细的 M 个格点：

$$\mathbb{Y} = \{y_1 < y_2 < \cdots < y_i < \cdots < y_M\}, \quad M \gg N$$

设定迭代次数 $iter = 0$ ，猜测初始值函数向量 $v^0(x)$

$$[v^0(x_1), v^0(x_2), \cdots, v^0(x_i), \cdots, v^0(x_N)]'$$

选择停止准则 $\varepsilon > 0$

2. 求解贝尔曼方程右侧：

对任意 $x_i \in \mathbb{X}$, $i = 1, \cdots, N$ ，根据运动方程计算下期状态：

$$x'_{ij} = h(y_j, x_i), \quad \forall j = 1, \cdots, M$$

利用插计算值函数在 $x'_{ij} = h(y_j, x_i)$ 处，当前迭代下的值函数取值 $\tilde{v}^{iter}(x'_{ij})$ ，据此求

解贝尔曼方程右侧：

$$v^{iter+1}(x_i) \equiv v_i^{iter+1} = \max_{y \in \mathbb{Y}} u(y, x_i) + \beta \tilde{v}^{iter}(x'_{ij})$$

3. 检验停止准则：

若 $\|v^{iter+1}(x) - v^{iter}(x)\| < \varepsilon$ ，则进行停止迭代，输出值函数和策略函数；否则回到第 2 步。

```

1  %% setup
2  % economic param
3  alpha = 0.3;
4  sigma = 1.5;
5  beta = 0.95;
6  delta = 0.1;
7
8  ks = ((1-beta*(1-delta)) / (alpha*beta))^(1/(alpha-1));
9  csy = 1-alpha*beta*delta/(1-beta*(1-delta));
10
11 % numerical param
12 nk = 20;
13 nc = 1000;
14 epsilon = 1e-6;
15 dev = 0.9;
16
17 % discretize k
18 kmin = (1-dev)*ks;
19 kmax = (1+dev)*ks;
20 kgrid = linspace(kmin,kmax,nk)';
21
22 % discretize c
23 cmin = 0.01;
24 cmax = kmax^alpha;
25 cgrid = linspace(cmin,cmax,nc)';
26
27 %% iteration on bellman operator
28 % initialize
29 error = 1;
30 v = ((csy*kgrid.^alpha).^(1-sigma)-1)./(1-sigma); % value function
31 tv = zeros(nk,1);
32 g = zeros(nk,1); % decision rule: index

```

```

33     u = (cgrid.^(1-sigma)-1) / (1-sigma);
34     iter = 1;
35
36     % iteration
37     tic
38     while error > epsilon
39     for i = 1:nk
40         % all possible kp when ki now: nc*1 dimension
41         kp = kgrid(i).^alpha + (1-delta)*kgrid(i) - cgrid;
42         % interp one函数用于正在kp处插值: nc*1 dimension
43         vinterp1 = interp1(kgrid,v, kp, 'spline');
44
45         % bellman operator
46         [tv(i),g(i)] = max(u+beta*vinterp1);
47     end
48     error = max(abs(tv-v));
49     v = tv;
50     iter = iter + 1;
51 end
52 toc
53
54 %% solution
55 c = cgrid(g);
56 % kprime = kgrid(g);
57 kprime = kgrid.^alpha+(1-delta)*kgrid-c;

```

用时仅 0.05 秒。

2.6.3 值函数迭代的改进:

2.6.4 投影法的初步实现: 配置算法

2.6.5 Euler Based Methods

3 数值方法

确定性最优增长模型结构简单，并且状态变量维度很低，只有资本存量 k ，前面的迭代和逼近方法都能快速求解。但是，量化宏观模型状态变量的维度通常较高，可能包含多个外生冲击或内生状态变量，部分异质性个体模型可能还涉及无穷维的分布作为状态，这些都会带来维度诅咒（Curse of Dimensionality），导致基础的值函数迭代方法消耗大量计算时间，甚至不收敛等问题；同时，对于较为复杂的模型，基础的函数逼近的平滑估计方法也面临可靠性下降的风险。因此，必须对数值方法进行更进一步的学习，来解决这些麻烦。

本章将从随机最优增长模型开始，引出模型中计算条件期望的难点，并在马尔可夫假设下引出 AR(1) 过程的离散化方法，以解决这一难题；其次，我们将介绍更为灵活和一般化的数值积分方法来处理期望的问题；接着，转变思路，直接从值函数入手解决问题：先介绍函数逼近方法，在此基础上着重研究投影方法的理论和应用；最后，对其他常用算法进行介绍。

3.1 引例：随机最优增长

本节对随机最优增长模型（Stochastic Optimal Growth Model / Stochastic Neoclassical Growth Model）进行介绍。一方面，自 Brock and Mirman（1972）首次将随机 TFP 冲击引入计划者问题，将其作为宏观变量内生波动的解释后，随机最优增长模型就逐渐成为几乎所有经济周期模型的基本框架。另一方面，以随机最优增长作为引例，我们将说明外生冲击和高维状态给模型计算带来的难点，并初步窥探相应数值方法的运用。

3.1.1 基本概念与模型设定

在确定性最优增长中，给定期初资本存量，生产函数是确定的，代表性家庭（计划者）面临的资源约束为：

$$c_t + k_{t+1} \leq f(k_t) + (1 - \delta) k_t$$

随机最优增长模型与确定性模型的核心区别在于生产函数面临**随机事件**（Stochastic




图 3.1: 随机事件树

Event) 给生产率带来的不确定性, 资源约束形式为:

$$c_t(s^t) + k_{t+1}(s^t) \leq z_t(s^t) f(k_t(s^{t-1})) + (1 - \delta) k_t(s^{t-1}), \quad \forall s^t$$

其中, 称 $s_t \in S$ 是 t 时刻实现的一个随机事件, S 是随机过程的状态空间 (或称为支撑), 称 $s^t \equiv (s_0, s_1, \dots, s_t) = (s^{t-1}, s_t)$ 为至 t 时刻已经实现的事件的**历史**。举例来看, 假设 $s_t \in \{0, 1\}$, 例如 $s_t = 1$ 对应高生产率的 z , $s_t = 0$ 对应低生产率的 z 。图 3.1 给出了这一情形下 (即 $S = \{0, 1\}$) 随机事件可能的展开路径。从 $t = 0$ 时刻看, 时刻 t 时历史 s^t 实现的**无条件概率**为 $\pi_t(s^t)$; 对 $t > \tau$, s^t 实现的**条件概率**为 $\pi_t(s^t | s^\tau)$ 。

不失一般性, 假设 s_t 在离散空间上取值。从而模型中代表性家庭 (计划者) 偏好可写为:¹

$$\begin{aligned} U &= \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u(c_t(s^t)) \pi_t(s^t) \\ &= \mathbb{E}_0 \sum_{t=0}^{\infty} \beta^t u(c_t) \end{aligned} \tag{3.1}$$

¹为了形式的方便, 我们通常使用 $\mathbb{E}_0$ 表示基于零时刻给定状态 z_0 下的期望效用

3.1.2 序列问题和状态依存计划

在确定性问题中，家庭的最优选择一个**确定性的序列**；而在随机问题中，家庭的最优选择依赖于随机过程 z_t ，因此选择的消费和资本序列 $\{c_t(z^t)\}_{t=0}^{\infty}$, $\{k_{t+1}(z^t)\}_{t=0}^{\infty}$ 也是随机过程，通常我们将其称为**状态依存计划** (Contingent Plans)。我们将先利用序列方法求解状态依存计划的最优条件。

在序列问题下，家庭将概率序列 $\pi_t(s^t)$ 视为给定，选择消费和资本序列来最大化自身期望效用式 (3.1)：

$$\max_{\{c_t(s^t), k_{t+1}(s^t)\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u(c_t(s^t)) \pi_t(s^t)$$

资源约束为：

$$c_t(s^t) + k_{t+1}(s^t) \leq z_t(s^t) f(k_t(s^{t-1})) + (1 - \delta) k_t(s^{t-1}), \quad \forall s^t \quad (3.2)$$

非负性约束为：

$$c_t(s^t), k_{t+1}(s^t) \geq 0, \quad \forall s^t$$

其中第 0 期的资本 k_0 和状态 s_0 给定，即 $\pi_0(s_0) = 1$ 。记与资源约束相关的拉格朗日乘子为 $\lambda_t(s^t)$ ，则拉格朗日函数为：

$$\begin{aligned} \mathcal{L} = & \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u(c_t(s^t)) \pi_t(s^t) \\ & + \sum_{t=0}^{\infty} \sum_{s^t} \lambda_t(s^t) [z_t(s^t) f(k_t(s^{t-1})) + (1 - \delta) k_t(s^{t-1}) - c_t(s^t) - k_{t+1}(s^t)] \end{aligned}$$

容易得到，关于 $c_t(s^t)$ 的一阶条件为：

$$\beta^t \pi_t(s^t) u'(c_t(s^t)) = \lambda_t(s^t) \quad (3.3)$$

关于 $k_{t+1}(s^t)$ 的一阶条件为：

$$\lambda_t(s^t) = \sum_{s^{t+1}|s^t} \lambda_{t+1}(s^{t+1}) [z_{t+1}(s^{t+1}) f'(k_{t+1}(s^t)) + (1 - \delta)] \quad (3.4)$$

这里的一个关键点在于：当前 $k_{t+1}(s^t)$ 的选择会影响 $t+1$ 时刻基于 s^t 的所有可能的 s^{t+1} 下的生产，反映为求和符号下的 $s^{t+1} | s^t$ 。结合两个一阶条件，可以写出**随机形式的消费**

欧拉方程：

$$u'(c_t(s^t)) = \beta \sum_{s^{t+1}|s^t} \pi_{t+1}(s^{t+1} | s^t) u'(c_{t+1}(s^{t+1})) [z_{t+1}(s^{t+1}) f'(k_{t+1}(s^t)) + (1 - \delta)] \quad (3.5)$$

其中条件概率 $\pi_{t+1}(s^{t+1} | s^t) = \pi_{t+1}(s^{t+1}) / \pi_t(s^t)$ 。因此，方程右侧是一个**条件期望**，我们习惯将其写为：

$$u'(c_t) = \beta \mathbb{E}_t \{u'(c_{t+1}) [z_{t+1} f'(k_{t+1}) + (1 - \delta)]\} \quad (3.6)$$

注意 $\mathbb{E}_t$ 是一个**条件期望符号**，表示我们在 $\{s^{t+1} | s^t\}$ 上求和（或积分），也可以将其理解为基于 t 时刻信息的期望。

3.1.3 递归形式下的随机最优增长

为了数值求解的方便，我们希望进一步写出递归形式的模型。但是我们需要进行一些假设，来避免历史依赖带来的计算问题。一个自然的想法是假设 TFP 冲击具有**马尔可夫性**。对于具有马尔可夫性的随机过程，给定当前状态，未来状态的分布只依赖于当前而不依赖历史，即

$$\Pr(s_{t+1} | s_t, s_{t-1}, \dots, s_{t-l}) = \Pr(s_{t+1} | s_t), \quad \forall k \geq 1 \quad \forall t \quad (3.7)$$

我们将在下一节详细学习马尔可夫过程的性质与模型的求解。现在我们继续讨论递归形式下的最优条件与随机动态规划（Stochastic Dynamic Programming）。

在递归形式下，模型通过选择合适的**状态变量**来追踪经济的历史事件，习惯上我们可以省去随机事件历史 s^t 符号。给定当前 TFP 水平为 z ，记 $\pi(z' | z)$ 为下期 z' 发生的概率。对计划者问题，有如下贝尔曼方程：²

$$v(k, z) = \max_{k'} \left[u(zf(k) + (1 - \delta)k - k') + \beta \sum_{z'} v(k', z') \pi(z' | z) \right] \quad (3.8)$$

在确定性最优增长中，我们建立了序列方法和递归方法解的等价性。但是，对于随机最优增长，递归问题写出的贝尔曼方程右侧是条件于当前对**下一期**的期望，而序列问题下实际是条件于当前对**更远的未来**的期望。在此情形下，解的等价性还成立吗？答案是肯定的。原因很直观：递归问题中贝尔曼方程右侧的 $v(z', k')$ 是一个随机变量，它又包含着 $\mathbb{E}[(z'', k'') | z']$ （依次类推），而由迭代期望定律，这一项等价于条件于当前的 z ，

²对连续过程，第二项可以写为积分： $\beta \int v(k', z') \pi(z' | z) dz'$

即 $\mathbb{E}[(z'', k'') | z]$ 。同理，对 $v(z', k')$ 包含的所有未来状态下的值函数都成立。也就是说，虽然形式上看，递归问题只是对下一期的条件期望，但实际上它也包含着更远的未来，只不过这一未来不是条件于当前而是基于其前一期的，而迭代期望定律的存在使得其与条件于当前等价。因此，两种形式的解仍然等价。

回到贝尔曼方程，对下期资本求解一阶条件可得：

$$u'(zf(k) + (1 - \delta)k - k') = \beta \sum_{z'} \pi(z' | z) v_k(z', k') \quad (3.9)$$

包络定理表明：

$$v_k(z, k) = u'(zf(k) + (1 - \delta)k - k') (zf'(k) + (1 - \delta)) \quad (3.10)$$

从而我们可以得到递归形式下的欧拉泛函：

$$\begin{aligned} & u'(zf(k) + (1 - \delta)k - k') \\ &= \beta \sum_{z'} \pi(z' | z) \{u'(z'f(k') + (1 - \delta)k' - k'') [z'f'(k') + (1 - \delta)]\} \end{aligned} \quad (3.11)$$

将消费的定义代入并利用条件期望符号可将欧拉泛函写为如下常见形式：

$$u'(c_t) = \beta \mathbb{E}_t \{u'(c_{t+1}) [z_{t+1}f'(k_{t+1}) + (1 - \delta)]\}$$

它对所有 (z, k) 组合都成立，并且隐式地定义了计划者问题的解（策略函数）：

$$k' = g(k, z)$$

3.1.4 数值求解难点

对于离散时间下的动态规划，整体上可以分为两种类型：离散动态规划（Discrete Dynamic Programming）和连续动态规划（Continuous Dynamic Programming）——这里的离散和动态是针对状态变量和控制变量的取值空间而言的。我们的精力主要集中于后者，因为其在宏观模型中更为普遍，同时我们目前所接触的模型也属于这一范围。连续动态规划的计算求解整体有**两种思路**：

一是**离散化估计**（Discrete Approximation）：这与之前 VFI 的思路相近，通过离散化状态变量和控制变量空间，在一定范围的格点上寻找最优值。实际上，相当于将连续规划转化为离散规划。

二是**平滑估计**（Smooth Approximation）：类似于此前的 Collocation 方法，思路是

使用连续或平滑函数直接近似值函数或策略函数。这一方法更快速，但不如离散化可靠。我们将在函数逼近和投影法章节中重点介绍相关理论。

无论选取何种方法，在求解模型过程中的**主要难点**都可概括如下：

一是高维状态带来复杂的计算量：相比确定性最优增长模型，随机最优增长的关键点在于 TFP 冲击 z_t ，这一要素和资本存量 k_t 都是模型的状态变量。如果采用此前的 VFI 方法，那么离散化工作就要在两个维度上进行，由此产生的不同 (k, z) 的组合数量呈指数增长。

二是最优化或求根问题：在实际处理贝尔曼方程时，贝尔曼算子要求寻找方程右侧的最大值。在一些复杂问题中，计算机自带的函数无法完成这一工作，只能通过相关算法寻找最优点。此外，许多时候最优化问题可以转化为求根问题。

三是处理条件期望：在确定性模型中，值函数迭代过程包含了对于最优 k' 的选取（一个最大化的过程），然后能够得到更新后的值函数；但在随机模型中，对于贝尔曼方程右侧的条件期望，我们并不清楚下期 TFP 水平 z' 的取值。如果外生过程天然服从马尔科夫链，那么可以直接利用转移概率矩阵简化期望。不过更一般的情况是，外生冲击服从连续过程，例如 AR(1)，并非一个离散的马尔科夫链，导致原始贝尔曼方程右侧包含一个积分：

$$v(k, z) = \max_{k'} \left[u(zf(k) + (1 - \delta)k - k') + \beta \int v(k', z') \pi(z' | z) dz' \right]$$

实际上，处理贝尔曼方程右侧条件的期望（积分）是经常遇到的一般化问题，主要有两种处理办法：**一是利用马尔可夫过程的性质离散化 AR(1) 的状态空间：**用有限维马尔科夫链及其转移概率矩阵近似 AR(1) 过程，简化右侧的条件期望，然后通过离散化估计方法（如值函数迭代）求解。**二是数值积分：**这是更为灵活的积分计算方法，在特定的格点和权重下用求和形式近似右侧的积分。

需要强调：**离散化估计和平滑估计是求解动态规划的总体思路；而马尔可夫近似和数值积分则是具体的计算方法。**为了更清晰的领会相应难点，考虑用 VFI 求解如下例子：对随机最优增长框架，假设冲击 z_t 服从两状态马尔科夫链，状态空间为 $\{H = 1.015, L = 0.985\}$ 。两种状态间从状态 i 转移到状态 j 的概率为 π_{ij} , $i, j = H, L$ ，其中： $\pi_{HH} = \pi_{LL} = 0.95$, $\pi_{LH} = \pi_{HL} = 0.05$ ，以行为当前状态，以列为下一期状态，我们可以将其表示为如下转移矩阵：

$$P = \begin{pmatrix} 0.95 & 0.05 \\ 0.05 & 0.95 \end{pmatrix}$$

代码。。。耗时。。。。

从下一节开始，我们将展开对数值求根方法和最优化算法的介绍，这是用代码实现数值求解的基础；接着，我们会介绍马尔可夫过程，将其引入随机最优增长模型，这是

为处理条件期望所作的准备；然后，我们将针对离散化估计和平滑估计的进行学习：先介绍离散化估计：首先，学习如何将马尔科夫链可以用于近似连续 AR(1) 过程，进而将积分转化为以转移概率矩阵为权重的求和；接着，我们将学习数值积分方法，它同样用求和近似积分，但是是在特定节点和权重下的求和，并且未必与马尔可夫近似等同；在介绍完离散化估计后，我们将介绍平滑估计方法：先学习所需要的函数逼近理论，之后重点研究投影法的应用。此外，本章还将对一些其他重要算法进行介绍。

3.2 求根方法

本节对随机最优增长模型（Stochastic Optimal Growth Model / Stochastic Neoclassical Growth Model）进行介绍。一方面，自 Brock and Mirman (1972) 首次将随机 TFP 冲击引入计划者问题，将其作为宏观变量内生波动的解释后，随机最优增长模型就逐渐成为几乎所有经济周期模型的基本框架。另一方面，以随机最优增长作为引例，我们将说明外生冲击和高维状态给模型计算带来的难点，并初步窥探相应数值方法的运用。

3.3 数值优化

本节对随机最优增长模型（Stochastic Optimal Growth Model / Stochastic Neoclassical Growth Model）进行介绍。一方面，自 Brock and Mirman (1972) 首次将随机 TFP 冲击引入计划者问题，将其作为宏观变量内生波动的解释后，随机最优增长模型就逐渐成为几乎所有经济周期模型的基本框架。另一方面，以随机最优增长作为引例，我们将说明外生冲击和高维状态给模型计算带来的难点，并初步窥探相应数值方法的运用。

3.4 马尔可夫过程与条件期望

本节对马尔可夫过程理论进行讲解，并将其引入随机最优增长。我们曾指出，处理连续动态规划的总体思路主要有离散化估计和平滑估计，例如 VFI 和 Collocation，但无论选取何种方法，**计算的主要难点之一**都在于期望（积分）的计算。之所以先对马尔可夫过程进行学习，原因就在于它在两种方法中都发挥着重要作用：**它决定了条件期望的结构仅依赖当前状态。**

定义 3.1 随机过程（Stochastic Process）是某一**随机变量**（Random Variable） z_t 构成的时间序列 $\{z_t\}_{t=0}^{\infty}$ 。若 z_t 的**状态空间** $\mathcal{Z}$ 是有限或可数的，则称这一随机过程是离散取值的。

定义 3.2 随机过程 $\{z_t\}_{t=0}^{\infty}$ 被称为**马尔可夫过程**，若对任意 $k \geq 1$ 和任意 t ，成立：

$$\Pr(z_{t+1} \mid z_t, z_{t-1}, \dots, z_{t-k}) = \Pr(z_{t+1} \mid z_t)$$

即条件于当前 z_t ，未来独立于历史 z^{t-1} 。如果上述概率不依赖于时间 t ，则称这一马尔可夫过程是**时间齐次的**。

定义 3.3 **马尔科夫链** (Markov Chain) 是离散取值的马尔可夫过程，即状态空间 $\mathbb{Z}$ 可数或有限。

我们将主要考虑时间齐次的马尔可夫链。为了记号的方便，同时不失一般性，假设随机变量 z_t 的取值空间 $\mathbb{Z} = \{z_1, z_2, \dots, z_n\}$ 。³ 通常， n 维马尔可夫链可用三元符号 $(\mathbb{Z}, \pi_0, \mathbf{P})$ 表示。其中：

(1) **状态空间** $\mathbb{Z} = (z_1, z_2, \dots, z_n)'$ 是包含状态所有可能取值的 n 维列向量；

(2) **初始分布** $\pi_0 = (\pi_{01}, \pi_{01}, \dots, \pi_{0n})'$ 是一个 n 维列向量，其元素 $\pi_{0i} = \Pr(s_0 = s_i)$ 表示初始状态 $z_0 = z_i$ ，满足 $\sum_{i=1}^n \pi_{0i} = 1$ 。在应用中，通常选定某一 i ，使 $\pi_{0i} = 1$ ，即从确定的初始状态 z_i 开始。

(3) **转移概率矩阵** $\mathbf{P}$ 具有如下形式：

$$\mathbf{P} = \begin{pmatrix} p_{11} & p_{12} & \cdots & \vdots & \cdots & p_{1n} \\ p_{21} & & & \vdots & & \vdots \\ \vdots & & & \vdots & & \vdots \\ p_{i1} & \cdots & \cdots & p_{ij} & \cdots & p_{in} \\ \vdots & & & \vdots & & \vdots \\ p_{n1} & \cdots & \cdots & \vdots & \cdots & p_{nn} \end{pmatrix}$$

满足：

$$\sum_{j=1}^n p_{ij} = 1 \quad 0 \leq p_{ij} \leq 1 \quad \forall i$$

这一矩阵也被称为**随机矩阵** (Stochastic Matrix)。矩阵中的代表元素 (i, j) 元 p_{ij} 是一个条件概率，表示：

$$p_{ij} = \Pr(z_{t+1} = z_j \mid z_t = z_i)$$

³通常我们用大写字母如 Z_t 表示随机变量，用小写字母如 z_t 表示样本的实现。这里是为了记号的方便以及与随机增长模型中一致，我们使用小写的 z_t 表示随机变量

3.4.1 转移路径与概率分布的运动方程

马尔科夫链假设能够极大简化模型转移路径的计算。给定转移概率矩阵 $\mathbf{P}$ ，我们可以计算 $m = 1, 2, 3, \dots$ 步内从状态 z_i 转移到状态 z_j 的概率。例如，对 2 步转移：

$$\begin{aligned} \Pr(z_{t+2} = z_j \mid z_t = z_i) &= \sum_{k=1}^n \Pr(z_{t+2} = z_j \mid z_{t+1} = z_k) \Pr(z_{t+1} = z_k \mid z_t = z_i) \\ &= \sum_{k=1}^n p_{kj} p_{ik} = \sum_{k=1}^n p_{ik} p_{kj} \\ &= p_{ij}^{(2)} \end{aligned}$$

其中 $p_{ij}^{(2)}$ 表示两步转移概率矩阵 $\mathbf{P}^2 = \mathbf{P}\mathbf{P}$ 的 (i, j) 元。容易验证若 $\mathbf{P}$ 是一个转移概率矩阵，则 $\mathbf{P}$ 的 m 次幂 $\mathbf{P}^m$ 也是一个转移概率矩阵。一般而言， $\mathbf{P}^m$ 的 (i, j) 元不一定等于 $\mathbf{P}$ 的 (i, j) 元的 m 次方，即 $p_{ij}^{(m)} \neq (p_{ij})^m$ 。进一步归纳后不难得到：

$$\Pr(z_{t+m} = z_j \mid z_t = z_i) = p_{ij}^{(m)} \quad (3.12)$$

其中右侧表示 m 步转移概率矩阵 $\mathbf{P}^m$ 的 (i, j) 元。更一般化的，我们有如下查普曼-柯尔莫哥洛夫方程（Chapman-Kolmogorov Equation）：

$$\begin{aligned} \mathbf{P}^{m+k} &= \mathbf{P}^k \mathbf{P}^m \\ \Leftrightarrow \\ p_{ij}^{(m+k)} &= \sum_{r=1}^n p_{ir}^{(k)} p_{rj}^{(m)} \end{aligned} \quad (3.13)$$

令 n 维列向量 $\boldsymbol{\pi}_t = (\pi_{t,1}, \dots, \pi_{t,n})'$ 表示随机变量 z_t 其状态空间 $\mathcal{S}$ 上的无条件概率分布，其中的元素：

$$\pi_{t,i} = \Pr(z_t = z_i), \quad i = 1, \dots, n$$

由转移概率可得上述概率分布随时间的变化：

$$\begin{aligned}
 \pi_{1,i} &= \sum_{j=1}^n \Pr[z_1 = \mathbb{Z}_i \mid z_0 = \mathbb{Z}_j] \Pr[z_0 = \mathbb{Z}_j] = \sum_{j=1}^n \Pr[z_1 = \mathbb{Z}_i \mid z_0 = \mathbb{Z}_j] \pi_{0,j} \\
 &\vdots \\
 \pi_{t,i} &= \sum_{j=1}^n \Pr[z_t = \mathbb{Z}_i \mid z_{t-1} = \mathbb{Z}_j] \Pr[z_{t-1} = \mathbb{Z}_j] = \sum_{j=1}^n \Pr[z_t = \mathbb{Z}_i \mid z_{t-1} = \mathbb{Z}_j] \pi_{t-1,j} \\
 \pi_{t+1,i} &= \sum_{j=1}^n \Pr[z_{t+1} = \mathbb{Z}_i \mid z_t = \mathbb{Z}_j] \Pr[z_t = \mathbb{Z}_j] = \sum_{j=1}^n \Pr[z_{t+1} = \mathbb{Z}_i \mid z_t = \mathbb{Z}_j] \pi_{t,j}
 \end{aligned}$$

以矩阵形式表示，可得概率分布的运动方程（Law of Motion）为：

$$\begin{aligned}
 \pi'_1 &= \pi'_0 P \\
 \pi'_2 &= \pi'_1 P = \pi'_0 P^2 \\
 &\vdots \\
 \pi'_t &= \pi'_{t-1} P = \pi'_0 P^t
 \end{aligned}$$

从而有：

$$\pi_{t+1} = P' \pi_t = (P')^{t+1} \pi_0 \quad (3.14)$$

3.4.2 平稳分布

定义 3.4 稳态/平稳分布（Stationary Distribution）是指满足如下条件的一个无条件概率分布：

$$\pi_{t+1} = \pi_t$$

根据概率分布的运动方程3.14，平稳分布必须满足：

$$\pi = P' \pi \quad (3.15)$$

等价于：

$$(I - P') \pi = 0 \quad (3.16)$$

这表明：平稳分布 π 是矩阵 P' 对应特征值为 1 的特征向量（正则化使 $\sum_{i=1}^n \pi_i = 1$ ）。

定义 3.5 P, π 被称为平稳马尔科夫链，若分布 π 满足3.15式。

事实上， P 是随机矩阵（元素非负并且 $\sum_1^n p_{ij} = 1$ ）保证了 P 至少有一个特征根

为 1，进而至少有一个特征向量 π 是平稳分布。但是，平稳分布可能不唯一，因为可能有重复为 1 的特征根。确保平稳分布唯一的一个充分条件是： $0 < p_{ij} < 1, \forall i, j$ 。

例 3.1 考虑一个两状态马尔科夫链，转移矩阵为：

$$\mathbf{P} = \begin{bmatrix} 1-p & p \\ q & 1-q \end{bmatrix}$$

平稳分布 $\pi = (\pi^1, \pi^2)'$ 是如下方程的解：

$$\left[\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} - \begin{pmatrix} 1-p & q \\ p & 1-q \end{pmatrix} \right] \begin{pmatrix} \pi^1 \\ \pi^2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

可以解得：

$$\begin{pmatrix} \pi^1 \\ \pi^2 \end{pmatrix} = \begin{pmatrix} \frac{q}{p+q} \\ \frac{p}{p+q} \end{pmatrix}$$

不难看出，当 $q \rightarrow 0$ ，状态 2 会吸收状态 1。

有时，我们也会考虑连续支撑上的马尔可夫过程，此时原有概率分布的概念相应变为了概率密度。假设 z_t 的概率密度为 $\pi_t(z)$ ，根据转移方程有：

$$\pi_{t+1}(z') = \int p(z' | z) \pi_t(z) dz$$

其中， $p(z' | z)$ 是条件于 $z_t = z$ 下 $z_{t+1} = z'$ 的概率密度。平稳的概率密度函数 $\pi(z)$ 满足如下不动点条件：

$$\pi(z') = \int p(z' | z) \pi(z) dz$$

例 3.2 假设 $\{z_t\}$ 是一个线性高斯 AR(1) 过程：

$$z_{t+1} = (1 - \rho)\mu + \rho z_t + \sigma \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \text{iid } N(0, 1)$$

那么：

$$p(z' | z) = \frac{1}{\sigma} \phi \left(\frac{z' - (1 - \rho)\mu - \rho z}{\sigma} \right)$$

其中, $\phi(\varepsilon)$ 是标准正态分布的概率密度函数:

$$\phi(\varepsilon) \equiv \frac{1}{\sqrt{2\pi}} e^{-\varepsilon^2/2}$$

若 $|\rho| < 1$, 那么存在唯一的平稳概率密度:

$$\pi(z) = \frac{\sqrt{1-\rho^2}}{\sigma} \phi\left(\sqrt{1-\rho^2} \frac{(z-\mu)}{\sigma}\right)$$

3.4.3 马尔可夫假设下的随机最优增长

在马尔可夫假设下, z_t 服从一个一阶马尔可夫过程, 条件概率(密度)为 $\pi(z' | z)$, 这使得未来不依赖于众多可能的历史而只依赖于当前, 进而我们可以写出递归形式的随机最优增长:

$$v(k, z) = \max_{k'} \left[u(zf(k) + (1-\delta)k - k') + \beta \int v(k', z') \pi(z' | z) dz' \right]$$

不难得到欧拉泛函为:

$$u'(zf(k) - k') = \beta \int u'(z'f(k') - k'') z' f'(k') \pi(z' | z) dz'$$

我们指出它隐式地定义了动态规划问题的策略函数 $k' = g(k, z)$ 。形式上, 我们可以写出:

$$k_{t+1} = g(k_t, z_t)$$

现在, 只从模型性质分析的角度出发, 我们面临的一个问题是: $\{k_t\}$ 未必收敛至某一稳态, 那么 k 的分布是怎样的?

假设策略函数具有乘积形式, 即 $k_{t+1} = z_t g(k_t)$, 并且 z_t 随时间是独立同分布的, 因此可记累积分布函数为:

$$H(z) \equiv \Pr[z_t \leq z]$$

接下来考虑 t 时刻资本 k 的累计分布函数:

$$\Psi_t(k) \equiv \Pr[k_t \leq k]$$

例如，对 $t = 1$ ：

$$\begin{aligned}\Psi_1(k) &= \text{Prob}[k_1 \leq k] \\ &= \text{Prob}[z_0 g(k_0) \leq k] = \text{Prob}\left[z_0 \leq \frac{k}{g(k_0)}\right] \\ &= H\left(\frac{k}{g(k_0)}\right)\end{aligned}$$

记 $P(k' | k)$ 为条件分布：

$$P(k' | k) \equiv \text{Prob}[k_{t+1} \leq k' | k_t = k]$$

在独立同分布的假设下，可以得到：

$$P(k' | k) = H\left(\frac{k'}{g(k)}\right)$$

资本 k 的累计分布函数 $\Psi(\cdot)$ 的运动方程为：

$$\Psi_{t+1}(k') = \int P(k' | k) d\Psi_t(k)$$

用概率密度函数 $\psi(\cdot)$ 表示这一运动方程，则有：

$$\psi_{t+1}(k') = \int p(k' | k) \psi_t(k) dk$$

平稳概率密度是这一运动方程的不动点，即：

$$\psi(k') = \int p(k' | k) \psi(k) dk$$

更一般的来说，由策略函数 $k' = g(k, z)$ 和外生冲击的条件密度函数 $\pi(z' | z)$ ，可以得到状态 (k, z) 的联合分布（Joint Distribution）的运动方程，我们希望找到其不动点。

马尔可夫性的另一个好处是简化了模型中条件期望的计算，因为它使得下期状态只依赖于当前而不依赖于历史。例如，假设随机过程 $\{z_t\}_{t=0}^{\infty}$ 是一个马尔科夫链，取值空间为 $\mathbf{z} = (z_1, z_2, \dots, z_n)'$ 。那么给定 $z_t = z_i$ ， z_{t+1} 的条件期望为：

$$\mathbb{E}(z_{t+1} | z_t = z_i) = \mathbf{P}_i \mathbf{z} \quad (3.17)$$

其中， $\mathbf{P}_i$ 为转移概率矩阵 $\mathbf{P}$ 的第 i 行（即条件于当前状态为 z_i ）。对于随机最优增长模

型，假设 z_t 服从一个 n 维马尔可夫链，取值空间同上。给定 $k = k_m$, $z = z_i$ ，对值函数 $v(k_m, z_i)$ ，利用转移概率可以直接写出如下贝尔曼方程：

$$\begin{aligned} v(k_m, z_i) &= \max_{k'} u[zf(k_m) + (1 - \delta)k_m - k'] + \beta \mathbb{E}[v(k', z') \mid z = z_i] \\ &= \max_{k'} u[zf(k_m) + (1 - \delta)k_m - k'] + \beta \mathbf{P}_i v(k', \mathbf{z}) \end{aligned}$$

其中 $v(k', \mathbf{z})$ 是一个 n 维列向量，每行对应下期 z' 在空间 $\mathbf{z}$ 上可能的取值 $(z_1, \dots, z_n)$ ， $\mathbf{P}_i$ 则是转移矩阵的第 i 行，它表示条件于当前 TFP 状态为 z_i 。

我们可以将其写为更为紧凑的矩阵形式。记 $v(k_m, \mathbf{z})$ 是 n 维值函数，每行对应 TFP 的一种可能状态下的最优值。令 $\vec{\mathbf{1}}$ 是元素全部为 1 的 n 维列向量， $\mathbf{z}'$ 表示下期的 n 维列向量，从而有：

$$\begin{aligned} v(k_m, \mathbf{z}) &= \max_{k'} u[\mathbf{z}f(k_m) + \vec{\mathbf{1}}(1 - \delta)k_m - \vec{\mathbf{1}}k'] + \beta \mathbb{E}[v(k', \mathbf{z}') \mid \mathbf{z}] \\ &= \max_{k'} u[\mathbf{z}f(k_m) + \vec{\mathbf{1}}(1 - \delta)k_m - \vec{\mathbf{1}}k'] + \beta \mathbf{P} v(k', \mathbf{z}) \end{aligned}$$

3.5 马尔可夫近似与离散化估计

我们已经初步了解了马尔可夫性质对于条件期望结构的关键作用——使未来的分布只依赖于当前。截至目前，我们基本都是在离散空间上研究马尔可夫过程和贝尔曼方程，但我们曾指出，多数情形下外生冲击服从连续过程，即我们求解的是连续动态规划问题。对此我们也提出了两种总体思路：离散化估计和平滑估计。但无论选择何种总体思路，主要的难点都是处理连续的 AR(1) 过程，或者说计算积分。本节，我们将学习如何利用马尔可夫性近似 AR(1) 过程，并将其运用于离散化估计的整体框架。下一节我们将介绍另一种处理条件期望的方法：数值积分。

如果选择离散化估计处理动态规划，并且想要在期望（积分）计算中直接利用马尔可夫性质，这就要求离散化后的外生过程服从马尔可夫链，并且需要找到对应的转移概率矩阵。因此，对于外生过程的离散化并不像离散化资本那样简单。假设一个典型的 AR(1) 冲击形式如下：

$$z_{t+1} = (1 - \rho)\mu + \rho z_t + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \text{IID } N(0, \sigma_\varepsilon^2) \quad (3.18)$$

其中， μ 为 z_t 的无条件均值， $\rho \in (0, 1)$ 。不失一般性，令 $\mu = 0$ 。 ε_t 互相独立，服从均值为 $\mathbb{E}[\varepsilon_{t+1}] = 0$ 、方差为 $\text{Var}[\varepsilon_{t+1}] = \sigma_\varepsilon^2$ 的正态分布，即：

$$\Pr[\varepsilon \leq u] = F(u/\sigma_\varepsilon)$$

其中 $F(\cdot)$ 是标准正态分布函数。显然, z_t 的无条件方差为:

$$\sigma_z^2 = \frac{1}{1 - \rho^2} \sigma_\varepsilon^2$$

我们的目标是: 构建一个状态空间为 $\{z^i\}_{i=1}^N$ 、转移矩阵为 $\pi = (\pi_{ij})$ 的马尔科夫链, 使其能较好的近似原有的连续 AR(1) 过程。其中 N 为格点数量, 取值越大, 那么近似越精确。简言之, 用马尔科夫链将连续的 AR(1) 过程离散化。目前, 已经发展了许多不同技巧来实现这一目标, 我们简要介绍如下几种重要和常见的方法。

3.5.1 TauChen (1986) 方法

TauChen (1986) 的方法通过如下三步将连续 AR(1) 过程离散化为马尔可夫链:

Step 1. 构造具有 N 个等距格点的离散空间:

$$(z^i)_{i=1}^N = \left\{ z_{\min}, z_{\min} + \frac{z_{\max} - z_{\min}}{N-1}, \dots, z_{\min} + \frac{N-2}{N-1} (z_{\max} - z_{\min}), z_{\max} \right\}$$

其中:

$$z_{\min} = -m\sigma_z, \quad z_{\max} = m\sigma_z$$

m 反映了这一估计能够覆盖的取值范围, 通常取 3 或者 4 就足够。

Step 2. 根据格点找到 N 个区间:

$$\begin{aligned} I_1 &= \left(-\infty, z_{\min} + \frac{z_{\max} - z_{\min}}{2(N-1)} \right) \\ I_2 &= \left(z_{\min} + \frac{z_{\max} - z_{\min}}{2(N-1)}, z_{\min} + \frac{3(z_{\max} - z_{\min})}{2(N-1)} \right), \dots, \\ I_{N-1} &= \left(z_{\min} + \frac{(2N-5)(z_{\max} - z_{\min})}{2(N-1)}, z_{\min} + \frac{(2N-3)(z_{\max} - z_{\min})}{2(N-1)} \right), \\ I_N &= \left(z_{\min} + \frac{(2N-3)(z_{\max} - z_{\min})}{2(N-1)}, \infty \right) \end{aligned}$$

Step 3. 依据正态概率分布函数, 计算 z_t 落入相应区间的概率作为转移概率, 即:

$$\pi_{ij} = \Pr(z_{t+1} \in I_j \mid z_t = z^i)$$

具体看, 若记格点的间距为 ω , 那么通过计算 z_t 落入相应区间 $[z^j - \omega/2, z^j + \omega/2]$ ($j = 2, \dots, N-1$) 的概率以及落入两端的概率 (小于 $z^1 + \omega/2$ 对应 $j = 1$, 大于 $z^N - \omega/2$

对应 $j = N$), 可得转移矩阵元素 π_{ij} 为:

$$\pi_{ij} = \begin{cases} F\left(\frac{\bar{z}^1 - \rho\bar{z}^i + \omega/2}{\sigma_\varepsilon}\right) & \text{for } j = 1 \\ F\left(\frac{\bar{z}^j - \rho\bar{z}^i - \omega/2}{\sigma_\varepsilon}\right) - F\left(\frac{\bar{z}^j - \rho\bar{z}^i + \omega/2}{\sigma_\varepsilon}\right) & \text{for } j = 2, \dots, N-1 \\ 1 - F\left(\frac{\bar{z}^j - \rho\bar{z}^i - \omega/2}{\sigma_\varepsilon}\right) & \text{for } j = N, \end{cases}$$

3.5.2 Rouwenhorst 方法

TauChen (1986) 的方法简单方便, 但是也有学者指出, 当 ρ 接近 1 时, 这一近似不够准确。与此同时, 在宏观经济中, 许多外生冲击的自回归系数实际是很接近 1 的, 因此如下的 Rouwenhorst (1995) 近似方法受到推崇。我们在此介绍这一方法的一个特例, 实现步骤如下:

Step 1. 与 TauChen (1986) 相同, 构造具有 N 个等距格点的离散空间:

$$(z^i)_{i=1}^N = \left\{ z_{\min}, z_{\min} + \frac{z_{\max} - z_{\min}}{N-1}, \dots, z_{\min} + \frac{N-2}{N-1}(z_{\max} - z_{\min}), z_{\max} \right\}$$

其中:

$$z_{\min} = -m\sigma_z, \quad z_{\max} = m\sigma_z$$

但是此处 m 不能任意取值。

Step 2. 递归构建 $N \times N$ 维马尔可夫矩阵 Π_N :

- 对 $N = 2$, 取:

$$\Pi_2 = \begin{bmatrix} p & 1-p \\ 1-p & p \end{bmatrix}$$

- 对 $N \geq 3$, 先构建 $N \times N$ 维矩阵:

$$\begin{aligned} \Pi_N = & p \begin{bmatrix} \Pi_{N-1} & \mathbf{0} \\ \mathbf{0}' & 0 \end{bmatrix} + (1-p) \begin{bmatrix} \mathbf{0} & \Pi_{N-1} \\ 0 & \mathbf{0}' \end{bmatrix} \\ & + p \begin{bmatrix} \mathbf{0}' & 0 \\ \Pi_{N-1} & \mathbf{0} \end{bmatrix} + (1-p) \begin{bmatrix} 0 & \mathbf{0}' \\ \mathbf{0} & \Pi_{N-1} \end{bmatrix} \end{aligned}$$

Step 3. 正则化: 将除了第一行和最后一行的矩阵元素全部除以 2, 从而保证每行的行和为 1。

对于 p 和 m , 可以设定如下: 取 $p = (1 + \rho)/2$ 和 $m = \sqrt{N-1}$ 。通过上述过程, 可

以证明所构造的马尔科夫链的无条件均值和无条件方差与原始 AR(1) 过程的相同。这一方法只用到了均值和方差的信息以及当 $N \rightarrow \infty$ 时马尔可夫过程的不变分布收敛至正态分布。当 ε_{t+1} 服从正态分布、真实 ρ 接近 1 时，这一方法较为有效。

3.5.3 Tauchen-Hussey (1991) 方法

这一方法与 Gauss-Hermite 数值积分方法有关，我们在此简要介绍，同时作为数值积分的一个引例。假设我们要计算条件期望：

$$E[v(z') | z] = \int_{-\infty}^{\infty} v(z') f(z' | z) dz'$$

其中 $f(\cdot | z)$ 是给定 $z_t = z$ 下 z_{t+1} 的条件密度。利用 Gauss-Hermite 方法，⁴ 我们可以对这一积分进行如下估计：

$$\int v(z') f(z' | z) dz' \simeq \pi^{-1/2} \sum_{j=1}^N \omega_j v(\sqrt{2\sigma}x_j + \rho z)$$

其中， x_j 和 ω_j 是 Gauss-Hermite 结点和权重。这一近似方法的问题在于，它连续地依赖取值于 z 。TauChen 和 Hussey (1991) 提出了如下变换：

$$\int v(z') f(z' | z) dz' = \int v(z') \frac{f(z' | z)}{f(z' | 0)} f(z' | 0) dz' = \frac{1}{\sqrt{\pi}} \sum_{j=1}^N w_j v(z^j) \frac{f(z^j | z)}{f(z^j | 0)}$$

其中 $z^j = \sqrt{2\sigma}x_j$ 。进而可得：

$$E[v(z') | z^i] \simeq \sum_{j=1}^N \tilde{\pi}_{ij} v(z^j), \quad \tilde{\pi}_{ij} = \pi^{-1/2} w_j \frac{f(z^j | z^i)}{f(z^j | 0)}$$

由于此时可能出现：

$$\sum_{j=1}^N \tilde{\pi}_{ij} \neq 1$$

因此可以进行正则化：

$$\pi_{ij} = \frac{\tilde{\pi}_{ij}}{\sum_{j=1}^N \tilde{\pi}_{ij}}$$

⁴我们将在后面介绍这一数值积分方法。

并做如下估计：

$$E[v(z') | z^i] \simeq \sum_{j=1}^N \pi_{ij} v(z^j)$$

需要注意这里并不是积分的 **Gauss-Hermite** 估计。当 N 足够大时， $\sum_{j=1}^N \tilde{p}_{ij}$ 收敛到 1。因此，我们可以用取值空间为 $\{z^1, z^2, \dots, z^N\}$ 、转移矩阵为 (π_{ij}) 的马尔可夫链近似 AR(1) 过程。

3.5.4 求解离散化的随机最优增长

离散化后求和仍有 V ，可以通过离散化后 VFI，也可作为后面函数逼近和 Projection 的引入，即用函数逼近 V

3.6 数值积分

即使有了离散化，直接计算条件期望可能仍然有困难，例如，如果我们希望保留 z_t 的取值空间作为连续的支撑，

事实上，虽然数值积分没有使用马尔可夫性去离散化外生过程，但这一性质在条件期望的计算中仍然发挥了基础性的作用，因为几分钟变量的演变不依赖于历史

如果使用马尔可夫链近似 AR(1) 过程，马尔可夫性质将在期望计算中发挥直接作用；即使是使用数值积分算法，它仍然依赖状态变量的马尔可夫性质：对未来的积分只依赖于当前。

换句话说，虽然数值积分与马尔可夫近似不等同，但缺少马尔可夫性质，数值积分也很难进行。这也正是我们始终强调宏观模型中马尔可夫性的原因。

3.7 Function Approximation

截至目前，无论是基于马尔可夫链离散化 AR(1) 过程计算积分还是直接数值积分，其后续求解步骤中，都是基于值函数迭代的方法继续进行，因为即便有了积分的数值算法，我们仍然对值函数的形式一无所知。回顾我们在第一章最后介绍的配置算法，它通过直接逼近值函数进行求解。事实上，在随机模型中，这一方法也是适用的，在本节，我们详细介绍函数逼近的基本理论，为下一节投影方法奠定基础。

3.8 Projection Methods

我们已经详细了解了值函数逼近的主要理论，现在，我们可以通过选定基函数逼近值函数，再配合离散化 AR(1) 或数值积分方法，避免值函数迭代的缺点。通常我们称这一方法为投影法或。。。法。先看一个简单的例子。

3.9 EGM

4 完备市场理论与宏观经济学中的均衡

目前为止，我们都是从计划者（Social Planner）角度和代表性家庭（同质家庭）的假设下处理最优增长模型。在计划者问题中，计划者能够直接配置资源而不需要通过市场调节，因此价格并没有显示出现在优化问题中。那么，计划者问题中的均衡能通过**市场配置**或者说**价格机制**实现吗？即：如果经济是分散的（Decentralized Economy），存在家庭和企业等在市面上的互动，如何定义经济中的均衡，价格在其中起到什么作用？这一（竞争）均衡产生的配置有什么特征，和计划者问题中的均衡配置有什么关系？前一章动态规划和递归的框架能在定义均衡中起到什么作用？代表性家庭的设定又为什么具有合理性？

回答上述问题离不开宏观经济学中的一个重要理论：完备市场（Complete Market）理论。首先，本章将介绍完备市场理论中两种基础市场结构：**阿罗-德布鲁市场**和**序贯市场**；其次，研究这两种市场下的竞争均衡与计划者问题（帕累托问题）均衡的关系；同时，我们将指出这两种均衡定义方式的不足，并应用递归的思想定义递归竞争均衡；再次，应用完备市场理论讨论代表性家庭的存在性和资本资产定价问题；最后，将相关均衡概念应用于一个分散经济下的最优增长模型，通过具体例子深入分析。

4.1 完备市场理论基础

4.1.1 经济环境设定

经济的时间是离散且无穷的： $t = 0, 1, \dots, \infty$ 。在每一期，都有一个**随机事件**（Stochastic Event）实现，记为：

$$s_t \in S$$

通常我们将其称之为**状态**（State）。集合 S 是所有可能发生的事件的集合。记截至 t 时刻，所有实现事件的历史（History）为：

$$s^t = (s_0, s_1, \dots, s_t) = (s^{t-1}, s_t)$$

历史 s^t 发生的**无条件概率** (Unconditional Probability) 记为:

$$\pi_t(s^t)$$

对时刻 $t > \tau$, 记在 s^τ 实现的条件下, 观测到 s^t 实现的**条件概率** (Conditional Probability) 为:

$$\pi_t(s^t | s^\tau)$$

在本章, 我们始终假设交易在观测到 s_0 的实现后进行, 也就是说: $\pi_0(s_0) = 1$ 。此外, 我们暂时无需假设马尔可夫性。

经济中有 I 个个体 (消费者), 标记为 $i = 1, \dots, I$ 。个体 i 获得的随机禀赋为 $y_t^i(s^t)$, 这一禀赋依赖于实现的事件历史 s^t , 同时历史 s^t 是公共可观测的。个体 i 选择历史依赖的消费计划 (History-Dependent Consumption Plan):

$$c^i \equiv \{c_t^i(s^t)\}_{t=0}^\infty$$

个体 (消费者) i 的偏好为:

$$\begin{aligned} U_i(c^i) &\equiv \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u_i(c_t^i(s^t)) \pi_t(s^t) \\ &= \mathbb{E}_0 \sum_{t=0}^{\infty} \beta^t u_i(c_t^i) \end{aligned} \tag{4.1}$$

其中, $\mathbb{E}_0$ 是基于 s_0 的**条件期望**。注意这里效用函数除了其自变量的下标不同, 我们同时允许不同个体效用函数本身结构的差异, 即效用函数具有下标, 即 u_i , 但所有个体的效用 u_i 都符合相关规范化假设, 同时假设二次可微性。此外, 假设个体间分享概率 $\pi_t(s^t)$ 的信息, 即可以不使用记号 π_t^i 。经济中的**可行配置** (Feasible Allocation) 满足资源约束:

$$\sum_i c_t^i(s^t) = \sum_i y_t^i(s^t), \quad \text{all } t, s^t \tag{4.2}$$

4.1.2 两种交易结构

完备市场是宏观经济学中的重要概念, 它与**不完备市场**的主要区别在于: 经济中存在足够多的如状态依存合约等金融工具 (数量覆盖未来所有可能的状态数), 个体通过交易这些工具构建资产组合, 进而能够实现任意可行配置, 对冲所有个体风险 (Idiosyncratic Risk)。

定义 4.1 状态依存合约 (State-Contingent Claims) 是一种支付依赖于未来某个事件 (状态) s^t 是否实现的合约。例如如果未来可能发生 {晴天, 下雨} 两种状态, 消费者可以购买下雨时获得 1 单位消费品和晴天时获得 1 单位消费品的合约。

完备市场可以在如下两种经典的市场结构下实现, 我们在此分别介绍。

(1) 阿罗-德布鲁市场 (Arrow-Debreu Market)

在 Arrow-Debreu 结构下, 市场只在 $t = 0$ 时刻开放, 消费者在市场上交易的是对所有未来时刻 $t \geq 1$ 的消费品的索取权 (Complete Set of Contingent Consumption Claims)。这些索取权是状态依存的 (State-Contingent Claims) —— 依赖于截至 t 时所有可能发生的事件历史 s^t , 也被称为阿罗-德布鲁证券 (Arrow-Debreu Security)。在 $t = 0$ 时刻后, 签订的合约生效, 但没有额外交易再发生, 因此这一交易结构也被称为**零时交易** (Time-Zero Trading)。在阿罗-德布鲁市场中, 由于能交易所有未来时间和可能状态下的消费品索取权 (工具足够多), 因此阿罗-德布鲁市场天然满足完备市场的定义。

性质 4.1 阿罗-德布鲁市场天然满足完备的。

(2) 序贯市场 (Sequential Market)

与 Arrow-Debreu 市场不同, 序贯市场中的交易是按期进行的。市场每一期都会重新开放, 但是市场上只存在一种单期状态依存合约 (one-period-ahead state-contingent claims)。在 t 时刻, 交易的范围仅针对已实现的历史 s^t 这一条件下所有可能的 $s^{t+1} = (s^t, s_{t+1})$ 。序贯市场也被称为**阿罗市场** (Arrow Market) 或 Radner 市场, 其中的单期状态依存合约被称为**阿罗证券** (Arrow Securities)。同样, 如果每期都存在足够多的阿罗证券, 可以覆盖下期所有可能状态, 那么序贯市场也可以达到完备。但是, 如果交易工具不足, 则序贯交易可能无法达成完备性。例如我们在后面不完备市场理论中将会看到的, 若经济中仅存在单期无风险债券, 则市场是不完备的。

性质 4.2 序贯市场可以达到动态完备 (Sequentially Complete)。但如果市场中只存在无风险债券, 那么序贯市场是不完备的。

图 4.1 和图 4.2 分别给出了三期情形下一个两状态马尔科夫链在两种市场下的商品空间的例子。随机事件 $s_t \in S = \{0, 1\}$ 。在阿罗-德布鲁市场下 (图 4.1), 站在 $t = 0$ 时刻, $s_0 = 1$ 给定, 截至 $t = 3$ 时刻所有可能的事件历史有 8 种。个体在 $t = 0$ 时对 $t \geq 3$ 时所有 8 个可能节点下的商品索取权进行交易。图 4.2 是在序贯市场下, 截至 $t = 2$ 时刻实现的一个特定历史, 和给定这一实现的历史下, $t = 3$ 时刻的两种可能性。在 $t = 2$, 个体仅能交易在当前历史 $(0, 0, 1)$ 下所能达到的 $t = 3$ 时节点的商品。

两种市场结构对比而言, 阿罗-德布鲁市场更近似一个理论基准, 而序贯交易相对更贴近于现实市场。此外, 对于上述两种市场结构, 我们很自然的会想到如下问题:




图 4.1: 两状态马尔科夫链的阿罗-德布鲁商品空间




图 4.2: 两状态马尔科夫链的阿罗-德布鲁商品空间

- 两种市场中的均衡配置相同吗，与计划者均衡配置有什么关系？
- 消费者的最优配置是否依赖于历史（History-Dependent）？

我们将证明：两种市场交易结构会带来相同的帕累托最优配置，并且在完备市场下， t 时刻的最优消费配置仅依赖部分刻画 $t = 0$ 时刻财富分布的时不变参数和 t 时刻经济所实现的总禀赋，不会依赖带来相应总禀赋的历史。

4.1.3 帕累托问题

在研究上述两种市场均衡配置的特征前，我们希望先定义一个基准配置用于进行比较，一个自然的想法是帕累托最优。帕累托最优是指，无法使一个个体变得更好而同时不使其他个体变得更差。如果一个配置是帕累托最优的，我们称其为有效（efficient）。我们可以通过为计划者解如下帕累托问题（Pareto Problem）找到一个有效配置。

计划者为每个个体 $i = 1, \dots, I$ 选择 $c^i \equiv \{c_t^i(s^t)\}_{t=0}^{\infty}$ 来最大化如下目标：

$$W = \sum_{i=1}^I \lambda_i U_i(c^i) \quad (4.3)$$

其面临的资源约束为：

$$\sum_i c_t^i(s^t) = \sum_i y_t^i(s^t) \quad \forall t, s^t \quad (4.4)$$

其中 λ_i 是非负的帕累托权重（Pareto Weights）。如果一个配置能构成一组非负权重下上述问题的解，我们就称这一配置为帕累托有效（Pareto Efficient）。对这一优化问题，构建拉格朗日函数：

$$\begin{aligned} \mathcal{L} &= \sum_i \lambda_i \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u_i(c_t^i(s^t)) \pi_t(s^t) + \sum_{t=0}^{\infty} \sum_{s^t} \theta_t(s^t) \sum_i [y_t^i(s^t) - c_t^i(s^t)] \\ &= \sum_{t=0}^{\infty} \sum_{s^t} \left\{ \sum_{i=1}^I \lambda_i \beta^t u_i(c_t^i(s^t)) \pi_t(s^t) + \theta_t(s^t) \sum_{i=1}^I [y_t^i(s^t) - c_t^i(s^t)] \right\} \\ &= \sum_i \sum_{t=0}^{\infty} \sum_{s^t} \{ \lambda_i \beta^t u_i(c_t^i(s^t)) \pi_t(s^t) + \theta_t(s^t) [y_t^i(s^t) - c_t^i(s^t)] \} \end{aligned}$$

其中非负的 $\theta_t(s^t)$ 为第 t 期和历史 s^t 对应约束的拉格朗日乘子。从这一优化问题的形式上看，计划者实际面临的是一个静态问题（Static Problem）序列，因为问题中并不涉及跨期变量。具体看，对 $c_t^i(s^t)$ 求解 FOC 得：

$$\lambda_i \beta^t u'_i(c_t^i(s^t)) \pi_t(s^t) = \theta_t(s^t) \quad \forall i, t, s^t \quad (4.5)$$

不失一般性，取个体 i 和个体 1，将他们的 FOC 结合可得：

$$\frac{u'_i(c_t^i(s^t))}{u'_1(c_t^1(s^t))} = \frac{\lambda_1}{\lambda_i} \quad \forall t, s^t \quad (4.6)$$

也即：

$$c_t^i(s^t) = u_i'^{-1} \left(\frac{\lambda_1}{\lambda_i} u'_1(c_t^1(s^t)) \right) \quad (4.7)$$

这意味着任意个体的消费都可以写为关于个体 1 的消费 $c_t^1(s^t)$ 的函数。进一步，将上式代入资源约束4.2可得：

$$\sum_i u_i'^{-1} \left(\frac{\lambda_1}{\lambda_i} u'_1(c_t^1(s^t)) \right) = \sum_i y_t^i(s^t) \equiv Y_t(s^t) \quad \forall t, s^t \quad (4.8)$$

注意到，式4.8是关于 $c_t^1(s^t)$ 的单一非线性方程（Single Nonlinear Equation）。右侧对 i 的求和可以定义为经济的总禀赋，而由于帕累托权重 $\{\lambda_i\}_{i=1}^I$ 是一组给定的参数，因此左侧对 i 求和后也与个体 i 无关，进而可以从中解出 $c_t^1(s^t)$ 。

进一步观察式4.8可知，给定一组外生参数 $\{\lambda_i\}_{i=1}^I$ ， $c_t^1(s^t)$ 只依赖当前实现的总禀赋，既不依赖时刻 t ，也不依赖特定的能够带来当前总禀赋的历史 s^t 或是在 t 时刻个体禀赋的分布。同时，式4.7将 c_t^i 表为了 $c_t^1(s^t)$ 的函数，从而可得其余所有个体的消费配置 $c_t^i(s^t)$ ：同样是只依赖于所实现的总禀赋的。至此，我们就得到了计划者在参数 $\{\lambda_i\}_{i=1}^I$ 下的一个帕累托有效配置，且均衡解的形式是一个时不变函数：

$$c_t^i(s^t) = f(\lambda_i, Y_t; \boldsymbol{\lambda})$$

性质 4.3 对于计划者的帕累托问题，一组有效配置具有如下特征：

- 与时间 t 无关，与历史无关（*history-independent or history-free*）：当前的 Y_t 是所有历史的充分统计量；
- 与 t 时刻个体禀赋的分布无关（*distribution-free*）：只有求和后的 Y_t 重要。

假设存在两条不同历史路径 s^t 和 $\tilde{s}^t$ ，但只要 $Y_t(s^t) = Y_t(\tilde{s}^t)$ ，就有 $c_t^i(s^t) = c_t^i(\tilde{s}^t)$ 。

进一步观察4.6式，对任意两个个体 (i, j) 成立：

$$\frac{u'_i(c_t^i(s^t))}{u'_j(c_t^j(s^t))} = \frac{\lambda_j}{\lambda_i} \quad \forall t, s^t$$

也就是说，在任何有效配置中，个体间消费边际效用比在任意时刻、任意历史下都相等。背后的经济含义是：计划者通过维持不同个体间消费边际效用比来为所有个体在任意时

间和状态下提供**消费保险**（**Consumption Insurance**）。由于计划者问题中除了总的资源约束外不存在其他约束，因此很自然的将这一情形定义为**完美消费保险**（Perfect Consumption Insurance）或**完美风险承担**（Perfect Risk Sharing）。

定义 4.2 完美消费保险（Perfect Consumption Insurance），或称**完美风险承担**（Perfect Risk Sharing），是指一组消费配置 $\{c^i = \{c_t^i(s^t)\}_{t=0}^\infty\}_{i=1}^I$ ：使不同个体间的消费边际效用比在任意时刻、任意状态下都相同（Constant across any time and states）。

至此，我们通过求解计划者的帕累托问题，建立了一个基准均衡配置。这一均衡是帕累托有效的，因为计划者不可能使某一个体变好而不使其他人变差。从计算的角度看：我们通过式4.8解出 $c_t^1(s^t)$ ，再通过式4.7解出其余个体的 $c_t^i(s^t)$ 。并且由式4.7可知：只有不同个体间帕累托权重的比值是值得关注的。因此，我们可以进行正则化，将权重和定为 1： $\sum_i \lambda_i = 1$ 。由于每个个体的消费配置只是总禀赋的函数，因此其个体消费与总禀赋（总消费）完全相关，并且所占份额与其所分配得的帕累托权重相关。

4.2 Arrow-Debreu 市场中的均衡

本节将对第一种完备市场——阿罗-德布鲁市场进行研究。我们在本章开头提出了问题：计划者问题中的帕累托均衡是否能通过**市场配置**或者说**价格机制**实现？我们之前已经介绍了阿罗-德布鲁市场和序贯市场两种市场结构，本节先研究前者，我们将会证明：**帕累托最优可以由 Arrow-Debrue 市场下的一组竞争均衡（Competitive Equilibrium）实现。**

回顾阿罗-德布鲁市场的结构：交易在 $t = 0$ 时发生， s_0 已经实现。消费者只能在 $t = 0$ 时刻购买或售出未来 t 时刻消费品的索取权（阿罗-德布鲁证券），这些权利依历史 s^t 而定（contingent on history s^t ）。记 $q_t^0(s^t)$ 为 $t = 0$ 时交易的阿罗-德布鲁证券的价格。¹。表示约定了在时间 t 和历史 s^t 实现时交割 1 单位消费品的状态依存合约的价格，也称为**阿罗-德布鲁价格**（Arrow-Debreu Price）。经济中总的资源约束仍为：

$$\sum_i c_t^i(s^t) = \sum_i y_t^i(s^t) \quad \forall t, s^t \quad (4.9)$$

个体 i 将价格视为给定，面临预算约束：

$$\sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) c_t^i(s^t) \leq \sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) y_t^i(s^t) \quad (4.10)$$

¹这一记号下，价格的时间脚标 t 和历史 s^t 的时刻一定对应，0 只是提示了交易发生时间，在一些教科书中，也常见 $p_t(s^t)$ 记号，可以用于与后文序贯市场中的价格区分

方程右侧表示零时刻个体 i 未来禀赋的价值（即初始财富），左侧表示其消费在零时刻的价值。需要强调，个体 i 面临的预算约束是**单一**（single）的一个方程。原因在于：在阿罗-德布鲁市场中，所有交易都在零时刻进行。个体 i 的目标是选择 $c^i \equiv \{c_t^i(s^t)\}_{t=0}^{\infty}$ 来最大化自身效用函数：

$$U_i(c^i) = \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u_i[c_t^i(s^t)] \pi_t(s^t) \quad (4.11)$$

记与个体 i 预算约束相关的拉格朗日乘子为 μ_i ，则拉格朗日方程为：

$$\begin{aligned} \mathcal{L} &= \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u_i(c_t^i(s^t)) \pi_t(s^t) + \mu_i \sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) [y_t^i(s^t) - c_t^i(s^t)] \\ &= \sum_{t=0}^{\infty} \sum_{s^t} \{ \beta^t u_i(c_t^i(s^t)) \pi_t(s^t) + \mu_i q_t^0(s^t) [y_t^i(s^t) - c_t^i(s^t)] \} \end{aligned}$$

关于 $c_t^i(s^t)$ 的 FOC 为：

$$q_t^0(s^t) = \beta^t \frac{u_i'(c_t^i(s^t))}{\mu_i} \pi_t(s^t) \quad \forall t, s^t \quad (4.12)$$

在进一步分析求解问题前，我们先介绍与定义均衡有关的几个概念：

定义 4.3 价格系统（Price System）是一组价格函数序列 $\{q_t^0(s^t)\}_{t=0}^{\infty}$

定义 4.4 配置（Allocation） $\{c^i\}_{i=1}^I$ 集成了每个个体 i 的消费函数序列 $c^i = \{c_t^i(s^t)\}_{t=0}^{\infty}$

定义 4.5 阿罗-德布鲁均衡（Arrow-Debreu Equilibrium），也可称为阿罗-德布鲁竞争均衡（Arrow-Debreu Competitive Equilibrium），由满足如下条件的一个价格系统 $\{q_t^0(s^t)\}_{t=0}^{\infty}$ 和一组可行配置 $\{c^i\}_{i=1}^I$ 构成：

- 任意个体 i 将价格系统 $\{q_t^0(s^t)\}_{t=0}^{\infty}$ 视为给定，在**预算约束4.10**下选择消费

$$\{c_t^i(s^t)\}_{t=0}^{\infty}$$

最大化其目标效用**4.11**

- 所有个体 i 选择的消费配置 $\{c^i\}_{i=1}^I$ 满足**市场出清条件**（即经济总的资源约束）**4.9**： $\sum_i c_t^i(s^t) = \sum_i y_t^i(s^t) \quad \forall t, s^t$

需要强调，**竞争均衡**是一个广义的概念，适用于任何分散决策的市场结构（Decentralized），并不限于阿罗-德布鲁市场。在竞争市场上，家庭、企业等经济主体将价格视

为给定，最优化其目标函数，均衡时所有市场出清。阿罗-德布鲁均衡正是竞争均衡在一个完备市场下的实现形式。

定义 4.6 竞争均衡 (Competitive Equilibrium) 由一个价格系统 $\{q_t^0(s^t)\}_{t=0}^{\infty}$ 和一组可行配置 (Feasible Allocation) $\{c^i\}_{i=1}^I$ 构成。在竞争均衡下：

- 各经济主体价格系统视为给定，相应配置构成个体最优化问题的解；
- 相应配置使所有市场出清。

回到一阶条件，不难发现，个体 (i, j) 间边际效用的比值关于所有历史和时间都是不变的：

$$\frac{u'_i[c_t^i(s^t)]}{u'_j[c_t^j(s^t)]} = \frac{\mu_i}{\mu_j} \quad \forall t, s^t \quad (4.13)$$

与处理计划者帕累托问题的方法相似，不失一般性地取个体 i 和个体 1，从而有：

$$c_t^i(s^t) = u_i'^{-1} \left(\frac{\mu_i}{\mu_1} u'_1(c_t^1(s^t)) \right) \quad (4.14)$$

同样，将其带入经济的资源约束4.2可得：

$$\sum_i u_i'^{-1} \left(\frac{\mu_i}{\mu_1} u'_1(c_t^1(s^t)) \right) = \sum_i y_t^i(s^t) \equiv Y_t(s^t) \quad (4.15)$$

和帕累托问题一致，方程右侧式当前实现的总禀赋。由此式，我们可以去求解 $c_t^1(s^t)$ ，它仅依赖于当前的总禀赋和一个比值序列 $\{\frac{\mu_i}{\mu_1}\}_{i=2}^{\infty}$ 。由4.14式我们就能解得其余所有个体的消费配置。均衡解的形式是一个时不变函数：

$$c_t^i = g(\mu_i, Y_t; \mu)$$

性质 4.4 阿罗-德布鲁市场中竞争均衡配置具有如下特征：

- 与时间 t 无关，总禀赋 Y_t 是历史的充分统计量。

不过，根据预算约束4.10式：

$$\sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) g(\mu_i, Y_t; \mu) = \sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) y_t^i(s^t), \quad \text{all } i$$

均衡时 μ_i 会通过价格 q 依赖于个体禀赋分布 $y^i = \{y_t^i(s^t)\}$ 的，也就是说，不同个体禀赋分布会带来不同的配置结果。换句话说，如果我们想得到某一配置结果 $c^i = \{c_t^i(s^t)\}_{t=0}^{\infty}$ ，我们可以通过改变 y^i ，找到一个能够带来这一配置的乘子 μ_i 。简言之，任意可行均衡配

置都能通过重新调整财富分布来实现。这对于后文理解福利经济学第二定理十分关键。

前面提到，阿罗-德布鲁市场天然就是完备市场，这一市场有什么特点？能够实现完美风险承担吗？在计划者问题的中，对任意个体 (i, j) ，其最优条件的比：

$$\frac{u'_i(c_t^i(s^t))}{u'_j(c_t^j(s^t))} = \frac{\lambda_j}{\lambda_i} \quad \forall t, s^t$$

由于权重是外生常数，因此我们说这一配置实现了完美消费保险。对阿罗-德布鲁市场，任意个体 (i, j) ，其最优条件的比：

$$\frac{u'_i(c_t^i(s^t))}{u'_j(c_t^j(s^t))} = \frac{\mu_i}{\mu_j} \quad \forall t, s^t$$

形式上，由于 μ_i 是内生的，因此个体异质性风险（Idiosyncratic Risk）似乎未被保险掉。但我们已经指出，阿罗-德布鲁问题中个体面临的预算约束是单一的方程。因此，虽然不同禀赋分布下乘子向量解出的值不同（进而均衡配置不同），但由于乘子本身不是时变的，从而边际消费比也是恒定的，符合此前对完美消费保险的定义4.2：不同个体间的消费边际效用比在任意时刻、任意状态下都相同。

我们借此想要强调的是：初始禀赋分布的差异确实会带来不同的均衡配置水平：禀赋分布的变化（例如计划者将 i 的一部分财富分给 j ）带来的是配置问题：对于禀赋高的个体，均衡时其乘子（边际效用）低。在价格系统的作用下，内生乘子反应的是分配的效率，而不是未对冲的个体风险。或者说，完美风险承担并不是指均衡配置不随禀赋分布变化，而是指个体的消费路径不会受未来个体异质性风险的影响，可以通过市场交易对冲风险。对于阿罗-德布鲁这一完备市场，由于存在覆盖未来所有可能的证券，因此消费者可以通过购买或出售证券，对冲未来禀赋波动的风险，锁定未来所有状态下的消费水平。例如个体 i 在未来某一状态下可能面临收入降低，那么，通过在零时刻购买该状态下消费品的索取权，就可以对冲风险。进一步观察最优条件，对任意个体 i ，在不同状态 s^t 和 s^τ 下成立：

$$\beta^{t-\tau} \frac{\pi(s^t) u'(c^i(s^t))}{\pi(s^\tau) u'(c^i(s^\tau))} = \frac{q_t^0(s^t)}{q_\tau^0(s^\tau)} \quad \forall i, s^t, s^\tau \quad (4.16)$$

即个体 i 通过使概率和价格调整后的 $MRS = MRT$ ，实现消费平滑（Consumption Smoothing）。

实际上，正如后面我们将证明的：阿罗-德布鲁均衡是一组特殊权重下的帕累托均衡。因此必然满足完美消费保险。

性质 4.5 阿罗-德布鲁市场（完备市场）实现了完美消费保险。

至此我们对阿罗-德布鲁均衡的特征进行了初步分析，但是，**仍未得到一般均衡问题的解**。在计划者的帕累托问题中，我们通过比值消去了乘子 $\theta_t(s^t)$ ，其解 $c_t^i(s^t)$ 只与总禀赋和外生权重比值有关，从而解相对容易。但对于阿罗-德布鲁市场中的问题，我们在求解 $c_t^i(s^t)$ 时还有内生的乘子向量 $\mu = (\mu_1, \dots, \mu_I)$ 未知。换句话说，竞争均衡是由**数量-价格体系**构成的，除了数量，我们还需要求解价格。

4.2.1 Arrow-Debreu 竞争均衡价格

一个自然的想法是通过每个个体的预算约束4.10来求解价格系统或乘子向量，目前我们仍未使用这一条件。对每个个体 i ，将均衡配置 $c_t^i = g(\mu_i, Y_t; \mu)$ 带入预算约束：

$$\sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) g(\mu_i, Y_t; \mu) = \sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) y_t^i(s^t), \quad \text{all } i$$

不难看出，可以构建出关于 I 个未知量 μ_i 的 I 个非线性方程。由4.14式可知， μ_i 以 μ_i/μ_1 的形式进入函数 $g(\cdot)$ ，可以乘上一个常数而不会影响结果，即可以正则化后进行求解。例如固定某一乘子 μ_1 ，调整其他乘子。实际上，正则化的本质是调整价格系统的计价单位。

在均衡时，价格和乘子相互协调使消费者的最优选择和市场出清条件一致：当价格 $q_t^0(s^t)$ 变化时，个体的预算约束变化，消费者调整乘子以优化跨期消费；乘子通过边际效用决定消费者需求，进而影响市场出清时的价格。换句话说，需要找到一组 $(\mu_i, q_t^0(s^t))$ ，使得二者相互一致——本质上，这是一个**不动点问题**。我们将会在4.2.2节的算法中看到其运用。

也可以从下面的视角进行理解：假设 $\{c^i\}_{i=1}^I$ 是一个均衡配置，则一阶条件4.12式：

$$q_t^0(s^t) = \beta^t \frac{u'_i(c_t^i(s^t))}{\mu_i} \pi_t(s^t) \quad \text{for all } t, s^t$$

可以看作将价格系统 $q_t^0(s^t)$ 描述为任意个体 i 的均衡配置的函数。因此，我们希望找到一个计算方法，可以先避开价格的计算就得到均衡配置。我们下面将看到，通过解计划者问题将会提供极大的方便。此外，由于价格系统的单位是任意的，因此其中一个价格可以被正则化，我们通常选择 $q_0^0(s_0) = 1$ ，即将零时刻的商品作为计价物。这也意味着： $\mu_i = u'_i(c_0^i(s_0))$ 。

4.2.2 Arrow-Debreu 竞争均衡的算法

我们已经知道：想要求解竞争均衡（数量-价格），必须想办法得到4.14式和4.15式中的比值 μ_i/μ_1 , $i = 1, \dots, I$ 。同时我们也已经阐明，寻找一组自我一致的均衡价格 $q_t^0(s^t)$ 和乘子 μ_i 本质是一个不动点问题。下面的 **Negishi 算法** 可以完成这项工作：

- 任意选取一个 μ_i ，例如 μ_1 ，使其始终取一个固定的正数（正则化）。猜测其余正数 μ_i 的取值，然后从4.14和4.15式解得一个候选的配置 $c^i, i = 1, \dots, I$
- 对任意一个个体 i ，利用一阶条件4.12求得价格系统 $q_t^0(s^t)$
- 对 $i = 1, \dots, I$ ，检查预算约束4.10是否满足。若某一个体 i 的消费花费超过了其财富，那么提高其乘子 μ_i 猜测值；反之降低
- 迭代上述至收敛

4.2.3 阿罗-德布鲁均衡配置

除了均衡价格，我们还面临一个重要问题：阿罗-德布鲁市场中的竞争均衡和社会计划者的帕累托最优均衡有什么关系。回顾计划者问题中所得的条件4.7和4.8：

$$c_t^i(s^t) = u_i'^{-1} \left(\frac{\lambda_1}{\lambda_i} u_1'(c_t^1(s^t)) \right)$$

$$\sum_i u_i'^{-1} \left(\frac{\lambda_1}{\lambda_i} u_1'(c_t^1(s^t)) \right) = \sum_i y_t^i(s^t) \equiv Y_t(s^t) \quad \forall t, s^t$$

与阿罗-德布鲁市场中竞争均衡问题所得的条件4.14和4.15：

$$c_t^i(s^t) = u_i'^{-1} \left(\frac{\mu_i}{\mu_1} u_1'(c_t^1(s^t)) \right)$$

$$\sum_i u_i'^{-1} \left(\frac{\mu_i}{\mu_1} u_1'(c_t^1(s^t)) \right) = \sum_i y_t^i(s^t) \equiv Y_t(s^t) \quad \forall t, s^t$$

对帕累托问题，权重 λ 是一组外生参数，当其变化时，帕累托最优配置就可以构成一个前沿集合，也就是说帕累托均衡不止一个。对比两个问题的最优条件发现，**竞争均衡配置就是一个特殊的帕累托最优配置**，其满足权重 $\lambda_i = \mu_i^{-1}$ 。并且这些权重在乘以一个标量后是唯一确定的，因为在帕累托问题中，权重的绝对值并不重要，重要的是其相对比例。此外，由于 u' 递减，因此 u'^{-1} 递增，从而 μ_i 与个体 i 的财富反相关。也就是说：**竞争均衡意味着计划者分配给穷人的权重更低**。进一步对比计划者问题的一阶条件4.5：

$$\lambda_i \beta^t u_i'(c_t^i(s^t)) \pi_t(s^t) = \theta_t(s^t) \quad \forall i, t, s^t$$

和阿罗-德布鲁均衡的一阶条件4.12:

$$q_t^0(s^t) = \beta^t \frac{u'_i(c_t^i(s^t))}{\mu_i} \pi_t(s^t) \quad \text{for all } t, s^t$$

当竞争均衡是帕累托最优，即计划者设定 $\lambda_i = \mu_i^{-1}$ 时，对应计划者问题的资源约束（注意不是预算约束）的影子价格 $\theta_t(s^t)$ 等于竞争均衡价格 $q_t^0(s^t)$ 。

4.2.4 福利经济学定理

阿罗-德布鲁市场中的竞争均衡和计划者帕累托均衡间的关系本质上反映了两条福利经济学基本定理。

- 福利经济学第一定理表明：竞争均衡配置是帕累托有效的。这正对应于前文 $\lambda_i = \mu_i^{-1}$ 的情形。
- 福利经济学第二定理表明：任意帕累托均衡都可以由某一竞争均衡支撑。前文指出，由于乘子 μ_i 依赖于财富分布，我们可以通过调整财富分配，找到一个与目标配置相匹配的乘子。也就是说，任意可行均衡配置都能通过适当重新分配财富来实现。因此福利经济学第二定理成立。

在4.2.1节，我们曾提出求解竞争均衡价格的另一个视角：绕过价格系统，通过解计划者问题来寻找阿罗-德布鲁均衡，其背后的支撑就是福利经济学第二定理。一旦找到了帕累托最优配置（同时也得到了资源约束的影子价格），我们就可以通过设定影子价格 $\theta_t(s^t)$ 等于竞争均衡价格 $q_t^0(s^t)$ 和调整初始财富，将帕累托均衡转化为一个竞争均衡。

4.2.5 应用：资产定价初步

在本小节，我们利用阿罗-德布鲁证券讨论资产定价问题。回顾这一证券的定义：它是一个依存于 s^t 的对 t 时刻一单位消费品的索取权。与之前一致，记其价格为 $q_t^0(s^t)$ ，表示在第 0 期交易的依存于 (t, s^t) 交割一单位消费品的合约的价格。这一合约在理论上是十分有用的：许多资产定价模型会在完备市场假设下，通过将感兴趣的资产分解为一个状态依存合约序列，利用状态价格平减指数（State Price Deflator） $q_t^0(s^t)$ 对序列中的每一元素进行估值，最后加总得到资产的定价。

例 4.1 冗余资产 (Redundant Asset): 这一资产带来的收益流为 $\{d_t(s^t)\}_{t \geq 0}$ ，是对 t 时刻 s^t 历史下的消费品索取权序列。在完备市场中，根据无套利原则，这一资产的价格必定等于：

$$p_0^0(s_0) = \sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) d_t(s^t) \quad (4.17)$$

例 4.2 无风险永续债 (Riskless Consol): 这一资产会在每期都确定地提供一单位消费品, 即 $d_t(s^t) = 1, \forall t, s^t$, 则这一资产的价格为:

$$\sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) \quad (4.18)$$

例 4.3 无风险剥离债 (Riskless Strips): 是指将债券的本金和利息现金流拆分成独立的零息债券。考虑将上述无风险永续债未来每期的利息支付单独剥离: 当 $\tau = t \geq 0$ 时, $d_\tau = 1$, 否则 $d_\tau = 0$ 。实际上, 拆分后形成的本质上是一个仅在到期日 t 支付的零息债券。剥离出的第 t 期的条带价值为:

$$\sum_{s^t} q_t^0(s^t) \quad (4.19)$$

例 4.4 尾部资产 (Tail Asset): 这一资产对后续序贯市场均衡和阿罗-德布鲁均衡关系的研究至关重要。考虑冗余资产带来的收益流, 对 $\tau \geq 1$, 假设我们剥离掉前 $\tau - 1$ 期的收益, 同时希望得到剩余收益流 $\{d_t(s^t)\}_{t \geq \tau}$ 的零时刻价格。特别的, 我们希望得到某一特定实现的历史 s^τ 下这一**尾部资产**的价值。记 $p_\tau^0(s^\tau)$ 为条件于历史 s^τ 实现时带来 $\{d_t(s^t)\}_{t \geq \tau}$ 的资产的**零时价格** (即在零时刻交易, 注意上标), 那么价值为:

$$p_\tau^0(s^\tau) = \sum_{t \geq \tau} \sum_{s^t | s^\tau} q_t^0(s^t) d_t(s^t) \quad (4.20)$$

其中, 对于 $s^t | s^\tau$ 的求和符号表示我们对所有满足 $\tilde{s}^\tau = s^\tau$ 的可能的后续历史 $\tilde{s}^t$ 进行求和。当价格的单位是零时刻状态 s_0 下的商品, 正则化有 $q_0^0(s_0) = 1$ 。为了将价格 $p_\tau^0(s^\tau)$ 转化为以时刻 τ 历史 s^τ 下的商品计价, 我们将其除以 $q_\tau^0(s^\tau)$ (阿鲁-德布鲁价格) 就可得到正则化后的尾部资产价格 $p_\tau^\tau(s^\tau)$ (上标: 时刻 τ 交易, 即 τ 时价格; 下标和括号中: 依存于 (τ, s^τ) 的合约):

$$p_\tau^\tau(s^\tau) \equiv \frac{p_\tau^0(s^\tau)}{q_\tau^0(s^\tau)} = \sum_{t \geq \tau} \sum_{s^t | s^\tau} \frac{q_t^0(s^t)}{q_\tau^0(s^\tau)} d_t(s^t) \quad (4.21)$$

又由阿罗-德布鲁市场中的一阶条件式4.12:

$$\begin{aligned} q_t^\tau(s^t) &\equiv \frac{q_t^0(s^t)}{q_\tau^0(s^\tau)} = \frac{\beta^t u'_i[c_t^i(s^t)] \pi_t(s^t)}{\beta^\tau u'_i[c_\tau^i(s^\tau)] \pi_\tau(s^\tau)} \\ &= \beta^{t-\tau} \frac{u'_i[c_t^i(s^t)]}{u'_i[c_\tau^i(s^\tau)]} \pi_t(s^t | s^\tau) \end{aligned} \quad (4.22)$$

这里 $q_t^\tau(s^t)$ 表示以时刻 τ 历史 s^τ 下的物品计价的许诺在在时刻 t 历史 s^t 下交割的一单位消费品的合约的价格。因此，依存于时刻 τ 历史 s^τ 的尾部资产的 τ 时价格可以进一步简化为:

$$p_\tau^\tau(s^\tau) = \sum_{t \geq \tau} \sum_{s^t | s^\tau} q_t^\tau(s^t) d_t(s^t) \quad (4.23)$$

式4.23有非常多运用，例如在 τ 时刻购买的承诺从此刻 τ 开始分红的股权定价。实际上，尾部资产定价公式4.23就是将资产价格表示为以时刻 τ 历史 s^τ 下的物品计价。

例 4.5 单期回报 (One-Period Returns):

4.3 序贯市场下的均衡

本小节研究另一种市场中的均衡——序贯市场均衡 (Sequential Market Equilibrium, SME)。虽然阿罗-德布鲁市场是具有良好的性质的天然完备市场，但更适于作为一个理论基础，而序贯市场则更贴近于实践中的金融交易。在序贯市场中，只要每期阿罗证券 (单期状态依存证券) 的数量足够覆盖下期所有状态 (Complete Set of one-period-ahead Contingent Claims)，那么序贯市场也可以达到**动态完备 (Sequentially Complete)**。由此，我们自然会猜想：序贯市场 (竞争) 均衡应该也是帕累托最优的，且与阿罗-德布鲁市场 (竞争) 均衡等价。我们将给出序贯均衡存在的条件，并对均衡间的等价性进行证明。

回顾序贯市场交易的特征：市场每期都会重新开放，但是只有一种单期状态依存合约，交易按期进行形成一个序列。记在第 t 期历史 s^t 下签订的在第 $t+1$ 期状态 s_{t+1} 实现时交割 1 单位消费品的阿罗证券的价格为 $\tilde{Q}_t(s^t, s_{t+1})$ ；记个体 i 购买 (售出) 的这一证券的数量为 $\tilde{a}_{t+1}^i(s^t, s_{t+1})$ ，² 从而其预算约束为：

$$\tilde{c}_t^i(s^t) + \sum_{s_{t+1}} \tilde{Q}_t(s^t, s_{t+1}) \tilde{a}_{t+1}^i(s^t, s_{t+1}) \leq y_t^i(s^t) + \tilde{a}_t^i(s^{t-1}, s_t) \quad (4.24)$$

对 $\tilde{a}_{t+1}^i(s^t, s_{t+1}) > 0$ ，个体将会在 s_{t+1} 实现时收到消费品，因此是一种资产；反之是一

²我们在序贯市场中使用 $\sim$ 记号用于与阿罗-德布鲁市场区分

种负债。

这里需要强调的有两点：一是，在阿罗-德布鲁问题中，个体的预算约束是单一的终身预算约束；但在序贯市场中，个体面临的是序列问题，因此约束条件是一系列不同期的预算约束，也就是说优化问题中约束的对应乘子是时变的。二是，这一问题中个体 i 的状态变量：在第 t 期，个体需要构建一个资产组合 $\{\tilde{a}_{t+1}^i(s^t, s_{t+1})\}_{s_{t+1} \in S}$ ，它是所有可能发生的状态（事件） $s_{t+1} \in S$ 对应的阿罗证券构成的向量。每个元素对应于某一特定状态 s_{t+1} 依存的证券 $\tilde{a}_{t+1}^i(s^{t+1})$ ：只有这一特定状态 s_{t+1} 实现才会支付（注意此时 $t+1$ 的历史 s^{t+1} 形成），进而决定个体 i 的下期开始时的资产状态（Asset Position）。因此对第 t 期，不等式右侧 $\tilde{a}_t^i(s^{t-1}, s_t)$ 可写为 $\tilde{a}_t^i(s^t)$ ，即在第 t 期决策时，个体状态变量（资产）由已经实现的历史 s^t 确定。

在竞争市场上，个体 i 将价格视为给定，其序列问题为：在预算约束4.24下，通过选择消费序列 $\tilde{c}^i \equiv \{\tilde{c}_t^i(s^t)\}_{t=0}^\infty$ 和资产组合的序列 $\{\{\tilde{a}_{t+1}^i(s^t, s_{t+1})\}_{s_{t+1} \in S}\}_{t=0}^\infty$ 最大化效用：

$$U(\tilde{c}^i) = \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u_i(\tilde{c}_t^i(s^t)) \pi_t(s^t) \quad (4.25)$$

记个体 i 第 t 期预算约束相关的乘子为 $\mu_t^i(s^t)$ ，则个体 i 的拉格朗日函数：

$$\begin{aligned} \mathcal{L}^i = & \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u_i(\tilde{c}_t^i(s^t)) \pi_t(s^t) \\ & + \sum_{t=0}^{\infty} \sum_{s^t} \mu_t^i(s^t) \left[y_t^i(s^t) + \tilde{a}_t^i(s^t) - \tilde{c}_t^i(s^t) - \sum_{s_{t+1}} \tilde{Q}_t(s^t, s_{t+1}) \tilde{a}_{t+1}^i(s^t, s_{t+1}) \right] \end{aligned}$$

易得关于 $\tilde{c}_t^i(s^t)$ 和 $\{\tilde{a}_{t+1}^i(s^t, s_{t+1})\}_{s_{t+1} \in S}$ 中某一代表元素（如特定 s_{t+1} 实现）的一阶条件为：

$$\beta^t u_i'(\tilde{c}_t^i(s^t)) \pi_t(s^t) = \mu_t^i(s^t) \quad (4.26)$$

$$\tilde{Q}_t(s^t, s_{t+1}) \mu_t^i(s^t) = \mu_{t+1}^i(s^t, s_{t+1}) \quad (4.27)$$

消去乘子可得：

$$\tilde{Q}_t(s^t, s_{t+1}) = \beta \frac{u_i'(\tilde{c}_{t+1}^i(s^{t+1}))}{u_i'(\tilde{c}_t^i(s^t))} \pi_{t+1}(s^{t+1} | s^t), \quad s^{t+1} = (s^t, s_{t+1}) \quad \forall s_{t+1}, t, s^t \quad (4.28)$$

其中条件概率 $\pi_{t+1}(s^{t+1} | s^t) \equiv \frac{\pi_{t+1}(s^{t+1})}{\pi_t(s^t)}$ 。³

³根据前面约定的条件概率记号：对时刻 $t > \tau$ ，记在 s^τ 实现的条件下，观测到 s^t 实现的条件概率

4.3.1 自然债务限制与序贯市场均衡

回忆第一章介绍的无限期最优增长模型：经济的最优路径要求横截性条件来排除资本存量无限增长。对于定义序贯市场均衡，目前遗留了一个类似的问题：庞氏骗局（Ponzi Game），即个体不断滚动新债来偿还旧债和利息，导致消费者预算集无界，使得问题无解。排除庞氏骗局的基本思路是：要求借款者的债务不能超过其未来收入的现值。在序贯市场中我们将看到，通过直接对债务水平施加一定约束，可以达成非庞氏条件。并且，我们通常会寻找一个最弱的债务限制，被称为自然债务限制（Natural Debt Limit），其想法是：要求个体在任意可能状态下都能够偿还其债务。

需要额外指出的是，非庞氏条件是为了确保解的存在性，而横截性条件则确保了最优性（回顾我们由有限期转向无限期最优增长的讨论），因此二者并不等同。为了方便理解自然债务限制，先看一个简单的局部均衡例子。

例 4.6 假设一个无限期经济体中，利率恒定为 r ，禀赋 $\{y_t\}$ 为外生过程， a_t 为 t 期期初的资产状态（小于零时为负债）。代表性家庭的预算约束为：

$$c_t + a_{t+1} \leq y_t + (1+r)a_t$$

从而对 t 期：

$$a_{t+1} = y_t + (1+r)a_t - c_t$$

对 $t+1$ 期：

$$\begin{aligned} a_{t+2} &= y_{t+1} + (1+r)a_{t+1} - c_{t+1} \\ &= y_{t+1} + (1+r)[y_t + (1+r)a_t - c_t] - c_{t+1} \\ &= y_{t+1} + (1+r)y_t + (1+r)^2a_t - (1+r)c_t - c_{t+1} \end{aligned}$$

对 $t+2$ 期：

$$\begin{aligned} a_{t+3} &= y_{t+2} + (1+r)a_{t+2} - c_{t+2} \\ &= y_{t+2} + (1+r)[y_{t+1} + (1+r)y_t + (1+r)^2a_t - (1+r)c_t - c_{t+1}] - c_{t+2} \\ &= y_{t+2} + (1+r)y_{t+1} + (1+r)^2y_t + (1+r)^3a_t - (1+r)^2c_t - (1+r)c_{t+1} - c_{t+2} \end{aligned}$$

（Conditional Probability）记作 $\pi_t(s^t|s^\tau)$ ，因此此处最优条件中条件概率的时间脚标为 $t+1$ 。

依次递归展开，可得对 $t + N$ 期：

$$\begin{aligned} a_{t+N} &= y_{t+N-1} + (1+r)y_{t+N-2} + (1+r)^2 y_{t+N-3} + \cdots + (1+r)^{N-2} y_{t+1} + (1+r)^{N-1} y_t \\ &\quad + (1+r)^N a_t - (1+r)^{N-1} c_t - (1+r)^{N-2} c_{t+1} - \cdots - (1+r) c_{t+N-2} - c_{t+N-1} \\ &= \sum_{j=1}^{N-1} (1+r)^{N-1-j} y_{t+j} + (1+r)^N a_t - \sum_{s=t}^{N-1} (1+r)^{N-1-j} c_{t+j} \end{aligned}$$

进一步施加约束条件，要求无穷远处资产的现值大于等于 0（实际上最优路径是由横截性条件保证的，必然取等号，不再证明），即：

$$\lim_{N \rightarrow \infty} \frac{a_{t+N}}{(1+r)^N} = 0$$

与递归的预算约束合并可得：

$$\lim_{N \rightarrow \infty} \left[\sum_{j=1}^{N-1} \frac{y_{t+j}}{(1+r)^{j+1}} + a_t - \sum_{j=1}^{N-1} \frac{c_{t+j}}{(1+r)^{j+1}} \right] = 0$$

从而：

$$a_t = \sum_{j=1}^{\infty} \frac{c_{t+j}}{(1+r)^{j+1}} - \sum_{j=1}^{\infty} \frac{y_{t+j}}{(1+r)^{j+1}}$$

又由于消费的非负性，可得债务约束条件，其中右侧即为自然债务限制：

$$a_t \geq - \sum_{j=1}^{\infty} \frac{y_{t+j}}{(1+r)^{j+1}}$$

我们已经知道：与阿罗-德布鲁市场不同，如果不施加额外约束，序贯均衡可能不存在，因此我们希望寻找一组最弱的条件。从阿罗-德布鲁市场均衡出发，有助于解决这个问题：我们希望找到序贯市场上的一组债务约束限制（State-by-State Debt Limits），使得零时交易中的均衡也能够由序贯市场支撑。前文指出，最弱的债务约束限制——自然债务限制：要求个体在任意状态下偿还其债务是可行的。结合消费的非负性，我们可以推导出其具体形式。

记 $q_{\tau}^t(s^{\tau})$ 为以时刻 t 历史 s^t 下的消费品计价的阿罗-德布鲁价格。⁴ 由尾部资产定

⁴此前推导尾部资产价格时，用到了记号 q_t^{τ} ，是以时刻 τ 历史 s^{τ} 下的物品计价的时刻 t 历史 s^t 下交割的一单位消费品的价格， $t \geq \tau$ 。此处是以时刻 t 历史 s^t 的物品计价， $\tau \geq t$ ，因此上下标相反。只是记号。

价的知识，个体 i 的在时刻 t 历史 s^t 下的尾部资产价值：

$$A_t^i(s^t) = \sum_{\tau=t}^{\infty} \sum_{s^\tau | s^t} q_\tau^t(s^\tau) y_\tau^i(s^\tau) \quad (4.29)$$

我们将 $A_t^i(s^t)$ 称为**自然债务限制 (Natural Debt Limit)**：它是在当前时间和状态下，个体 i 所能偿还的最多债务值：即从当期开始，设定此后消费始终为零。需要注意的是，在序贯交易下，条件于明天状态 s_t 的实现，个体 i 在时刻 $t-1$ 和历史 s^{t-1} 下无法承诺偿还比 $A_t^i(s^t)$ 更多的债务。也就是说，对于明天每一种可能实现的状态 s_t ，个体 i 在 $t-1$ 都面临一个与之对应的借款约束。回顾前面我们所强调的，消费者每期构建的资产组合是一个向量，每个元素都应一种可能实现的状态，因此我们将其记为 $\{\tilde{a}_{t+1}^i(s^t, s_{t+1})\}_{s_{t+1} \in S}$ ，此处正与之一致。因此，对后续优化问题中与这一约束相关的乘子，我们将记为 $\nu(s^t, s_{t+1})$ 。至此，对第 t 期的个体 i ，条件于 s_{t+1} ，我们可以写出如下自然债务限制条件来排除庞氏骗局：

$$\tilde{a}_{t+1}^i(s^{t+1}) \geq -A_{t+1}^i(s^{t+1}) \quad (4.30)$$

但是，对于债务额外施加约束条件，会导致最优化问题拉格朗日函数的变化。我们将看到，自然债务约束在序贯均衡时是非紧的。因此，此前得到的一阶条件仍然是正确的，进而能为研究序贯市场均衡与阿罗-德布鲁均衡的关系提供方便。记 $\nu_t^i(s^t, s_{t+1})$ 为个体 i 第 t 期面临的、条件于在 $t+1$ 期实现状态 s_{t+1} 时的自然债务限制约束乘子，则正确的拉格朗日函数为：

$$\begin{aligned} \mathcal{L}^i = & \sum_{t=0}^{\infty} \sum_{s^t} \beta^t u_i(\tilde{c}_t^i(s^t)) \pi_t(s^t) \\ & + \sum_{t=0}^{\infty} \sum_{s^t} \mu_t^i(s^t) \left[y_t^i(s^t) + \tilde{a}_t^i(s^t) - \tilde{c}_t^i(s^t) - \sum_{s_{t+1}} \tilde{Q}_t(s^t, s_{t+1}) \tilde{a}_{t+1}^i(s^t, s_{t+1}) \right] \\ & + \sum_{t=0}^{\infty} \sum_{s^t} \sum_{s_{t+1}} \nu_t^i(s^t, s_{t+1}) [A_{t+1}^i(s^{t+1}) + \tilde{a}_{t+1}^i(s^{t+1})] \end{aligned}$$

从而关于消费和资产的正确一阶条件为：

$$\beta^t u_i'(\tilde{c}_t^i(s^t)) \pi_t(s^t) = \mu_t^i(s^t) \quad (4.31)$$

$$\tilde{Q}_t(s^t, s_{t+1}) \mu_t^i(s^t) = \mu_{t+1}^i(s^t, s_{t+1}) + \nu_t^i(s^t, s_{t+1}) \quad (4.32)$$

我们现在证明：**均衡时自然债务限制约束一定是非紧的**：假设存在某一历史 s^{t+1} ，带来一个紧的自然债务限制，那么，消费者从此时开始，必须设定今后消费为 0，才能保证

偿还债务。也就是说，如果自然债务限制为紧，则个体未来的收入全部被用于偿还债务。但效用函数的 Inada 条件， $\lim_{\tilde{c} \rightarrow 0} u_i(c) = +\infty$ 意味着：未来的边际效用将会是无穷。那么，个体只需要将此前的部分消费推迟到自然债务限制为紧之后，就很容易能找到一个可行的更好的消费配置。因此，乘子 $\nu_t^i(s^t; s_{t+1})$ 始终为 0，之前得到的最优条件 4.28 是正确的，即：

$$\tilde{Q}_t(s^t, s_{t+1}) = \beta \frac{u'_i(\tilde{c}_{t+1}^i(s^{t+1}))}{u'_i(\tilde{c}_t^i(s^t))} \pi_{t+1}(s^{t+1} | s^t), \quad s^{t+1} = (s^t, s_{t+1}) \quad \forall s_{t+1}, t, s^t \quad (4.33)$$

定义 4.7 财富分布 (Distribution of Wealth)，是一组向量 $\vec{a}_t(s^t) = \{\tilde{a}_t^i(s^t)\}_{i=1}^I$ ，满足： $\sum_i \tilde{a}_t^i(s^t) = 0$ 。

我们将在后文证明两个市场均衡等价性时详细讨论关于财富分布的问题。现在给出是因为它是定义均衡的一个必要条件。

定义 4.8 序贯市场均衡 (Sequential Market Equilibrium) 是一个竞争均衡，由初始财富分布 $\vec{a}_0(s_0) = \{\tilde{a}_0^i(s_0)\}_{i \in I}$ 、自然债务限制 $\left\{ \{A_t^i(s^t)\}_{t=0, s^t \in S^t} \right\}_{i \in I}$ 、消费-资产组合配置 $\left\{ [\tilde{c}_t^i(s^t), \{\tilde{a}_{t+1}^i(s^t, s_{t+1})\}_{s_{t+1} \in S}]_{t=0}^\infty \right\}_{i \in I}$ 和阿罗价格 $\{\tilde{Q}(s^t, s_{t+1})\}_{t=0, s_{t+1} \in S}^\infty$ 和构成，满足：

- 任意个体 i 将价格视为给定，在预算约束 4.24 和自然债务约束 4.30 下选择消费和资产组合序列

$$[\tilde{c}_t^i(s^t), \{\tilde{a}_{t+1}^i(s^t, s_{t+1})\}_{s_{t+1} \in S}]_{t=0}^\infty$$

最大化其目标效用 4.25

- 所有个体 i 的消费-资产组合配置 $\left\{ [\tilde{c}_t^i(s^t), \{\tilde{a}_{t+1}^i(s^t, s_{t+1})\}_{s_{t+1} \in S}]_{t=0}^\infty \right\}_{i \in I}$ 使产品和金融市场出清：

$$\sum_{i=1}^I \tilde{c}_t^i(s^t) = \sum_{i=1}^I y_t^i(s^t)$$

$$\sum_{i=1}^I \tilde{a}_{t+1}^i(s^t, s_{t+1}) = 0 \quad \forall s_{t+1} \in S$$

4.3.2 均衡等价性

比较两个竞争市场的均衡配置，我们很容易发现二者的均衡是等价的。我们的证明思路是：给定 A 市场下的价格-消费配置，证明在 B 市场存在一个均衡价格，使得给定的消费在 B 市场中这一价格下符合 B 市场的均衡条件。为了方便起见，在此写下两个

市场的均衡条件。对阿罗-德布鲁市场，均衡条件为4.12:

$$q_t^0(s^t) = \beta^t \frac{u'_i(c_t^i(s^t))}{\mu_i} \pi_t(s^t) \quad \forall t, s^t$$

其中乘子 μ_i 是个体 i 的终身预算约束。对序贯市场，均衡条件为4.33:

$$\tilde{Q}_t(s^t, s_{t+1}) = \beta \frac{u'_i(\tilde{c}_{t+1}^i(s^{t+1}))}{u'_i(\tilde{c}_t^i(s^t))} \pi_{t+1}(s^{t+1} | s^t), \quad s^{t+1} = (s^t, s_{t+1}) \quad \forall s_{t+1}, t, s^t$$

现在，给定 $(\{c_t^i(s^t)\}, q_t^0)$ 为阿罗-德布鲁市场中的一个竞争均衡。我们假设序贯市场中存在满足下式的阿罗价格（构造序贯市场中的价格）:

$$\tilde{Q}_t(s^t, s_{t+1}) = \frac{q_{t+1}^0(s^{t+1})}{q_t^0(s^t)} \equiv q_{t+1}^t(s^{t+1}) \quad (4.34)$$

使得序贯市场上的均衡消费正为 c 。也就是说，往证这一价格和 $\tilde{c} = c$ 满足序贯均衡条件。这是容易的：由阿罗-德布鲁均衡条件可进一步推得:

$$\frac{q_{t+1}^0(s^{t+1})}{q_t^0(s^t)} = \beta \frac{u'_i(c_{t+1}^i(s^{t+1}))}{u'_i(c_t^i(s^t))} \pi_{t+1}(s^{t+1} | s^t) \quad (4.35)$$

从而对我们猜测（构造）的价格 $\tilde{Q}_t(s^t, s_{t+1})$ ，有:

$$\tilde{Q}_t(s^t, s_{t+1}) = \frac{q_{t+1}^0(s^{t+1})}{q_t^0(s^t)} = \beta \frac{u'_i(c_{t+1}^i(s^{t+1}))}{u'_i(c_t^i(s^t))} \pi_{t+1}(s^{t+1} | s^t) \quad (4.36)$$

其中第一个等号是根据我们的构造，第二个等号是根据4.35。不难看出，当序贯均衡条件4.33中 $\tilde{c} = c$ ，上述结果正是序贯市场的均衡条件。也就是说，阿罗-德布鲁市场中给定的这组竞争均衡使得序贯市场的均衡条件成立。反之同理。

定理 4.1 若 (c, q) 是一个阿罗-德布鲁均衡，那么 $(\vec{a}, c, \tilde{Q})$ 是一个序贯市场均衡，其价格满足:

$$\tilde{Q}_t(s^t, s_{t+1}) = \frac{q_{t+1}^0(s^{t+1})}{q_t^0(s^t)} (\equiv q_{t+1}^t(s^{t+1})) \quad (4.37)$$

若 $(\vec{a}, c, \tilde{Q})$ 是一个序贯市场均衡, 那么 (c, q) 是一个阿罗-德布鲁均衡, 其价格满足:

$$\begin{aligned}
 q_t^0(s^t) &= q_{t-1}^0(s^{t-1}) \tilde{Q}_{t-1}(s^{t-1}, s_t) \\
 &= q_{t-2}^0(s^{t-2}) \tilde{Q}_{t-2}(s^{t-2}, s_{t-1}) \tilde{Q}_{t-1}(s^{t-1}, s_t) \\
 &= \dots \\
 &= 1 * \tilde{Q}_0(s_0, s_1) \tilde{Q}_1(s^1, s_2) \dots \tilde{Q}_{t-1}(s^{t-1}, s_t)
 \end{aligned} \tag{4.38}$$

这一定理表明, 任一阿罗-德布鲁均衡可以在包含了一组完备单期阿罗证券的序贯市场均衡中实现; 反之, 任一序贯市场均衡都可以在阿罗-德布鲁市场实现。简言之, 两个竞争市场均衡是相合的, 并且都是帕累托有效的。

本节开始的讨论已经完成了对于这一定理的大部分证明, 但还遗漏了一个问题: 初始财富 $\vec{a}_0$ 如何选择? 一个自然的猜测显然是所有个体在零时刻的资产都为 $\mathbf{0}$, 即初始财富分布 $\vec{a}_0(s_0) = \vec{0}$, 这意味着每个个体依赖于其自身财富流为消费融资。这与零时交易中消费者在 $t = 0$ 时根据终身预算约束为未来的状态依存合约融资是同一方法。为了证明这一猜测, 我们必须证明 $\vec{a}_0(s_0) = \vec{0}$ 使得序贯市场中的个体 i 能够为 $\{c_t^i(s^t)\}$ 这一消费计划 (阿罗-德布鲁市场中的均衡配置) 融资, 并且在任意历史实现后的任意期内都没有提高消费的可能。对这一问题的论证有些复杂, 总的思路是: 建立序贯市场中财富和阿罗-德布鲁市场中财富的关系, 利用相应关系完成证明。下面具体来看。

首先, 在序贯市场中, 均衡时个体的财富或者说状态有什么特征, 即 $\tilde{a}_{t+1}^i$ 是什么样的? 此前的论证证明了在均衡时两个市场中的消费相同, 以及均衡价格间的关系, 但是对于 $\tilde{a}_{t+1}^i$, 我们了解的很少。我们需要借助阿罗-德布鲁均衡来建立一些概念: 思考如下问题: 对于零时交易下的竞争均衡, 个体 i 在 t 时刻历史 s^t 实现后的**延续财富** (Continuation Wealth) 是多少? 显然, 答案是个体在 (t, s^t) 下持有的对今天和未来消费索取权价值的加总。由于历史 s^t 已经实现, 对于任意历史 $\tilde{s}^t \neq s^t$ 的索取权, 需要忽略掉。也就是说, 财富在零时交易结束后就被决定下来, 相当于个体出售了其全部未来禀赋留 (预算约束4.10右侧), 以换取状态依存的消费索取权 (预算约束4.10左侧)。

而从序贯市场的角度看, 由于交易是逐期进行的, 消费者每期都会重新获得对于禀赋的所有权, 因此个体 i 的在某一时刻的财富可以被分解为两部分: **金融财富**和**非金融财富**。其中, (t, s^t) 下的金融财富由个体在 t 期初持有的依存于当前实现的状态为 s_t 的阿罗证券构成; 非金融财富由个体当前和未来禀赋构成。如果两种市场结构带来相同的均衡配置, 那么, t 期初个体在序贯市场下的**金融财富**应该等于以零时交易价格衡量的阿罗-德布鲁市场下的**延续财富**减去他当前和未来禀赋带来的**延续财富** (即**非金融财富**)。

以时刻 t 历史 s^t 下的消费品对其计价，个体 i 在时刻 t 历史 s^t 实现下的金融财富为：

$$\Upsilon_t^i(s^t) = \sum_{\tau=t}^{\infty} \sum_{s^\tau | s^t} q_\tau^t(s^\tau) [c_\tau^i(s^\tau) - y_\tau^i(s^\tau)] \quad (4.39)$$

价格 $q_\tau^t(s^\tau)$ 表示以时刻 t 历史 s^t 下的消费品计价。⁵ 实际上，个体 i 在时刻 t 历史 s^t 实现下的金融财富，从阿罗-德布鲁均衡的视角看，就是一个尾部资产。根据阿罗-德布鲁市场下个体的终身预算约束4.10（必定取等），所有个体在零时刻的金融财富都为零，即 $\Upsilon_0^i(s_0) = 0, \forall i$ 。对 $t > 0$ ，个体 i 的金融财富 $\Upsilon_t^i(s^t)$ 可能不为 0，但是根据总资源的可行性约束式4.2，所有个体加总后必然有：

$$\sum_{i=1}^I \Upsilon_t^i(s^t) = 0, \quad \forall t, s^t \quad (4.40)$$

也就是说，在序贯市场中，阿罗债券使得金融财富净供给为零：一部分人的资产就是另一部分人的负债。

回到我们的目标：研究序贯市场中个体的财富（状态）的特征，或者说与阿罗-德布鲁市场上财富的关系，即我们希望将个体在序贯市场上时刻 t 历史 s^t 下的财富与阿罗-德布鲁视角下的尾部资产 $\Upsilon_t^i(s^t)$ 匹配，这也是我们借助阿罗-德布鲁市场的原因。我们猜想，序贯市场中的个体 i 在 $t \geq 0$ 和历史 s^t 下会选择 $\tilde{a}_{t+1}^i(s^t, s_{t+1}) = \Upsilon_{t+1}^i(s^{t+1}), \forall s_{t+1}$ 。如果以时刻 t 历史 s^t 下的产品计价，由此形成的资产组合的价值为：

$$\begin{aligned} \sum_{s_{t+1}} \tilde{a}_{t+1}^i(s_{t+1}, s^t) \tilde{Q}_t(s_{t+1} | s^t) &= \sum_{s^{t+1} | s^t} \Upsilon_{t+1}^i(s^{t+1}) q_{t+1}^t(s^{t+1}) \\ &= \sum_{s^{t+1} | s^t} \sum_{\tau=t+1}^{\infty} \sum_{s^\tau | s^{t+1}} q_\tau^{t+1}(s^\tau) [c_\tau^i(s^\tau) - y_\tau^i(s^\tau)] q_{t+1}^t(s^{t+1}) \\ &= \sum_{\tau=t+1}^{\infty} \sum_{s^\tau | s^t} q_\tau^t(s^\tau) [c_\tau^i(s^\tau) - y_\tau^i(s^\tau)] \end{aligned} \quad (4.41)$$

其中第一个等式用到了前面论中我们的猜想和构造（并验证过的）序贯价格与阿罗-德布鲁价格的对应关系4.34式；第二个等式用到了 $\Upsilon_{t+1}^i(s^{t+1})$ 的定义；第三个等式是由于以下关系成立：

$$q_\tau^{t+1}(s^\tau) q_{t+1}^t(s^{t+1}) = \frac{q_\tau^0(s^\tau)}{q_{t+1}^0(s^{t+1})} \frac{q_{t+1}^0(s^{t+1})}{q_t^0(s^t)} = q_\tau^t(s^\tau) \text{ for } \tau > t$$

⁵我们在推导尾部资产定价时曾用到这一价格。

为了证明个体 i 可以支付得起这一策略, 我们利用预算约束4.24计算消费计划 $\{\tilde{c}_\tau^i(s^\tau)\}$:

$$\tilde{c}_t^i(s^t) + \sum_{s_{t+1}} \tilde{Q}_t(s^t, s_{t+1}) \tilde{a}_{t+1}^i(s^t, s_{t+1}) = y_t^i(s^t) + \tilde{a}_t^i(s^t)$$

对上式, 在 $t = 0$ 时有 $\tilde{a}_0^i(s_0) = 0$, 并将式4.41带入可得 ($t = 0$ 并将4.41中的记号 τ 变为 t):

$$\tilde{c}_0^i(s_0) + \sum_{t=1}^{\infty} \sum_{s^t} q_t^0(s^t) [c_t^i(s^t) - y_t^i(s^t)] = y_0^i(s_0) + 0$$

又根据阿罗-德布鲁均衡的预算约束4.10:

$$\sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) c_t^i(s^t) = \sum_{t=0}^{\infty} \sum_{s^t} q_t^0(s^t) y_t^i(s^t)$$

不难得到:

$$\tilde{c}_0^i(s_0) = c_0^i(s_0)$$

也就是说: 我们为序贯市场中个体猜想的这一资产组合构建方法在 $t = 0$ 时是可以支付得起的, 并且零时刻的消费与对应的阿罗-德布鲁竞争均衡中零时刻的消费的相同。

在后续的时间 $t > 0$ 和历史 s^t 下, 我们将序贯市场预算约束4.24中的 $\tilde{a}_t^i(s^t)$ 替换为 $\Upsilon_t^i(s^t)$ 可得:

$$\tilde{c}_t^i(s^t) + \sum_{s_{t+1}} \tilde{Q}_t(s^t, s_{t+1}) \tilde{a}_{t+1}^i(s^t, s_{t+1}) = y_t^i(s^t) + \Upsilon_t^i(s^t) \quad (4.42)$$

又注意到, 式4.41中的资产组合的价值可以写为:

$$\begin{aligned} & \sum_{s_{t+1}} \tilde{a}_{t+1}^i(s_{t+1}, s^t) \tilde{Q}_t(s^t, s_{t+1}) \\ &= \sum_{\tau=t+1}^{\infty} \sum_{s^\tau | s^t} q_\tau^t(s^\tau) [c_\tau^i(s^\tau) - y_\tau^i(s^\tau)] \\ &= \sum_{\tau=t}^{\infty} \sum_{s^\tau | s^t} q_\tau^t(s^\tau) [c_\tau^i(s^\tau) - y_\tau^i(s^\tau)] - q_t^t(s^t) [c_t^i(s^t) - y_t^i(s^t)] \\ &= \Upsilon_t^i(s^t) - [c_t^i(s^t) - y_t^i(s^t)] \end{aligned} \quad (4.43)$$

其中第二个等号是加一项 $\tau = t$ 时的两个求和, 再减去同一个成分, 第三个等号是根据左侧第一项就是 $\Upsilon_t^i(s^t)$ 的定义和 $q_t^t(s^t) = 1$ 。以及在我们的猜想下, 序贯均衡的预算约

束4.24（或4.42）又可写为：

$$\sum_{s_{t+1}} \tilde{a}_{t+1}^i(s_{t+1}, s^t) \tilde{Q}_t(s^t, s_{t+1}) = \Upsilon_t^i(s^t) + y_t^i(s^t) - \tilde{c}_t^i(s^t)$$

结合上面两式立得：

$$\tilde{c}_t^i(s^t) = c_t^i(s^t)$$

至此，我们证明了通过在序贯市场中选择 $\tilde{a}_{t+1}^i(s^t, s_{t+1}) = \Upsilon_{t+1}^i(s^{t+1})$, $\forall s_{t+1}$ 这一策略，可以达成与阿罗-德布鲁均衡相同的消费计划。换句话说，我们猜测的初始财富分布 $\vec{a}_0(s_0) = \vec{0}$ 是可以使两个市场下的竞争均衡等价的。

但是，为什么个体 i 不选择降低持有的资产来增加未来的消费（即为何 $\tilde{c} = c$ 在序贯市场上是最优的）？事实上，这一结果是由自然债务约束保障的。特别的，由于自然债务约束为紧时，消费者会设定后续消费全部为零，因此，若个体想要确保消费计划 $\{c_\tau^i(\tau)\}$ 在下期任何状态下都可行的话，必须从自然债务限制4.29中减去承诺的这一消费路径的价值。也就是说，个体面临比自然债务约束4.30更紧的约束，即对任意 s^{t+1} ，有约束：

$$\tilde{a}_{t+1}^i(s^{t+1}) \geq -A_{t+1}^i(s^{t+1}) + \sum_{\tau=t+1}^{\infty} \sum_{s^\tau | s^{t+1}} q_\tau^{t+1}(s^\tau) c_\tau^i(s^\tau) = \Upsilon_{t+1}^i(s^{t+1})$$

其中第二个等号用到了自然债务限制 $A_{t+1}^i(s^{t+1})$ 和尾部财富 $\Upsilon_{t+1}^i(s^{t+1})$ 的定义。这样，个体在任何时刻 t 都不会通过降低下期财富至低于 $\Upsilon_{t+1}^i(s^{t+1})$ 来提高 t 期消费，因为这样做会使得未来任何时刻任何历史下的消费难以满足序贯市场一阶条件4.33。

4.4 递归竞争均衡

对于序贯市场均衡，我们思考问题的出发点是序列形式。不过在第一章我们曾指出，序列问题的维度较高。具体看，在我们的例子中，价格 $\tilde{Q}_t(s^t, s_{t+1})$ 和财富分布 $\vec{a}_t(s^t)$ 都依赖于历史 s^t ，因此是过去所有事件 $\{s_\tau\}_{\tau=0}^t$ 的时变函数，这也导致很难从实证角度验证。我们希望经济可以由有限状态变量的函数来描述，这些状态变量足以包含过去事件的影响和当前的信息。第一章介绍的递归方法框架可以在此发挥作用。因此，我们将依照将序列问题转化为递归形式的思路，进一步定义递归竞争均衡（Recursive Competitive Equilibrium, RCE）。实践中，一些宏观模型的均衡可能并非帕累托最优，或是难以通过序列形式求解，此时定义递归竞争均衡是非常有效的。

在阿罗-德布鲁均衡和序贯均衡中，均衡由数量和价格的序列构成，即每个时点上的每个变量对应一个数值。递归竞争均衡（也可称为递归均衡）则与之不同，其特点是将均衡描述为状态变量的函数。事实上，RCE 也具有序列交易的结构，但由于我们将在动

态规划的思路下处理问题，因此定义出的均衡是以函数而非序列表达的。简言之，序贯均衡是对给定的状态变量值（如初始资本存量）定义的，而递归均衡适用于所有可能的状态变量值。

4.4.1 马尔可夫性下均衡的特征

在当前的经济设定中，能够引发我们对递归和状态的概念进行思考的只剩下随机事件 s_t 。我们未对这一随机变量做出任何假定，如独立性或时间不变性等。为了使模型中的状态变量能概括过去和当下，进而使用递归方法，我们需要对随机事件的结构做一些假定。一个自然的想法就是马尔可夫性。

给定 $\pi(s' | s)$ 为马尔科夫链，初始分布 $\pi_0(s)$ ，状态空间 $s \in S$ 。

$$\begin{aligned} Pr(s_0 = s) &= \pi_0(s) \\ Pr(s_{t+1} = s' | s_t = s) &= \pi(s' | s) \end{aligned}$$

从而有概率测度：

$$\pi_t(s^t) = \pi(s_t | s_{t-1}) \pi(s_{t-1} | s_{t-2}) \dots \pi(s_1 | s_0) \pi_0(s_0)$$

通常会给定初始状态 s_0 ，即 $\pi_0(s_0) = 1$ 。根据马尔可夫性， $t > \tau$ 时的条件概率 $\pi_t(s^t | s^\tau)$ 仅依赖 τ 时刻的状态 s_τ ，而不依赖 τ 之前的历史，因此有：

$$\pi_t(s^t | s^\tau) = \pi(s_t | s_{t-1}) \pi(s_{t-1} | s_{t-2}) \dots \pi(s_{\tau+1} | s_\tau) \quad (4.44)$$

从性质4.4中我们知道，（两种）竞争均衡中个体的消费只与当前实现的总禀赋有关，而与历史和时间无关。并且这一结论是对任意随机过程的禀赋成立的。进一步，我们假设个体 i 在 t 期的禀赋是 s_t 的时不变可测函数，即对任意 i 有 $y_t^i(s^t) = y^i(s_t)$ ，从而立得：

$$c_t^i(s^t) = \bar{c}^i(s_t) \quad (4.45)$$

将式4.44和4.45代入序贯市场的最优条件4.33可得：

$$\begin{aligned} \tilde{Q}_t(s^t, s_{t+1}) &= \beta \frac{u'_i(\bar{c}_{t+1}^i(s^{t+1}))}{u'_i(\bar{c}_t^i(s^t))} \pi_{t+1}(s^{t+1} | s^t) \\ &= \beta \frac{u'_i(\bar{c}^i(s_{t+1}))}{u'_i(\bar{c}^i(s_t))} \pi(s_{t+1} | s_t) \equiv Q(s_{t+1} | s_t), \quad s^{t+1} = (s^t, s_{t+1}) \quad \forall s_{t+1}, t, s^t \end{aligned} \quad (4.46)$$

即序贯均衡价格只与当前状态有关，与历史无关。

对阿罗-德布鲁市场，回忆在尾部资产定价中，时刻 t 历史 s^t 下交割的一单位消费品，如果以时刻 τ 和历史 s^τ 计价，其价格为：

$$\begin{aligned} q_t^\tau(s^t) &\equiv \frac{q_t^0(s^t)}{q_\tau^0(s^\tau)} = \frac{\beta^t u'_i[c_t^i(s^t)] \pi_t(s^t)}{\beta^\tau u'_i[c_\tau^i(s^\tau)] \pi_\tau(s^\tau)} \\ &= \beta^{t-\tau} \frac{u'_i[c_t^i(s^t)]}{u'_i[c_\tau^i(s^\tau)]} \pi_t(s^t | s^\tau) \end{aligned}$$

对此式应用上述假设，可类似得到：阿罗-德布鲁均衡中的相对价格 $q_t^\tau(s^t)$ 只与当前时刻 τ 的状态有关，与历史无关。

$$q_t^\tau(s^t) = \beta^{t-\tau} \frac{u'_i[\bar{c}^i(s_t)]}{u'_i[\bar{c}^i(s_\tau)]} \pi_t(s_t | s_\tau) \quad (4.47)$$

具体来讲，可以总结为如下性质：

性质 4.6 若时刻 t 的禀赋是马尔可夫状态 s_t 的函数，那么阿罗-德布鲁均衡下以时刻 τ 历史 s^τ 消费品计价的时刻 t ($0 \leq \tau \leq t$) 历史 s^t 的物品的相对价格是历史无关的，即对 $t - \tau = k - j$, $[s_\tau, s_{\tau+1}, \dots, s_t] = [\tilde{s}_j, \tilde{s}_{j+1}, \dots, \tilde{s}_k]$, 成立：

$$q_t^\tau(s^t) = q_k^j(\tilde{s}^k), \quad j, k \geq 0$$

利用相对价格的这一性质，我们可知自然债务限制4.29式和消费者财富水平4.39式是历史无关的：

$$A_t^i(s^t) = \bar{A}^i(s_t) \quad (4.48)$$

$$\Upsilon_t^i(s^t) = \bar{\Upsilon}^i(s_t) \quad (4.49)$$

式4.49对于理解序贯竞争均衡为何能达到最优（First-Best）非常关键。在最优结果下，消费者不会承担个体异质性风险（Idiosyncratic Risk）：在每一期，个体初始的财富水平与已经实现的历史禀赋是无关的；换句话说，个体过去进行的金融交易保险掉了其自身禀赋流的异质性风险。此时，状态依存的财富水平（只与当前状态 s_t 有关）是个体在 $t-1$ 期决定的，并且这一财富可以支撑此前的交易计划。

实际上，由于当期状态 s_t 决定了当期禀赋、当期价格并且包含预测未来禀赋和未来价格实现的所有信息，因此，最优财富选择只与 s_t 有关。当下期状态会使个体下期禀赋更低或是使更远的未来有更贫穷的前景时，个体当前会选择更高的财富水平。需要注意的是，总体风险（Aggregate Shock）是无法分散掉的。市场上看不见的手利用序贯均衡价格 $Q(s_t | s_{t-1})$ 和市场出清，协调各个消费者在 $t-1$ 时的交易，使他们只承担总体风

险。

4.4.2 定义递归均衡

在当前假设下，序贯价格 $Q(s' | s)$ 和禀赋 $y^i(s)$ 都只是马尔可夫状态 s 的函数。这可以使我们进一步研究递归形式下的个体最优化问题。个体 i 在时刻 t 的状态使其期初财富（ $t-1$ 时决定的） a_t^i 和当前实现的 s_t 。我们要寻找一对使个体效用最大化的决策规则 $h^i(a, s)$, $g^i(a, s; s')$:

$$c_t^i = h^i(a_t^i, s_t) \quad (4.50a)$$

$$a_{t+1}^i(s_{t+1}) = g^i(a_t^i, s_t; s_{t+1}) \quad (4.50b)$$

令 $v^i(a, s)$ 为个体 i 从状态 (a, s) 开始的问题的最优值，可以写出贝尔曼方程：

$$v^i(a, s) = \max_{c, \{\hat{a}(s')\}_{s' \in S}} \left[u_i(c) + \beta \sum_{s'} v^i(\hat{a}(s'), s') \pi(s' | s) \right] \quad (4.51)$$

个体面临预算约束：

$$c + \sum_{s'} Q(s' | s) \hat{a}(s') \leq y^i(s) + a \quad (4.52)$$

非负约束和自然债务约束：

$$c \geq 0, \quad (4.53a)$$

$$\hat{a}(s') \geq -\bar{A}^i(s'), \quad \forall s' \quad (4.53b)$$

进一步将贝尔曼方程写为：

$$v^i(a, s) = \max_{\{\hat{a}(s')\}_{s' \in S}} \left[u_i \left(y^i(s) + a - \sum_{s'} Q(s' | s) \hat{a}(s') \right) + \beta \sum_{s'} v^i(\hat{a}(s'), s') \pi(s' | s) \right]$$

由于预算约束4.52中包含了价格，因此贝尔曼方程的解隐性地依赖于 $Q(\cdot | \cdot)$ 。记使贝尔曼方程右侧达到最大的策略函数为：

$$c = h^i(a, s) \quad (4.54a)$$

$$\hat{a}(s') = g^i(a, s; s') \quad (4.54b)$$

对右侧求解关于下期财富（在特定 s' 实现下）的一阶条件可知：

$$Q(s' | s) u'_i \left(y^i(s) + a - \sum_{s'} Q(s' | s) \hat{a}(s') \right) = \beta \pi(s' | s) v_a^i(\hat{a}(s'), s')$$

又由包络定理（Benveniste-Scheinkman 条件）可知，取最优时：

$$v_a^i(a, s) = u'_i \left(y^i(s) + a - \sum_{s'} Q(s' | s) \hat{a}(s') \right)$$

从而关于下期财富的一阶条件可以重新整理为如下欧拉泛函，其中待求解的是策略函数 $\hat{a}(s') = g^i(a, s; s')$ ：

$$\begin{aligned} & Q(s' | s) u'_i \left(y^i(s) + a - \sum_{s'} Q(s' | s) g^i(a, s; s') \right) \\ &= \beta \pi(s' | s) u'_i \left(y^i(s') + a'(s') - \sum_{s''} Q(s'' | s') g^i(g^i(a, s; s'), s'; s'') \right) \end{aligned} \quad (4.55)$$

利用资源约束和最优策略的定义可将其简化为：

$$Q(s_{t+1} | s_t) = \frac{\beta u'_i(c_{t+1}^i) \pi(s_{t+1} | s_t)}{u'_i(c_t^i)} \quad (4.56)$$

其中 $c_t^i = h^i(a_t^i, s_t)$, $c_{t+1}^i = h^i(a_{t+1}^i(s_{t+1}), s_{t+1}) = h^i(g^i(a_t^i, s_t; s_{t+1}), s_{t+1})$

定义 4.9 递归竞争均衡，由一个初始财富分布 $\vec{a}_0(s_0) = \{a_0^i(s_0)\}_{i=1}^I$ 、一组自然债务限制 $\{\bar{A}^i(s)\}_{i=1}^I$ 、一组价格（Pricing Kernel） $Q(s' | s)$ 一组值函数 $\{v^i(a, s)\}_{i=1}^I$ 和一组决策规则（策略函数） $\{h^i(a, s), g^i(a, s; s')\}_{i=1}^I$ 构成，满足如下条件：

- 每期的自然债务限制满足递归方程：

$$\bar{A}^i(s) = y^i(s) + \sum_{s'} Q(s' | s) \bar{A}^i(s' | s) \quad (4.57)$$

- 所有个体 i 将价格视为给定，在给定的 a_0^i 和 $\bar{A}^i(s)$ 下，值函数和决策规则构成其优化问题的解；
- 对所有 $\{s_t\}_{t=0}^\infty$ 的实现，决策规则中隐含的最优消费-资产组合配置

$$\{\{c_t^i, \{\hat{a}_{t+1}^i(s')\}_{s' \in S}\}\}$$

满足资源和金融市场出清条件，即对 $\forall t, s'$ 成立：

$$\begin{aligned}\sum_i c_t^i &= \sum_i y^i(s_t) \\ \sum_i \hat{a}_{t+1}^i(s') &= 0\end{aligned}$$

4.5 完备市场理论的应用

4.5.1 代表性家庭的存在性

在本节我们证明代表性家庭（Representative Household）设定的合理性：其背后是由完备市场所支撑的。不失一般性，假设存在两个家庭，1 和 2，效用函数分别为 $u(c^1)$ 和 $v(c^2)$ ，符合相关规范化假设。计划者分配给他们的权重分别为 λ 和 $1 - \lambda$ 。考虑计划者的帕累托最优问题：

$$U(C) \equiv \max_{\{c^1, c^2\}} \lambda u(c^1) + (1 - \lambda)v(c^2) \quad (4.58)$$

满足资源约束：

$$c^1 + c^2 \equiv C = Y \equiv y^1 + y^2 \quad (4.59)$$

容易求得 FOC：

$$\frac{u'(c^1)}{v'(c^2)} = \frac{1 - \lambda}{\lambda} \quad (4.60)$$

定义家庭 1 和家庭 2 消费函数分别为 $x^1(C)$ 和 $x^2(C)$ ，即：

$$\{x^1(C), x^2(C)\} \equiv \arg \max_{\{c^1, c^2\}} \lambda u(c^1) + (1 - \lambda)v(c^2) \text{ s.t. } c^1 + c^2 = C$$

显然， $x^1(C)$ 和 $x^2(C)$ 都是总资源的增函数。给定 $x^1(C)$ 和 $x^2(C)$ ，计划者值函数可以写为：

$$U(C) = \lambda u(x^1(C)) + (1 - \lambda)v(x^2(C)) \quad (4.61)$$

证明代表性家庭的存在性，相当于证明两个异质家庭最优化行为进行加总后的结果与某一效用函数下的最优化行为等价，进而这一函数就能作为代表性家庭的偏好。因此必须要证明 $U(C)$ 是一个合理的效用函数。

性质 4.7 $U(\cdot)$ 关于 C 递增

证明. 由于 u 和 v 都递增， $x^1(C)$ 和 $x^2(C)$ 关于 C 递增，结论显然。 $\square$

性质 4.8 $U(\cdot)$ 是凹的

证明. 考虑两个不同水平的总资源 C 和 C' , 往证:

$$\gamma U(C) + (1 - \gamma)U(C') < U(\gamma C + (1 - \gamma)C') \quad \forall \gamma \in (0, 1)$$

将值函数4.61进一步写为:

$$\begin{aligned} \gamma U(C) + (1 - \gamma)U(C') &= \gamma [\lambda u(x^1(C)) + (1 - \lambda)v(x^2(C))] \\ &\quad + (1 - \gamma) [\lambda u(x^1(C')) + (1 - \lambda)v(x^2(C'))] \\ &= \lambda [\gamma u(x^1(C)) + (1 - \gamma)u(x^1(C'))] \\ &\quad + (1 - \lambda) [\gamma v(x^2(C)) + (1 - \gamma)v(x^2(C'))] \end{aligned}$$

由 u 和 v 的凹性,

$$\begin{aligned} &\lambda [\gamma u(x^1(C)) + (1 - \gamma)u(x^1(C'))] + (1 - \lambda) [\gamma v(x^2(C)) + (1 - \gamma)v(x^2(C'))] \\ &< \lambda u(\gamma x^1(C) + (1 - \gamma)x^1(C')) + (1 - \lambda)v(\gamma x^2(C) + (1 - \gamma)x^2(C')) \end{aligned}$$

当总资源为 $\gamma C + (1 - \gamma)C'$ 时, 对如下两个消费:

$$c^1 = \gamma x^1(C) + (1 - \gamma)x^1(C'), \quad c^2 = \gamma x^2(C) + (1 - \gamma)x^2(C')$$

他们是可行的, 但是一定不会比总资源为 $\gamma C + (1 - \gamma)C'$ 下的帕累托配置更好, 因此结合 $x^1(C)$ 和 $x^2(C)$ 的定义可知:

$$\begin{aligned} &\lambda u(\gamma x^1(C) + (1 - \gamma)x^1(C')) + (1 - \lambda)v(\gamma x^2(C) + (1 - \gamma)x^2(C')) \\ &\leq \lambda u(x^1(\gamma C + (1 - \gamma)C')) + (1 - \lambda)v(x^2(\gamma C + (1 - \gamma)C')) \end{aligned}$$

从而,

$$\begin{aligned} \gamma U(C) + (1 - \gamma)U(C') &= \lambda [\gamma u(x^1(C)) + (1 - \gamma)u(x^1(C'))] \\ &\quad + (1 - \lambda) [\gamma v(x^2(C)) + (1 - \gamma)v(x^2(C'))] \\ &< \lambda u(\gamma x^1(C) + (1 - \gamma)x^1(C')) \\ &\quad + (1 - \lambda)v(\gamma x^2(C) + (1 - \gamma)x^2(C')) \\ &\leq \lambda u(x^1(\gamma C + (1 - \gamma)C')) \\ &\quad + (1 - \lambda)v(x^2(\gamma C + (1 - \gamma)C')) \end{aligned}$$

倒数第二个小于号是由于凹性，最后一个不等号时根据 x 的定义和帕累托最优性。最终：

$$\gamma U(C) + (1 - \gamma)U(C') < U(\gamma C + (1 - \gamma)C')$$

□

上述论证过程中，我们是在计划者的帕累托最优问题下才构建出了值函数（消费配置取最优时的效用函数）。换句话说，想要允许代表性家庭存在，市场必须要能够达到一个帕累托均衡，而我们已经证明，完备市场中的竞争均衡就是帕累托最优的。因此，如果市场是完备的，那么即便市场上个体间的偏好是异质性的，他们的行为加总后都等价于一个偏好为 $U(C)$ 的代表性家庭在进行总体决策（Aggregate Decision）。实际上，当我们写下一个代表性家庭模型，其实就隐含地假设了家庭所在市场的完备性。

4.5.2 资本资产定价 (CAPM)

4.6 均衡概念的运用：分散经济下的最优增长模型

回顾本章开头的问题：我们希望证明，在一个分散经济最优增长模型中，其竞争均衡是帕累托最优的。

4.6.1 AD

为了更清晰的阐明宏观经济学中相关的均衡概念，现在先考虑如下问题：当模型中包含企业（firm）和消费者（consumer）在市场上的互动时，经济中的竞争均衡（Competitive Equilibrium）是怎样的？假设消费者拥有所有的生产要素（资本）并将其租赁给企业；假设代表性家庭拥有这些企业，索取其利润；假设产品市场和要素市场（劳动与资本）是完全竞争的（perfectly competitive），这意味着家庭和企业都将价格视为给定（take as given）。

4.6.2 SQ

4.6.3 Recursive Competitive Equilibrium

在一些宏观模型中，均衡可能并非帕累托最优，也可能难以通过序列形式或 Arrow-Debreu 形式求解，这时我们通常会定义递归竞争均衡（Recursive Competitive Equilibrium）。

不难发现，在对 AD 和 ST 进行介绍时，我们所解决问题的出发形式都是动态优化而不是此前介绍的递归形式（动态规划）。事实上，在递归方法下同样也可以定义均衡概

念。同时，RCE 时 ST 的递归表示。

4.6.4 Summerize

5 DSGE

动态随机一般均衡模型（Dynamic Stochastic General Equilibrium, DSGE）模型是过去 20 多年里宏观经济学的主要工具。这一框架在微观基础下，构建包含经济动态和随机特征的一般均衡模型来解释增长与波动。从 DSGE 模型的发展历史看，主要经历了由实体经济周期模型（Real Business Cycle Model, RBC），到新凯恩斯主义模型（NK-DSGE），再到近些年异质性主体新凯恩斯模型（HANK）的演变。当然，这些发展的背后离不开模型估计、求解、计算技术等突破及应用。

本章将先基于确定性 RCK 模型和随机最优增长模型，对 DSGE 的基础求解方法——对数线性化方法和 Blanchard-Khan 条件进行介绍；接着介绍初代 DSGE 模型——RBC 模型的构建与求解；最后对 NK-DSGE 框架进行推导求解，这是现代货币政策分析的核心工具。在本章的基础上，后续章节将对模型估计等结构宏观理论、异质性主体模型等进行详细探讨。

5.1 线性化求解

基于宏观模型的解法的不同，可以将其分为全局求解和局部求解。此前所接触的 VFI、投影法等等都属于全局解法，他们主要利用的是函数逼近与收敛的思路；局部求解则主要是基于稳态附近函数的泰勒展开，对系统的局部动态（Local Dynamics）进行估计，例如我们将要介绍的最为常见的（一阶）线性化求解。

5.1.1 对数线性化

对于模型中诸如消费 c_t 、资本 k_t 、产出 y_t 、劳动 l_t 等表示水平值的变量，线性化求解的第一步是通过对数线性化（Log-Linearized）将其变换为对自身稳态的百分比偏离。记 x_t 为一个表示水平值的变量， $\bar{x}$ 为其稳态值。那么，根据一阶泰勒展开， x_t 对于 $\bar{x}$ 的百分比偏离可表示为：

$$\hat{x}_t \equiv \log\left(\frac{x_t}{\bar{x}}\right) \approx \frac{x_t - \bar{x}}{\bar{x}}$$

从而我们可以将 x_t 表示为：

$$x_t = \bar{x}e^{\hat{x}_t} \tag{5.1}$$

同时，由一阶泰勒展开，还成立：

$$x_t = \bar{x}e^{\hat{x}_t} \approx \bar{x}(1 + \hat{x}_t) \quad (5.2)$$

需要注意的是，与对数线性化相对应的还有线性化这一概念，二者相似但不相同。一般而言，对于百分比变量，我们习惯对其进行线性化，而不是表示为对稳态的百分比偏离。例如某一模型中净利率为 r_t ，稳态为 $\bar{r}$ ，则其线性化表示为：

$$\hat{r} = r_t - \bar{r}$$

5.1.2 线性化 RCK 模型的稳定性

在相关最优条件下，我们可以将 RCK 模型写为紧凑的形式：

$$x_{t+1} = \Psi(x_t)$$

其中， $x_t = (c_t, k_t)$ ， Ψ 是包含欧拉方程和资源约束的向量值函数，从而线性化的 RCK 模型系统可以写为：

$$x_{t+1} = \bar{x} + \Psi'(\bar{x})(x_t - \bar{x})$$

或利用对数线性化方法，取对数后在稳态处进行全微分，直接将系统表示为对数偏离形式的齐次方程：

$$\begin{aligned} \log x_{t+1} &= \log \Psi(x_t) \\ \frac{x_{t+1} - \bar{x}}{\bar{x}} &= \Psi'(\bar{x}) \frac{x_t - \bar{x}}{\bar{x}} \end{aligned}$$

又由：

$$\hat{x}_t \equiv \frac{x_t - \bar{x}}{\bar{x}}$$

且在稳态处：

$$\bar{x} = \Psi(\bar{x})$$

可得对数线性化后的 RCK 模型为：

$$\hat{x}_{t+1} = \Psi'(\bar{x})\hat{x}_t \quad (5.3)$$

记 $A \equiv \Psi'(\bar{x})$ ，这是一个 2×2 的常系数矩阵，根据线性差分方程相关知识，线性化 RCK 模型系统的稳定性取决于 A 的特征值和特征向量。

我们先进一步将对数线性化后的系统写为更清晰的变量的形式。回忆刻画 RCK 模

型动态的两个关键方程：欧拉方程和资源约束，

$$\begin{aligned} u'(c_t) &= \beta u'(c_{t+1}) (f'(k_{t+1}) + 1 - \delta) \\ k_{t+1} &= f(k_t) + (1 - \delta)k_t - c_t \end{aligned}$$

对欧拉方程进行对数线性化，取对数后在稳态处全微分：

$$\begin{aligned} \log u'(c_t) &= \log \beta + \log u'(c_{t+1}) + \log (f'(k_{t+1}) + 1 - \delta) \\ u''(\bar{c}) \frac{c_t - \bar{c}}{u'(\bar{c})} &= u''(\bar{c}) \frac{c_{t+1} - \bar{c}}{u'(\bar{c})} + f''(\bar{k}) \frac{k_{t+1} - \bar{k}}{f'(\bar{k}) + 1 - \delta} \end{aligned}$$

记 $\hat{x}_t \equiv (x_t - \bar{x})/\bar{x}$ ，左侧项和右侧第一项同时乘以再除以 $\bar{c}$ ，右侧第二项同时乘以再除以 $\bar{k}$ ，可得：

$$\frac{u''(\bar{c})\bar{c}}{u'(\bar{c})} \hat{c}_t = \frac{u''(\bar{c})\bar{c}}{u'(\bar{c})} \hat{c}_{t+1} + \frac{f''(\bar{k})\bar{k}}{f'(\bar{k}) + 1 - \delta} \hat{k}_{t+1}$$

令：

$$\mathcal{R}(c) \equiv -\frac{U''(c)c}{U'(c)} \geq 0$$

并结合稳态处 $1/\beta = f'(\bar{k}) + 1 - \delta$ ，从而对数线性化后的欧拉方程为：

$$\hat{c}_{t+1} - \frac{\beta f''(\bar{k})\bar{k}}{\mathcal{R}(\bar{c})} \hat{k}_{t+1} = \hat{c}_t \quad (5.4)$$

类似地，对资源约束为：

$$\log k_{t+1} = \log [f(k_t) + (1 - \delta)k_t - c_t]$$

在稳态处全微分：

$$\hat{k}_{t+1} = \frac{1}{f'(\bar{k}) + (1 - \delta)\bar{k} - \bar{c}} [f'(\bar{k})(k_t - \bar{k}) + (1 - \delta)(k_t - \bar{k}) + (c_t - \bar{c})]$$

又由稳态时 $\bar{k} = f(\bar{k}) + (1 - \delta)\bar{k} - \bar{c}$ 以及 $1/\beta = f'(\bar{k}) + 1 - \delta$ ，整理可得对数线性化后的资源约束为：

$$\hat{k}_{t+1} = \frac{1}{\beta} \hat{k}_t - \frac{\bar{c}}{\bar{k}} \hat{c}_t \quad (5.5)$$

将两个差分方程写为矩阵形式：

$$\begin{bmatrix} 1 & -\frac{\beta f''(\bar{k})\bar{k}}{\mathcal{R}(\bar{c})} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \hat{c}_{t+1} \\ \hat{k}_{t+1} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -\frac{\bar{c}}{\bar{k}} & \frac{1}{\beta} \end{bmatrix} \begin{bmatrix} \hat{c}_t \\ \hat{k}_t \end{bmatrix}$$

整理后可得：

$$\begin{aligned} \begin{bmatrix} \hat{c}_{t+1} \\ \hat{k}_{t+1} \end{bmatrix} &= \begin{bmatrix} 1 & \frac{\beta f''(\bar{k})\bar{k}}{\mathcal{R}(\bar{c})} \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -\frac{\bar{c}}{\bar{k}} & \frac{1}{\beta} \end{bmatrix} \begin{bmatrix} \hat{c}_t \\ \hat{k}_t \end{bmatrix} \\ &= \begin{bmatrix} 1 - \frac{\beta f''(\bar{k})\bar{c}}{\mathcal{R}(\bar{c})} & -\frac{\beta f''(\bar{k})\bar{k}}{\mathcal{R}(\bar{c})} \frac{1}{\beta} \\ -\frac{\bar{c}}{\bar{k}} & \frac{1}{\beta} \end{bmatrix} \begin{bmatrix} \hat{c}_t \\ \hat{k}_t \end{bmatrix} \end{aligned}$$

也即：

$$A \equiv \begin{bmatrix} 1 - \frac{\beta f''(\bar{k})\bar{c}}{\mathcal{R}(\bar{c})} & -\frac{\beta f''(\bar{k})\bar{k}}{\mathcal{R}(\bar{c})} \frac{1}{\beta} \\ -\frac{\bar{c}}{\bar{k}} & \frac{1}{\beta} \end{bmatrix}$$

下面对系统稳定性，即矩阵 A 的特征值进行分析。根据代数知识，矩阵的判别式大于 0：

$$\begin{aligned} \Delta &\equiv \text{tr}(A)^2 - 4 \det(A) \\ &= \left(1 - \frac{\beta f''(\bar{k})\bar{c}}{\mathcal{R}(\bar{c})} + \det(A) \right)^2 - 4 \det(A) \\ &= \left(1 - \frac{\beta f''(\bar{k})\bar{c}}{\mathcal{R}(\bar{c})} - \det(A) \right)^2 > 0 \end{aligned} \tag{5.6}$$

因此特征值为实数。又根据矩阵的迹等于特征值的和，矩阵的行列式等于特征值的乘积，从而有：

$$\begin{aligned} \text{tr}(A) &= \lambda_1 + \lambda_2 = 1 - \frac{\beta f''(\bar{k})\bar{c}}{\mathcal{R}(\bar{c})} + \frac{1}{\beta} > 2 \\ \det(A) &= \lambda_1 \times \lambda_2 = \frac{1}{\beta} > 1 \end{aligned} \tag{5.7}$$

特征值乘积大于 0 说明其符号相同，而和大于 0 说明两个特征值都为正数。可以进一步利用矩阵的特征多项式进行判断。根据特征值是矩阵特征多项式的根：

$$p(\lambda) = \lambda^2 - \text{tr}(A)\lambda + \det(A) = (\lambda - \lambda_1)(\lambda - \lambda_2) = 0$$

但是：

$$p(1) = (1 - \lambda_1)(1 - \lambda_2) = 1 - \text{tr}(A) + \det(A) = -\frac{\beta f''(\bar{k})\bar{c}}{\mathcal{R}(\bar{c})} < 0$$

由于两个特征值均为正，因此必有一个不稳定特征根 $\lambda_1 > 1$ ，另一个稳定特征根 $\lambda_2 \in (0, 1)$ 。

5.1.3 线性差分方程解的性质

在进一步研究线性化 RCK 模型的特征前，需要对差分方程有所了解。首先，给定 a, b, x_0 和线性差分方程：

$$x_{t+1} - ax_t = b, \quad t = 0, 1, 2, \dots$$

当 $b = 0$ ，称其为齐次方程，解为：

$$\begin{aligned} x_1 &= a^1 x_0 \\ x_2 &= a^1 x_1 = a^2 x_0 \\ &\vdots \\ x_t &= a^1 x_{t-1} = a^t x_0 \end{aligned}$$

当 $b \neq 0$ ，称其为非齐次方程，只要 $a \neq 1$ ，系统就存在稳态

$$\bar{x} = \frac{b}{1-a}$$

不难得到解为：

$$(x_t - \bar{x}) = a^t (x_0 - \bar{x}), \quad t = 0, 1, 2, \dots$$

或可写为：

$$x_t = (1 - a^t) \bar{x} + a^t x_0, \quad t = 0, 1, 2, \dots$$

若 $a = 1$ ，稳态不存在，但仍有解：

$$x_t = tb + x_0$$

对上述线性差分方程，其稳定性取决于 a ：当 $|a| < 1$ ， $a^t \rightarrow 0$ ， $t \rightarrow \infty$ ，从而 $x_t \rightarrow \bar{x}$ ；当 $|a| > 1$ ， $a^t \rightarrow \pm\infty$ ， $t \rightarrow \infty$ ，稳态是不稳定的。注意到当 $a > 0$ ，系统是单调的；当 $a < 0$ ，系统是震荡的；当系统初始就在稳态处，那么无论 a 取何值，系统始终在稳态。

对多维情形，不失一般性，考虑 x_t 为二维的线性差分方程：

$$x_{t+1} - Ax_t = b, \quad t \geq 0$$

若 A 为对角阵，形如：

$$A = \begin{bmatrix} a_{11} & 0 \\ 0 & a_{22} \end{bmatrix}$$

那么两组方程间是独立的：

$$x_{1,t+1} - a_{11}x_{1,t} = b_1$$

$$x_{2,t+1} - a_{22}x_{2,t} = b_2$$

容易得到解为：

$$x_{1,t} = (1 - a_{11}^t) \bar{x}_1 + a_{11}^t x_{1,0}$$

$$x_{2,t} = (1 - a_{22}^t) \bar{x}_2 + a_{22}^t x_{2,0}$$

将解写为矩阵形式为：

$$x_t = (I - A^t) \bar{x} + A^t x_0$$

其中稳态为：

$$\bar{x} = (I - A)^{-1} b$$

显然，系统的稳定性取决于系数矩阵 A 的性质；同时注意到，在多维情形下，我们需要多个初始条件来确定解。

若 A 不是对角阵，即不同差分方程间存在关联，我们称其为耦合的（Coupled）。显然，在这情形下求解是复杂的，我们希望寻求将其转化为非耦合（对角化）的情形，矩阵对角化可以帮助我们。

引理 5.1 方阵 A 可被对角化，若存在可逆阵 Q 使得矩阵 D 满足：

$$D = Q^{-1} A Q$$

其中 D 是对角阵。

也就是说，当 A 不是对角阵，但是是可以对角化的，那么我们可以利用这一引理对变量进行变换：

$$z_t = Q^{-1} x_t$$

进而原差分系统可以被改写为：

$$x_{t+1} - A x_t = b \iff Q z_{t+1} - A Q z_t = b$$

即：

$$z_{t+1} - Q^{-1} A Q z_t = z_{t+1} - D z_t = Q^{-1} b$$

从而新的非耦合的差分系统为：

$$z_{t+1} = Dz_t + Q^{-1}b$$

其中 D 为对角阵。因此我们可以利用对角化情形下的结论，得到变换后方程的解：

$$\begin{aligned} z_t &= (I - D^t) \bar{z} + D^t z_0 \\ \bar{z} &= (I - D)^{-1} Q^{-1} b \end{aligned}$$

而根据 $x_t = Qz_t$ ，我们也就解决了原系统。

问题的关键在于如何确定与 A 对应的对角阵。我们希望将 A 写为 $AQ = QD$ ，其中 Q 是可逆的：

$$A \begin{pmatrix} q_1 & q_2 \end{pmatrix} = \begin{pmatrix} q_1 & q_2 \end{pmatrix} \begin{pmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{pmatrix}$$

也即：

$$\begin{aligned} Aq_1 &= \lambda_1 q_1 \\ Aq_2 &= \lambda_2 q_2 \end{aligned}$$

显然，矩阵的对角化与其特征值和特征向量密切相关：只要矩阵 A 的特征根不重复，那么 Q 的列向量就是特征根对应的特征向量，对角阵 D 的对角元素就是相应的特征根。

我们简要进行总结，然后回到线性化后的 RCK 模型上。假设系数矩阵 A 是良定义的（特征根不重复），那么可将其对角化： $A = QDQ^{-1}$ ，其中 D 为对角阵，元素是 A 的特征根，矩阵 Q 的列向量是与特征根对应的特征向量。那么对如下线性差分系统：

$$x_{t+1} = Ax_t + b, \quad t \geq 0$$

处理步骤如下：

Step 1. 计算稳态：

$$\bar{x} = (I - A)^{-1} b$$

Step 2. 将系统写为齐次形式，定义：

$$y_t \equiv x_t - \bar{x}$$

从而得到：

$$\begin{aligned}
 y_{t+1} &= x_{t+1} - \bar{x} = Ax_t + b - \bar{x} \\
 &= Ay_t + A\bar{x} + b - \bar{x} \\
 &= Ay_t + (A - I)(I - A)^{-1}b + b \\
 &= Ay_t - b + b \\
 &= Ay_t
 \end{aligned}$$

Step 3. 对角化：当 A 有不重复特征根，进行变量替换：

$$y_t \equiv Qz_t$$

从而得到：

$$Qz_{t+1} = AQz_t$$

或写为：

$$z_{t+1} = Q^{-1}AQz_t = Dz_t$$

不难得到这一齐次非耦合系统的解为：

$$z_t = D^t z_0$$

Step 4. 由 $z_t = Q^{-1}y_t$ ，可写出耦合方程：

$$y_t = QD^tQ^{-1}y_0$$

Step 5. 由 $x_t = y_t + \bar{x}$ ，写为原始变量形式：

$$\begin{aligned}
 x_t &= QD^tQ^{-1}(x_0 - \bar{x}) + \bar{x} \\
 &= (I - QD^tQ^{-1})\bar{x} + QD^tQ^{-1}x_0
 \end{aligned}$$

现在，研究系统的稳定性是容易的：若 A 的所有特征根绝对值都小于 1，那么当 $t \rightarrow \infty$ ， $D^t \rightarrow 0$ ，从而 $x_t \rightarrow \bar{x}$ 。此时，系统被称为全局稳定的。若 A 有任意特征根的绝对值大于 1，那么系统是不稳定的。根据 $y_t = Qz_t = QD^t z_0$ ，有：

$$y_t = \sum_{i=1}^n q_i \lambda_i^t z_{i,0}$$

也就是说，系统的解 y_t 是特征向量和特征根的某种加权平均。因此，若任意 λ_i 的绝对

值大于 1，那么 y_t 会发散，除非分配给那个特征根的权重为 0。

5.1.4 转移路径求解

对确定性 RCK 模型，唯一知道的就是外生参数和外生给定的初始状态 k_0 ，我们希望将消费和资本的路径表示为这些已知元素的函数。目前我们已经将抽象的最优化条件转化为了齐次线性系统：

$$\begin{bmatrix} \hat{c}_{t+1} \\ \hat{k}_{t+1} \end{bmatrix} = A \begin{bmatrix} \hat{c}_t \\ \hat{k}_t \end{bmatrix}$$

其中：

$$A \equiv \begin{bmatrix} 1 - \frac{\beta f''(\bar{k})\bar{c}}{\mathcal{R}(\bar{c})} & -\frac{\beta f''(\bar{k})\bar{k}}{\mathcal{R}(\bar{c})} \frac{1}{\beta} \\ -\frac{\bar{c}}{\bar{k}} & \frac{1}{\beta} \end{bmatrix}$$

并且，我们找到了一个不稳定特征根 $\lambda_1 > 1$ 和一个稳定特征根 $\lambda_2 \in (0, 1)$ ，但我们还没有找到具体的解。下面我们进一步求解这一系统。根据对角化方法，这一齐次系统的解可以写为：

$$\begin{bmatrix} \hat{c}_t \\ \hat{k}_t \end{bmatrix} = Q \begin{bmatrix} \lambda_1^t & 0 \\ 0 & \lambda_2^t \end{bmatrix} Q^{-1} \begin{bmatrix} \hat{c}_0 \\ \hat{k}_0 \end{bmatrix}$$

其中 Q 的列向量是 A 的特征根对应的特征向量。

但是，目前的问题在于： $\hat{k}_0$ 已经给定，但 $\hat{c}_0$ 未知。同时，有一个特征根是大于 1 的，那么当 $t \rightarrow \infty$ ，系统会爆炸。只有 $\hat{c}_0$ 恰好以正确的方式跳跃（Jump）到正确路径上，爆炸动态才会消失。具体看：

$$\begin{aligned} \begin{bmatrix} \hat{c}_t \\ \hat{k}_t \end{bmatrix} &= \begin{bmatrix} q_{11} & q_{12} \\ q_{21} & q_{22} \end{bmatrix} \begin{bmatrix} \lambda_1^t & 0 \\ 0 & \lambda_2^t \end{bmatrix} \frac{1}{\det(Q)} \begin{bmatrix} q_{22} & -q_{12} \\ -q_{21} & q_{11} \end{bmatrix} \begin{bmatrix} \hat{c}_0 \\ \hat{k}_0 \end{bmatrix} \\ &= \begin{bmatrix} q_{11}\lambda_1^t & q_{12}\lambda_2^t \\ q_{21}\lambda_1^t & q_{22}\lambda_2^t \end{bmatrix} \begin{bmatrix} q_{22}\hat{c}_0 - q_{12}\hat{k}_0 \\ -q_{21}\hat{c}_0 + q_{11}\hat{k}_0 \end{bmatrix} \frac{1}{\det(Q)} \\ &= \begin{bmatrix} q_{11}\lambda_1^t \left(q_{22}\hat{c}_0 - q_{12}\hat{k}_0 \right) - q_{12}\lambda_2^t \left(q_{21}\hat{c}_0 - q_{11}\hat{k}_0 \right) \\ q_{21}\lambda_1^t \left(q_{22}\hat{c}_0 - q_{12}\hat{k}_0 \right) - q_{22}\lambda_2^t \left(q_{21}\hat{c}_0 - q_{11}\hat{k}_0 \right) \end{bmatrix} \frac{1}{\det(Q)} \end{aligned}$$

由于当 $t \rightarrow \infty$ 时 $\lambda_1^t \rightarrow \infty$ ，因此需要通过正确的设置 $\hat{c}_0$ 来关闭爆炸路径（我们使用了一个自由度，这是唯一的一个不是由系统决定的内生变量）。也就是说，我们需要选择消费，确保不会出现违背预算约束或横截性条件的爆炸路径。显然，若设置：

$$\hat{c}_0 = \frac{q_{12}}{q_{22}} \hat{k}_0$$

那么 $q_{22}\hat{c}_0 - q_{12}\hat{k}_0 = 0$ ，可以消除大于 1 的特征根的影响，即排除不稳定动态。因此线性化 RCK 模型的解为：

$$\begin{bmatrix} \hat{c}_t \\ \hat{k}_t \end{bmatrix} = \frac{1}{\det(Q)} \begin{bmatrix} q_{12} \left(q_{11} - q_{21} \frac{q_{12}}{q_{22}} \right) \\ q_{22} \left(q_{11} - q_{21} \frac{q_{12}}{q_{22}} \right) \end{bmatrix} \lambda_2^t \hat{k}_0$$

在实践中：我们需要先找到并计算系数矩阵 A ；然后计算其特征根和特征值，得到矩阵 Q 来进行对角化；最后找到稳定的特征根来确保解的稳定性。

5.1.5 Blanchard-Khan 条件：求解线性理性预期模型

何谓宏观模型的求解？简言之，就是将模型中内生变量的动态表示为状态变量和外生变量的函数，例如上一小节对确定性 RCK 模型所进行的处理。不过，更为一般的情形是：模型中可能还有技术冲击等诸多外生随机过程，均衡条件涉及条件期望算子，因此线性化所得的系统是包含条件期望的。对于这样的线性理性预期模型，我们需要通过更一般化的方法来研究其解的性质：这就是 **Blanchard-Khan 条件**（BK 条件）。

在进一步学习 BK 条件前，我们需要再对模型中的变量类型进行强调与定义。更一般化地，模型的变量可以分为两类：**前定变量**（Predetermined Variables）和**非前定变量**（Non-Predetermined Variables），后者也被称为**跳跃变量**（Jump Variables）。顾名思义，前定变量是指：当进入第 t 期时，取值已经确定的变量，如 RCK 模型中的资本存量 k_t 、随机最优增长中的技术冲击 z_t ；非前定变量则是指：当进入第 t 期时，取值需要在当期决定的变量，如 RCK 模型中的消费。先通过如下两个例子来简单理解均衡的唯一性和（非）前定变量的特点。

例 5.1 一维跳跃变量的动态系统：假设动态系统中只有一个跳跃变量 y_t ，满足：

$$y_t = \phi y_{t+1}$$

其中参数 $\phi > 0$ 。方便起见，将上述关系写为：

$$y_{t+1} = \lambda y_t, \lambda = 1/\phi \quad (5.8)$$

写出第一个条件是为了强调这一关系并不意味着 y_{t+1} 是由 y_t 决定的。均衡的一个隐含条件是 y_t 的路径不会爆炸，即 $\lim_{T \rightarrow \infty} y_{t+T}$ 是有限值。我们感兴趣的问题是：（1） ϕ 需要满足何种条件来保证均衡的唯一性？（2）在这种条件下，均衡有什么特征？通过

迭代式 (5.8) 可知：

$$y_{t+T} = \lambda^T y_t$$

显然，当 $\lambda > 1$ 时，唯一能保证 $\lim_{T \rightarrow \infty} y_{t+T}$ 有限的情形是 $y_t \equiv 0$ ，这样均衡是存在且唯一的；当 $0 < \lambda \leq 1$ 时，任意取值的 y_t 都符合 $\lim_{T \rightarrow \infty} y_{t+T}$ 有限这一条件，这一情形被称为**未定** (Indeterminacy)，即无法确定唯一的 y_t 。因此，确保均衡**唯一性**的条件是： $\lambda > 1$ ，同时均衡解为：

$$y_t = 0, \forall t$$

换句话说，为了保证唯一性，参数 λ 需要满足：若不选择正确的 y_t ，系统就会爆炸。

进一步研究一个包含预期的动态系统：

例 5.2 一维跳跃变量和一维前定（或外生）变量的动态系统：在这一情形下，由于外生冲击（或前定变量） z_t 的影响， y_t 是随机的。考虑如下动态系统：

$$y_t = \phi \mathbb{E}_t [y_{t+1}] + \hat{z}_t$$

其中参数 $\phi > 0$ ， $\hat{z}_t$ 是服从如下过程的外生冲击：

$$\hat{z}_{t+1} = \rho \hat{z}_t + \hat{\varepsilon}_{t+1}$$

其中， $\hat{z}_t$ ， ε 是均值为 0，标准差为 $\hat{\sigma} > 0$ 的独立同分布随机变量，取值在第 t 期初确定。不难看出， $\hat{z}_t$ 是前定变量。与之前类似，将上述关系重新表示为：

$$\mathbb{E}_t [y_{t+1}] = \lambda y_t + z_t \quad (5.9)$$

其中， $\lambda = 1/\phi$ ， $z_t = -\hat{z}_t/\phi$ ，从而有：

$$z_{t+1} = \rho z_t + \varepsilon_{t+1}$$

其中 ε 均值为 0，标准差为 $\sigma = \hat{\sigma}/\phi$ 。

均衡的存在要求 $\lim_{T \rightarrow \infty} E_t [y_{t+T}]$ 是有限的，即我们希望得到 $\lim_{T \rightarrow \infty} E_t [y_{t+T}]$ 有限的解。向后代式 (5.9) 可得：

$$\mathbb{E}_{t+1} [y_{t+2}] = \lambda y_{t+1} + z_{t+1}$$

由迭代期望定律：

$$\begin{aligned}\mathbb{E}_{t+1}[y_{t+2}] &= \mathbb{E}_t[\mathbb{E}_{t+1}[y_{t+2}]] = \lambda \mathbb{E}_t[y_{t+1}] + \mathbb{E}_t[z_{t+1}] \\ &= \lambda^2 y_t + \lambda z_t + \rho z_t \\ &= \lambda^2 \left[y_t + \frac{1}{\lambda} \left[1 + \frac{\rho}{\lambda} \right] z_t \right]\end{aligned}$$

假设 $\lambda \neq \rho$ ，重复上述过程可得：

$$\begin{aligned}\mathbb{E}_t[y_{t+T}] &= \lambda^T \left[y_t + \frac{1}{\lambda} \left[1 + \frac{\rho}{\lambda} + \left(\frac{\rho}{\lambda}\right)^2 + \cdots + \left(\frac{\rho}{\lambda}\right)^{T-1} \right] z_t \right] \\ &= \lambda^T \left[y_t + \frac{1 - (\rho/\lambda)^T}{\lambda - \rho} z_t \right]\end{aligned}$$

显然，当 $\lambda > 1$ ，能够保证 $\lim_{T \rightarrow \infty} \mathbb{E}_t[y_{t+T}]$ 有限的唯一均衡解是：

$$y_t = - \lim_{T \rightarrow \infty} \frac{1 - (\rho/\lambda)^T}{\lambda - \rho} z_t = - \frac{1}{\lambda - \rho} z_t$$

当 $\lambda \leq 1$ ，由于有任意多的 y_t 取值路径都能保证 $\lim_{T \rightarrow \infty} \mathbb{E}_t[y_{t+T}]$ 有限，因此系统未定。

现在，考虑一般化情形的**线性理性预期模型**：模型中有 $n + k$ 个前定变量和 m 个非前定变量，其中前定变量由 n 个内生变量（例如资本存量 k_t ）和 k 个外生变量（例如对生产函数的冲击 z_t ）构成。假设线性化后系统形式如下：

$$\begin{matrix} B \\ (n+m) \times (n+m) \end{matrix} \times \begin{bmatrix} x_{t+1} \\ \mathbb{E}_t[y_{t+1}] \end{bmatrix} = \begin{matrix} A \\ (n+m) \times (n+m) \end{matrix} \begin{bmatrix} x_t \\ y_t \end{bmatrix} + \begin{matrix} E \\ (n+m) \times k \end{matrix} \begin{matrix} a_t \\ k \times 1 \end{matrix} \quad (5.10)$$

其中： x_t 是 $n \times 1$ 维的**内生前定变量**（注意不含外生前定变量）； y_t 是 $m \times 1$ 维的**非前定变量**（一定非外生）； a_t 是 $k \times 1$ 维的**外生（前定）变量**（外生冲击）； B 和 A 是 $(n + m) \times (n + m)$ 矩阵； E 是 $(n + m) \times k$ 矩阵。¹ 方便起见，假设外生冲击均服从 AR(1) 过程，对第 i 个冲击：

$$a_{t+1}^i = \rho_i a_t^i + \varepsilon_{t+1}^i, \quad \forall i = 1, \dots, k$$

其中 ε_{t+1} 均值为 0 且独立同分布。

¹大多数宏观模型线性化后具有这种形式，但也有特例。

若矩阵 B 可逆，式 (5.10) 可写为：

$$\begin{bmatrix} x_{t+1} \\ \mathbb{E}_t[y_{t+1}] \end{bmatrix} = B^{-1}A \begin{bmatrix} x_t \\ y_t \end{bmatrix} + B^{-1}Ea_t \quad (5.11)$$

记 $F = B^{-1}A$, $G = B^{-1}E$ ，由若当分解（Jordan Decomposition）， F 可变换为：

$$F = HJH^{-1}$$

从而：

$$\begin{bmatrix} x_{t+1} \\ \mathbb{E}_t[y_{t+1}] \end{bmatrix} = HJH^{-1} \begin{bmatrix} x_t \\ y_t \end{bmatrix} + Ga_t \quad (5.12)$$

其中矩阵 J 是由矩阵 F 的特征根构成的对角阵：

$$\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_{n+m} \end{bmatrix}$$

并且分解可以按照特征根绝对值从小到大排列进行的，即 $|\lambda_1| < |\lambda_2| < \cdots < |\lambda_{n+m}|$ ，记其中绝对值大于 1 的特征根数目为 h 。矩阵 H 由相应特征根对应的列向量构成：

$$\begin{bmatrix} v_1 & v_2 & \cdots & v_{n+m} \end{bmatrix}$$

BK 条件表明：均衡唯一（ x_t 和 y_t 的解路径不会爆炸）的条件是 $h = m$ ，即单位圆外的特征根数等于非前定变量个数。这与此前例子中的直觉一致：这里的矩阵 F 类似于前例中的 λ 。事实上，矩阵与向量相乘本质上就是在矩阵的特征向量方向上对向量进行扩展（压缩）或旋转；而特征值则告诉我们矩阵乘法究竟是沿特征向量所在方向扩展（特征值大于 1）还是压缩（特征值小于 1）了原向量。当 $h = m$ 时，我们可以选择唯一的均衡集合需要使得变换后的向量 $[x'_t \ y'_t]'$ 在相应扩展方向上为 0，即不会出现爆炸路径。

下面进一步求解和验证。将式 (5.12) 两侧同时左乘 H^{-1} 得到：

$$H^{-1} \begin{bmatrix} x_{t+1} \\ \mathbb{E}_t[y_{t+1}] \end{bmatrix} = JH^{-1} \begin{bmatrix} x_t \\ y_t \end{bmatrix} + H^{-1}Ga_t \quad (5.13)$$

注意到矩阵 H^{-1} 和 J 是 $(n+m) \times (n+m)$ 维的，可以对它们进行分块运算：将其行分

为 n 和 m 行两部分，将其列分为 n 和 m 列两部分，即

$$H^{-1} = \begin{bmatrix} \tilde{H}_{11} & \tilde{H}_{12} \\ \tilde{H}_{21} & \tilde{H}_{22} \end{bmatrix} \begin{matrix} n \times n & n \times m \\ m \times n & m \times m \end{matrix}$$

$$J = \begin{bmatrix} J_1 & 0 \\ 0 & J_2 \end{bmatrix} \begin{matrix} n \times n & \\ & m \times m \end{matrix}$$

其中 J_1 和 J_2 都是对角阵。为了与分块的形式对应，令：

$$H^{-1}G = \begin{bmatrix} \Gamma_1 \\ \Gamma_2 \end{bmatrix} \begin{matrix} n \times k \\ m \times k \end{matrix}$$

并定义：

$$\begin{bmatrix} \tilde{x}_t \\ \tilde{y}_t \end{bmatrix} \begin{matrix} n \times 1 \\ m \times 1 \end{matrix} = \begin{bmatrix} \tilde{H}_{11} & \tilde{H}_{12} \\ \tilde{H}_{21} & \tilde{H}_{22} \end{bmatrix} \begin{bmatrix} x_t \\ y_t \end{bmatrix} \quad (5.14)$$

在上述记号和定义下，式 (5.13) 可写为：

$$\begin{bmatrix} \tilde{x}_{t+1} \\ \mathbb{E}_t[\tilde{y}_{t+1}] \end{bmatrix} \begin{matrix} n \times 1 \\ m \times 1 \end{matrix} = \begin{bmatrix} J_1 & 0 \\ 0 & J_2 \end{bmatrix} \begin{bmatrix} \tilde{x}_t \\ y_t \end{bmatrix} \begin{matrix} n \times 1 \\ m \times 1 \end{matrix} + \begin{bmatrix} \Gamma_1 \\ \Gamma_2 \end{bmatrix} \begin{matrix} n \times k \\ m \times k \end{matrix} a_t \begin{matrix} k \times 1 \end{matrix}$$

我们重点关注后 m 个方程 ($i = n + 1, \dots, n + m$)，希望它们能与单位圆外的特征根相对应（但实际未必成立 $m = h$ ）：

$$\mathbb{E}_t[\tilde{y}_{t+1}] = J_2 \tilde{y}_t + \Gamma_2 a_t$$

$$\begin{matrix} m \times 1 & m \times m & m \times 1 & m \times k & k \times 1 \end{matrix}$$

注意到上式与例 5.2 中式 (5.9) $= \lambda y_t + z_t$ 十分相似。事实上，由于 J_2 是对角阵，我们可以利用与处理例 5.2 相同的步骤来处理当前的每个元素，进而确保迭代后取极限得到的

$m \times 1$ 维向量 $\lim_{T \rightarrow \infty} \mathbb{E}_t [\tilde{y}_{t+T}]$ 中的元素都是有限值。将 $m \times k$ 维矩阵 Γ_2 记为:

$$\Gamma_2 = \begin{bmatrix} \gamma_2^{n+1} \\ \gamma_2^{n+2} \\ \vdots \\ \gamma_2^{n+m} \end{bmatrix}$$

其中 γ_2^i ($i = n+1, \dots, n+m$) 是 $1 \times k$ 维行向量。那么, 对向量 $\mathbb{E}_t [\tilde{y}_{t+1}]$ 中的第 i 个元素 ($i = n+1, \dots, n+m$):

$$\begin{aligned} \mathbb{E}_t [\tilde{y}_{t+T}^i] &= \lambda_i^T \left[\tilde{y}_t^i + \frac{1}{\lambda_i} \left[1 + \frac{\rho_i}{\lambda_i} + \left(\frac{\rho_i}{\lambda_i} \right)^2 + \dots + \left(\frac{\rho_i}{\lambda_i} \right)^{T-1} \right] \gamma_2^i a_t^i \right] \\ &= \lambda_i^T \left[\tilde{y}_t^i + \frac{1 - (\rho_i/\lambda_i)^T}{\lambda_i - \rho_i} \gamma_2^i a_t^i \right], \quad \forall i = n+1, \dots, n+m \end{aligned}$$

显然, 若 $\lambda_i \in [0, 1]$, 那么系统未定 (任意取值的 $\tilde{y}_t^i$ 都能保证极限有限); 若 $\lambda_i \in [-1, 0]$, 系统同样未定; 因此要保证均衡存在且唯一, 必须要求后 m 个方程中都成立 $|\lambda_i| > 1$, $i = n+1, \dots, n+m$, 即 $m \geq h$, 原因在于若 $m < h$, 那么后 m 个方程中必然有发散的 $\tilde{y}_t^i$ 但若 $m > h$, 这违背了定义 (注意 h 是我们定义的单位圆外特征根数), 因此必然有 $h = m$, 也就是 BK 条件; 并且均衡解 $\tilde{y}_t$ 必须满足:

$$\tilde{y}_t^i = - \lim_{T \rightarrow \infty} \frac{1 - (\rho_i/\lambda_i)^T}{\lambda_i - \rho_i} \gamma_2^i a_t^i = - \frac{1}{\lambda_i - \rho_i} \gamma_2^i a_t^i, \quad \forall i = n+1, \dots, n+m$$

将其写为紧凑的矩阵形式:

$$\tilde{y}_t = \Lambda \Gamma_2 a_t$$

$\begin{matrix} m \times 1 & m \times m & m \times k & k \times 1 \end{matrix}$

其中矩阵 Γ 是 $m \times m$ 维对角阵, 对角元为 $-1/(\lambda_i - \rho_i)$, $i = n+1, \dots, n+m$ 。

下面我们可以将 y_t 和 x_{t+1} 用 x_t 表出。根据式 (5.14) 中 $\tilde{y}_t$ 的定义可知:

$$\Lambda \Gamma_2 a_t = \tilde{H}_{21} x_t + \tilde{H}_{22} y_t$$

从而非前定变量 (跳跃变量) y_t 的解可用前定变量 x_t 表示为:

$$y_t = -\tilde{H}_{22}^{-1} \tilde{H}_{21} x_t + \tilde{H}_{22}^{-1} \Lambda \Gamma_2 a_t \quad (5.15)$$

又由式 (5.12) 和 $F = HJH^{-1}$, 可写出:

$$\begin{bmatrix} x_{t+1} \\ \mathbb{E}_t[y_{t+1}] \end{bmatrix} = \begin{matrix} F \\ (n+m) \times (n+m) \end{matrix} \begin{bmatrix} x_t \\ y_t \end{bmatrix} + \begin{matrix} G \\ (n+m) \times k \end{matrix} a_t$$

将其进行分块表示:

$$F = \begin{bmatrix} F_{11} & F_{12} \\ F_{21} & F_{22} \end{bmatrix} = \begin{bmatrix} H_{11} & H_{12} \\ H_{21} & H_{22} \end{bmatrix} \begin{bmatrix} J_1 & 0 \\ 0 & J_2 \end{bmatrix} \begin{bmatrix} \tilde{H}_{11} & \tilde{H}_{12} \\ \tilde{H}_{21} & \tilde{H}_{22} \end{bmatrix}$$

$$G = \begin{bmatrix} G_1 \\ G_2 \end{bmatrix}$$

从而 x_{t+1} 可用 x_t 表示为:

$$x_{t+1} = F_{11}x_t + F_{12}y_t + G_1a_t = (F_{11} - F_{12}\tilde{H}_{22}^{-1}\tilde{H}_{21})x_t + (G_1 + F_{12}\tilde{H}_{22}^{-1}\Lambda\Gamma_2)a_t \quad (5.16)$$

我们将上述可以将上述过程应用于线性化后的随机最优增长模型。

例 5.3 随机最优增长模型的 BK 解法: 我们对此前介绍的随机最优增长模型进行适当扩展, 假设代表性家庭的目标函数为:

$$\mathbb{E}_0 \left[\sum_{t=0}^{\infty} \beta^t (\log(C_t) - \xi H_t) \right]$$

资源约束为:

$$K_{t+1} + C_t = \exp(z_t) K_t^\alpha H_t^{1-\alpha} + (1 - \delta)K_t$$

其中, 资本存量 K_t 为 (内生) 前定变量, 消费 C_t 和劳动供给 H_t 为非前定变量, 技术冲击 z_t 是 (外生) 前定变量, 服从:

$$z_{t+1} = \rho z_t + \varepsilon_{t+1}$$

不难得到欧拉方程为:

$$\frac{1}{C_t} = \mathbb{E}_t \left[\beta (1 + \alpha \exp(z_{t+1}) K_{t+1}^{\alpha-1} H_{t+1}^{1-\alpha} - \delta) \frac{1}{C_{t+1}} \right]$$

劳动供给方程为：

$$\frac{1}{C_t}(1 - \alpha) \exp(z_t) K_t^\alpha H_t^{1-\alpha} = \xi$$

在本例中我们以大写字母 X_t 表示水平值， $\bar{X}$ 表示稳态值，小写字母 $x_t \equiv \log(X_t/\bar{X})$ 为对稳态值的偏离。^a 对资源约束、欧拉方程和劳动供给方程进行对数线性化可得：

$$\begin{aligned} \bar{K}k_{t+1} + \bar{C}c_t &= \bar{K}^\alpha \bar{H}^{1-\alpha} (z_t + \alpha k_t + (1 - \alpha)h_t) + (1 - \delta)\bar{K}k_t \\ -c_t &= \mathbb{E}_t [\beta \alpha \bar{K}^{\alpha-1} \bar{H}^{1-\alpha} (z_{t+1} + (\alpha - 1)k_{t+1} + (1 - \alpha)h_{t+1}) - c_{t+1}] \\ h_t &= \frac{1}{\alpha}(z_t + \alpha k_t - c_t) \end{aligned}$$

由于劳动供给的选择是静态的，将其代入前两个方程，并对第二个方程利用 $\mathbb{E}_t[z_{t+1}] = \rho z_t$ ，整理可得：

$$\begin{aligned} \bar{K}k_{t+1} &= \frac{\bar{K}^\alpha \bar{H}^{1-\alpha}}{\alpha} z_t + (\bar{K}^\alpha \bar{H}^{1-\alpha} + (1 - \delta)\bar{K}) k_t - \left(\frac{1 - \alpha}{\alpha} \bar{K}^\alpha \bar{H}^{1-\alpha} + \bar{C} \right) c_t \\ (\beta(1 - \alpha)\bar{K}^{\alpha-1} \bar{H}^{1-\alpha} + 1) \mathbb{E}_t[c_{t+1}] &= \beta \bar{K}^{\alpha-1} \bar{H}^{1-\alpha} \rho z_t + c_t \end{aligned}$$

我们希望将这两个方程（即线性化后的模型）以如下矩阵形式表出：

$$B \begin{bmatrix} x_{t+1} \\ \mathbb{E}_t[y_{t+1}] \end{bmatrix} = A \begin{bmatrix} x_t \\ y_t \end{bmatrix} + E a_t$$

在本例中， $x_t = k_t$ ， $y_t = c_t$ ， $a_t = z_t$ ，从而有：

$$B \begin{bmatrix} k_{t+1} \\ \mathbb{E}_t[c_{t+1}] \end{bmatrix} = A \begin{bmatrix} k_t \\ c_t \end{bmatrix} + E z_t$$

其中：

$$\begin{aligned} B &= \begin{bmatrix} \bar{K} & 0 \\ 0 & \beta(1 - \alpha)\bar{K}^{\alpha-1} \bar{H}^{1-\alpha} + 1 \end{bmatrix} \\ A &= \begin{bmatrix} \bar{K}^\alpha + (1 - \delta)\bar{K} & -((1 - \alpha)\bar{K}^\alpha \bar{H}^{1-\alpha}/\alpha + \bar{C}) \\ 0 & 1 \end{bmatrix} \\ E &= \begin{bmatrix} \bar{K}^\alpha \bar{H}^{1-\alpha}/\alpha \\ \beta \bar{K}^{\alpha-1} \bar{H}^{1-\alpha} \rho \end{bmatrix} \end{aligned}$$

假设在模型参数下，矩阵 B 可逆，将方程两侧左乘 B^{-1} ，并令 $F = B^{-1}A$ ， $G = B^{-1}E$ ，根据此前的推导和记号可得：

$$\begin{aligned} c_t &= -\tilde{H}_{22}^{-1}\tilde{H}_{21}k_t + \tilde{H}_{22}^{-1}\Lambda\Gamma_2 z_t \\ k_{t+1} &= \left(F_{11} - F_{12}\tilde{H}_{22}^{-1}\tilde{H}_{21}\right)k_t + \left(G_1 + F_{12}\tilde{H}_{22}^{-1}\Lambda\Gamma_2\right)z_t \end{aligned}$$

^a $Z_t = \exp(z_t)$ ，使用这种记号只是为了对数线性化时书写的方便。

5.1.6 广义 Shur 方法

对线性理性预期模型：

$$B \begin{bmatrix} x_{t+1} \\ \mathbb{E}_t[y_{t+1}] \end{bmatrix} = A \begin{bmatrix} x_t \\ y_t \end{bmatrix} + E a_t$$

应用 BK 条件的前提是矩阵 B 可逆。若矩阵 B 不可逆，我们需要利用广义 Shur 分解（又被称为 QZ 分解）而不再是 Jordan 分解。

5.2 RBC

5.3 新凯恩斯-DSGE

6 宏观计量理论与方法

6.1 Empirical Macro Methods

6.2 DSGE 模型的估计与贝叶斯方法

6.3 结构估计

Part II 量化宏观核心理论

7 不完全市场理论

7.1 局部均衡下的不完全市场

7.2 一般均衡下的不完全市场

8 总体不确定下的异质性模型

8.1 Krusell-Smith 算法

8.2 实现 KS 算法

8.3 Reiter 算法

9 企业动态

9.1 企业动态基础

9.2 微观异质性与宏观动态

Part III 现代量化宏观主要模型：HANK

10 异质性家庭理论

10.1 TANK 模型

10.2 HANK 模型

11 异质性企业理论

11.1 异质性企业模型求解

11.2 金融异质性

Part IV 量化宏观专题

12 宏观债务、周期与政策

12.1 企业债务

12.2 家庭债务

12.3 政府债务

13 银行、金融危机与宏观政策

13.1 银行挤兑

13.2 银行资本

13.3 宏观政策与金融危机

14 异质性模型前沿理论

14.1 Structural Method

14.2 深度强化学习与分布计算